分类号 _____ 密 级 _____

UDC _____

昆明理工大学

硕士专业学位论文

复杂环境下无人车辆全局路径规划研究

研 究 生 姓 名 袁志豪

指导教师姓名、职称 杨秀建 教授

学 科 专 业 交通运输

研 究 方 向 无人车辆路径规划

论 文 工 作

起 止 日 期 2022 年 12 月~2024 年 6 月

论 文 提 交 日 期 2024 年 6 月

中国知网 https://www.cnki.net

摘 要

近年来，随着人工智能应用领域的拓展，多学科领域交叉融合发展的趋势日益深入。无人驾驶正从人类的未来畅想逐步成为现实，并有望解决日趋严重的交通拥堵、交通事故频发等问题。本文主要研究对象为复杂环境下的无人车辆全局路径规划，研究主要目的在于决策系统快速规划出一条满足无人车辆行驶安全的路径。A*算法是一种经典启发式路径规划算法，凭借其高效性、最优性、完备性以及灵活性等优点，目前已广泛应用于无人车辆、机器人等路径规划领域，但是传统 A*算法在路径规划过程中存在着扩展节点过多、路径质量不佳等问题，针对此类问题，本文从复杂环境下无人车辆全局路径规划这一角度出发，对 A*算法进行了相关改进，主要工作如下：

第一，针对平坦复杂环境。本文首先为 A*算法建立了一个全新的扩展策略，即双邻域选择扩展策略。相较于传统扩展策略，新的扩展策略具有扩展范围大、扩展次数少、路径质量佳等优点，能有效提高 A*算法路径规划效率。其次，本文为 A*算法重新设计了代价函数，进一步提高算法效率。最后针对规划出的路径冗余节点多等问题，采用了冗余点剔除策略、三次 B 样条平滑的方式，对路径进行了优化，有效提高了路径质量。在后续仿真分析与试验验证中，结果均表明本文所改进的 A*算法能快速规划出一条安全的路径。

第二，考虑到无人驾驶应用场景的拓宽，非平坦复杂环境下地形条件对路径规划的影响不容忽略。因此本文基于 A*算法提出一种应用于非平坦环境下无人车辆全局路径规划的 IGA*算法。首先，对非平坦环境建立了新的环境地图模型，即错栅格粒度地图模型，该模型能够在降低 DEM 分辨率的同时极大保留环境信息，为后续算法优化奠定基础。其次，考虑无人车辆在非平坦地形环境下的通过性，以最大爬坡度、地面阶跃高度以及地面陡峭度为指标，为 IGA*算法建立满足可纳性与一致性的代价函数。最后，通过在不同地图环境下仿真以及试验验证，证明了 IGA*算法的有效性与普适性。与 A*算法相比，IGA*算法无论是路径质量还是算法效率，均得到了大幅优化。

通过本文上述工作，改进后的算法能够满足不同场景下无人车辆全局路径规划的需求，复杂环境下无人车辆全局路径规划这一问题得到了有效解决。

关键词：无人车辆，路径规划，A*算法，代价函数，非平坦地形，环境地图模型

中国知网 https://www.cnki.net

ABSTRACTS

In recent years, with the expansion of artificial intelligence application fields, the trend of cross-fertilisation and development of multidisciplinary fields has become increasingly deep. Unmanned vehicles are gradually becoming a reality from the future of mankind's imagination, and are expected to solve the increasingly serious traffic congestion, traffic accidents and other problems. The main research object of thesis is global path planning for unmanned vehicles in complex environments, and the main purpose of the research is to make decisions to quickly plan a path to meet the safety of unmanned vehicles. The A* algorithm is a classical heuristic path planning algorithm, which is widely used in the field of unmanned vehicles, robots, and other path planning by virtue of its high efficiency, optimality, completeness, flexibility, etc., but the traditional A* algorithm has problems in the path planning process, which is not easy to solve. A* algorithm in the path planning process exists in the expansion of too many nodes, poor path quality and other problems, for such problems, thesis from the perspective of unmanned vehicles in complex environments global path planning, the A * algorithm for the relevant improvements, the main work is as follows:

First, for the flat complex environment. Thesis firstly establishes a new expansion strategy for the A* algorithm, i.e., the dual-neighbourhood selection expansion strategy. Compared with the traditional expansion strategy, the new expansion strategy has the advantages of large expansion range, fewer expansion times, and better path quality, which can effectively improve the path planning efficiency of A* algorithm. Secondly, thesis redesigns the cost function for the A* algorithm to further improve the efficiency of the algorithm. Finally, for the planned path redundant nodes and other problems, the redundant point elimination strategy, three times B-spline smoothing is used to optimise the path, which effectively improves the path quality. In the subsequent simulation analysis and experimental verification, the results show that the improved A* algorithm in thesis can quickly plan a safe path.

Secondly, considering the widening of unmanned application scenarios, the influence of terrain conditions on path planning in uneven terrain and complex environments cannot be ignored. Therefore, thesis proposes an IGA* algorithm based on the A* algorithm applied to global path planning for unmanned vehicles in non-flat environments. Firstly, a new environmental map model is established for the uneven terrain environment, i.e., the interleaved granularity map model, which can greatly retain the environmental information while reducing the resolution of the DEM, laying a foundation for the subsequent optimisation of the algorithm. Secondly, considering the passability

中国知网 https://www.cnki.net

of unmanned vehicles in uneven terrain, the maximum gradient, ground step height and ground steepness are used as indicators to establish a cost function for the IGA* algorithm that meets the requirements of naturability and consistency. Finally, the effectiveness and universality of the IGA* algorithm are demonstrated through simulation and experimental verification in different map environments. Compared with the A* algorithm, the IGA* algorithm is substantially optimised in terms of both path quality and algorithm efficiency.

Through the above work in thesis, the improved algorithm can meet the needs of global path planning for unmanned vehicles in different scenarios, and the problem of global path planning for unmanned vehicles in complex environments has been effectively solved.

Keywords: unmanned vehicles, path planning, A* algorithm, cost function, uneven terrain, environment map model

中国知网 https://www.cnki.net

目　录

第一章 绪论.....1
1.1 研究背景及意义.....1
1.2 国内外无人车辆发展现状.....2
1.2.1 国外无人车辆发展现状.....2
1.2.2 国内无人车辆发展现状.....6
1.3 无人车辆路径规划研究现状.....7
1.3.1 A*算法研究现状.....7
1.3.2 非平坦地形条件下路径规划研究现状.....8
1.4 本文主要研究内容.....10
1.5 本章小结.....11
第二章 环境地图模型与路径规划算法.....13
2.1 路径规划的定义.....13
2.2 环境地图模型.....13
2.2.1 点云地图.....14
2.2.2 栅格地图.....15
2.2.3 八叉树地图.....17
2.2.4 数字高程模型.....19
2.3 路径规划算法.....20
2.3.1 Dijkstra 算法.....20
2.3.2 Best First Search 算法.....22
2.3.3 A*算法.....24
2.3.4 PRM 算法.....26
2.3.5 RRT 算法.....29
2.3.6 人工势场法.....31
2.4 本章小结.....34
第三章 基于双邻域选择扩展策略的 A*路径规划算法.....35
3.1 双邻域选择扩展 A*路径规划算法.....35
3.1.1 改进邻域扩展策略.....35
3.1.2 代价函数优化.....39
3.1.3 冗余点剔除策略.....41
3.1.4 三次 B 样条曲线路径平滑.....43
3.1.5 算法流程.....44
3.2 仿真分析评价.....45
3.3 试验分析验证.....48

中国知网 https://www.cnki.net

3.4 本章小结.....51
第四章 基于错栅格粒度地图的 A*路径规划算法.....53
4.1 错栅格粒度地图模型.....53
4.2 IGA*算法.....58
4.2.1 地形通过性评估.....58
4.2.2 IGA*算法代价函数.....60
4.2.3 代价函数的一致性与可纳性.....61
4.2.4 IGA*算法策略.....62
4.3 仿真分析评价.....63
4.3.1 有效性分析.....63
4.3.2 普适性分析.....69
4.4 试验分析评价.....71
4.5 本章小结.....75
第五章 总结与展望.....77
5.1 总结.....77
5.2 展望.....77
参考文献.....79

中国知网 https://www.cnki.net

第一章 绪论

1.1 研究背景及意义

自 1885 年世界上第一辆汽车诞生至今已逾 130 余年[1]，这段漫长的历史见证了人类工业、社会、经济等领域翻天覆地的变革。而汽车的发展也一直贯穿其中，成为时代的见证者和推动者。汽车的出现拉近了人们的空间距离，极大促进了人口流动，从而在推动经济社会发展方面发挥了不可忽视的作用。与此同时，科技的发展进一步催生了汽车相关产业的技术革新，将汽车产业推向了一个新的高度。



图 1.1 世界上第一辆汽车

Figure 1.1 The world's first car

如今，汽车已经成为人们日常生活中不可或缺的一部分。根据不完全统计，截至 2023 年底，全球汽车保有量已达 14.46 亿辆。爆发式增长的汽车数量带来了一系列社会问题，其中包括交通拥堵和交通事故频发等。为有效应对这些问题，各国政府有关部门相继出台了一系列限制措施，包括限行、限购、限号等，但这些措施的效果一直收效甚微，难以从根本上解决交通拥堵和交通安全问题。因此，寻找新的解决方案势在必行。

与此同时，随着近年来人工智能应用领域的拓展，多学科领域交叉融合发展的趋势日益深入。无人驾驶车辆开始由科幻一步步转换为现实，并有望成为解决交通拥堵和提高交通安全的重要工具之一[2]。无人驾驶车辆的兴起被认为是未来交通系统的一大创新，其背后涉及到人工智能、感知技术等多个前沿领域的突破，有关技术的发展也标志着人类科技水平的飞跃。在此背景下，无人驾驶车辆相关技术与研究迎来了珍贵的发展机遇，同时也面临着一系列挑战。

目前，无人驾驶车辆系统主要分为三个部分：感知、决策与控制[3,4]。在以上三部分中，决策起着至关重要、承上启下的作用。决策是指在感知到周围环境的基础上，根据车辆当前状态和目标，制定最佳行动方案的过程。在无人驾驶车辆系统中，决策涉及到诸多方面，包括行驶路径的选择、车速的调整、交通规则的遵守等等。而作为决策之一的路径规划，其规

中国知网 https://www.cnki.net

划结果直接影响着无人驾驶车辆的行驶稳定性和安全性，其重要性不言而喻。深入研究无人车辆路径规划也具有以下重要意义：

(1) 通行效率提升：优秀的路径规划可以快速帮助无人驾驶车辆选择最佳的行驶路线，避开无法通行的路段，优化车辆行驶过程，从而提高整体的交通效率。这不仅减少了车辆在路上的停滞时间，也有助于减少交通拥堵，改善城市交通状况。

(2) 安全性增强：良好的路径规划能够使无人驾驶车辆更加安全地行驶。通过考虑道路条件、通行约束条件、周围环境等因素，路径规划可以避免潜在的行驶威胁，并最大程度地降低行驶风险，保障行人和乘车人员的安全。

(3) 适应复杂环境：现实世界中的无人车辆行驶环境变化多端，包括道路环境、多类型障碍物、其他车辆和行人等因素。良好的路径规划需要能够适应这些复杂的环境变化，及时调整行驶策略，保证车辆能够在各种情况下安全地行驶。

(4) 提升用户体验：无人驾驶车辆的用户体验与其路径规划密切相关。合理的路径规划不仅可以减少规划时间，还可以提供更加舒适和愉悦的乘车体验，增强用户对无人驾驶技术的信心和接受度。

(5) 未来发展的基础：无人驾驶技术是未来交通系统发展的重要方向之一。深入研究无人车辆路径规划，可以为未来智能交通系统的建设提供技术支持和基础理论，推动智能交通领域的发展和进步。

综上所述，研究无人车辆路径规划对于提升交通效率、增强安全性、改善用户体验以及推动智能交通系统的发展都具有重要意义，是当前和未来智能交通领域的关键研究方向之一。

1.2 国内外无人车辆发展现状

1.2.1 国外无人车辆发展现状

关于无人驾驶车辆的相关研究，最早可追溯到百余年前。1921 年，美国军方在美国俄亥俄州一街道进行无线电控制汽车相关实验并获得成功，这被认为是人类对于无人驾驶车辆的最早技术探索[5]。时间来到 4 年后，美国 HOUDINA 无线电控制公司的创始人前美陆军工程师 Francis P. Houdina 在美国纽约曼哈顿区百老汇大道对其改装后的一辆无线电操控汽车进行了道路实验，Houdina 通过发射无线电信号进而控制该车辆行驶，这辆后来被称为“American Wonder”的车辆是人类历史上第一辆有据可查的无人驾驶车辆[6,7]。1939 年，在美国纽约世界博览会上，美国通用汽车公司提出了“自动高速公路”(Automated Highway System, AHS)这一概念，展示了其关于未来汽车与交通的发展设想[8]。随着第二次世界大战的结束，人类科学技术发展迎来了一个新的阶段。在 1966 年至 1972 年间，美国斯坦福国际研究院（Stanford Research International，SRI）成果研制出了世界上第一个移动机器人 Shakey，该机器人能够实现自主感知、决策与控制，而这也成为了后来的机器人与无人驾驶

中国知网 https://www.cnki.net

车辆的系统主要框架，直至今日[9-11]。1977 年，地点来到日本，日本筑波工程研究实验室的 S.Tsugawa 及其同事创新性地将两个摄像头安装于无人驾驶车辆上，在高架轨道的辅助作用下，通过所搭载的摄像头来检测轨道信息，最高车速达到了 30 km/h，这是目前已知最早基于视觉设备进行无人驾驶的尝试[12]。自此，无人驾驶翻开了一个新的篇章。

1986 年，在美国国防部高级研究计划局(Defense Advanced Research Projects Agency, DARPA)“战略计算计划”项目的支持下，美国卡内基梅隆大学的 NavLab 研究小组推出了 NavLab 系列第一辆自动驾驶车辆 NavLab 1[13]，该车搭载了包括视觉相机、激光测距仪、超声测距仪、陀螺仪、GPS 等在内的一系列传感器，之后在卡内基梅隆大学校园内进行了相关道路测试。然而，测试结果并不理想，在典型结构化道路环境中，NavLab 1 最高车速只达到了 28 km/h，在之后的非结构化道路上则只有 12 km/h。针对此问题，团队在 1995 年推出了 NavLab 5。与 NavLab 1 相比，NavLab 5 各方面均得到了较大提升，并在之后进行了横穿美国大陆的道路实验，他们从匹兹堡、宾夕法尼亚州到加利福尼亚州的圣地亚哥，从东海岸到西海岸，总实验里程长达 4587 km。在这次实验中，NavLab 5 完成了 98.2%的自动驾驶任务，单次最长自动驾驶距离达到了 111km，平均车速也提升到了 102.72 km/h[14,15]。目前，NavLab 系列最新一代为 NavLab 11，该系统通过采用神经网络实现了道路环境的识别与分析，在道路测试中，NavLab 11 最高车速可达 102 km/h，较之 NavLab 1 已提高了 264%。

除了上述 NavLab 系列，几乎在同一时间开发的德国 VaMoRs 系列对无人驾驶车辆同样具有深远意义。

1987 年，德国慕尼黑联邦国防军大学的 Ernst Dickmann 教授及其团队将一辆奔驰面包车改装成无人驾驶车辆，并采用机器视觉技术进行相关车道线的识别，随后在德国巴伐利亚州丁戈尔芬的一条封闭的高速公路上进行了测试[16]。作为 VaMoRs 系列的初代作品，测试期间，该车车速一度达到了 96km/h，测试里程超过 20 公里[17,18]。在彼时的技术条件下，该测试结果极大鼓舞了相关研究人员的信心，并对后世无人驾驶车辆相关研究产生了深远影响。八年后，Dickmanns 教授团队与梅赛德斯-奔驰汽车公司团队在初代 VaMoRs 系统基础上推出了第二代系统，并成功搭载在两台奔驰 500 SEL 轿车上，两辆车分别命名为 VITA-1 和 VITA-2。与初代相比，第二代 VaMoRs 系统车辆前后都搭载了由两个 CCD 摄像头构成的双目视觉系统，并拥有更高配置的计算单元。在后续超过 1600 公里的道路测试中，无人驾驶系统完成了近 95%的自动驾驶任务，最高车速至高达到了 180 km/h[19]。

1998 年，意大利帕尔玛大学的 Alberto Borggi 教授带领团队开发了 ARGO 无人车。在之后的长距离道路测试实验中 ARGO 完成了近 94%的自动驾驶任务，最高车速为 112 km/h，与 NavLab 1 实验类似，实验道路同样包括了非结构化的山地丘陵道路与结构化的城市道路[20,21]。

如图 1.2 所示，从左至分别为 NavLab、VaMoRs 及 ARGO 无人车辆。

中国知网 https://www.cnki.net



图 1.2 NavLab、VaMoRs、ARGO 无人车辆（从左至右）

Figure 1.2 NavLab, VaMoRs, ARGO unmanned vehicles (from left to right)

随着 21 世纪的到来，在阿富汗战争这一背景下， DARPA 于 2004 年 3 月在美国加利福尼亚州东南部的莫哈维沙漠地区举办第一届 DARPA 无人车辆挑战赛（DARPA Grand Challenge）。当局希望通过此次比赛，加快推动无人驾驶车辆技术，并早日应用于美军陆地装备无人化[22]。本届比赛通过预选赛与资格赛角逐后有包括 SUV、怪兽卡车以及摩托车等各种类型车辆（如图 1.3 所示）在内的共计 15 只车队进入决赛，但没有车辆能够完成全程 240 公里的比赛，最终，来自卡内基梅隆大学的 Sandstorm 赢得了最远距离冠军[23]。



图 1.3 参加第一届 DARPA 无人车辆挑战赛决赛部分车辆

Figure 1.3 Some of the vehicles that participated in the finals of the 1st DARPA Unmanned Vehicle Challenge

一年后的 2005 年 10 月，第二届 DARPA 无人车辆挑战赛如期举行。相较于第一届，第二届比赛道路环境更为恶劣。在最终在进入决赛的 23 只队伍中，共有 5 只队伍跑完全程，完成比赛任务。后根据行驶时间判定，斯坦福大学的 Stanley、卡内基梅隆大学的 Sandstorm 和 Highlander 分别获得了前三名[24]。

2007 年 11 月，第三届 DARPA 无人车辆挑战赛在美国西部加利福尼亚州维克多维尔的乔治空军基地举办。与前两届比赛不同的是，本届比赛道路环境不再是沙漠地形环境，而是全长 96 公里的结构化道路城市环境，比赛中车辆需要遵守所有交通规则并同时与周围交通工具交互协同，赛事名称也更名为“DARPA Urban Challenge”。最终，在进入决赛的 11 只队伍中，共有 6 只队伍跑完全程，完成比赛任务。后根据行驶时间判定，卡内基梅隆大学的 Boss、斯坦福大学的 Junior 和弗吉尼亚理工大学的 Odin 获得了前三名[25,26]。此届比赛同时也是 DARPA 无人车辆挑战赛的最后一届。图 1.4 展示了部分参加第二届及第三届 DARPA

中国知网 https://www.cnki.net

无人车辆挑战赛的车辆。DARPA 通过短短三届比赛，极大的促进了无人驾驶车辆技术的发展，在无人驾驶历史上留下了浓墨重彩的一笔，对于无人驾驶而言极具里程碑意义。



图 1.4 参加第二届及第三届 DARPA 无人车辆挑战赛部分车辆

Figure 1.4 Selected vehicles participating in the 2nd and 3rd DARPA Unmanned Vehicle Challenges

2009 年 1 月，谷歌正式启动名为“Project Chauffeur”的无人驾驶项目，这也标志着传统互联网公司开始进军无人驾驶领域。第一代谷歌无人车辆由丰田 Prius 改造而来，车上搭载了包括 Velodyne 64 线激光雷达以及摄像头在内的多种传感器，并在后续道路测试中完成了 100 英里的自动驾驶任务[27]。2012 年 5 月，谷歌获得了内华达州颁发的第一张自动驾驶汽车测试牌照，并于同年推出了改造自 Lexus Rx450h SUV 的第二代无人车辆，并在后续道路测试中累计完成了超过 30 万英里的测试任务。

2014 年 5 月，谷歌推出了一款名为“Firefly”的无人驾驶车辆，该车在配备了包括摄像头、毫米波雷达、激光雷达和超声波等在内的一系列传感器的同时，整合了 Google 地图和云服务等优势资源，使得人机交互体验大大增强。在第二年，一位盲人乘客乘坐 Firefly，在完全没有人工干预的情况下，Firefly 成功通过了美国得克萨斯州首府奥斯汀市区，完成了一次真正意义上的无人驾驶。图 1.5 展示了谷歌的历代无人车辆。



图 1.5 谷歌历代无人车辆

Figure 1.5 Google's generations of unmanned vehicles

2014 年，美国汽车工程学会（Society of Automotive Engineers，SAE）制定了无人驾驶汽车分级标准 SAE J3016《标准道路机动车驾驶系统分类与定义》，正式对无人车辆自动化划分为六个等级[28,29]。2015 年 10 月，特斯拉推出了一款名为 Autopilot 的半自动驾驶系统，这是第一款商用的自动驾驶技术。2016 年，谷歌无人驾驶项目正式从谷歌独立，取名“Waymo”。两年后，Waymo 推出了全球第一个没有人员监督的无人驾驶汽车服务[30]。

2023 年 8 月 26 日，特斯拉公司 CEO Elon Reeve Musk（埃隆·里夫·马斯克）在互联网上向全球直播了特斯拉最新一代自动驾驶系统 FSD Beta V12 的道路测试全过程[31]。FSD

中国知网 https://www.cnki.net

Beta V12 是有史以来第一个端到端 AI 自动驾驶系统（Full AI End-to-End），从头到尾都是通过 AI 实现，99%的决策都是由神经网络给出的，不需要高精地图、不需要激光雷达，仅仅依靠车身的摄像头视觉输入，通过神经网络分析思考，输出控制策略。

1.2.2 国内无人车辆发展现状

与国外相比，国内无人驾驶领域的研发整体呈现起步迟缓，但发展迅速的趋势。大致可分为以下三个阶段：

（1）早期探索阶段（2010 年前）：在这一阶段，国内对于无人车辆主要停留在学术研究和实验阶段。自上世纪八十年代前后，有部分高校和科研机构开始进行相关技术探索和实验验证。“八五”计划期间，由清华大学、浙江大学、国防科技大学、北京理工大学以及南京理工大学联合研制了 ABT-I 系列无人车。1995 年，清华大学的何克忠教授带领团队开始对无人车辆进行研制和开发，后续推出了多款 THMR-V 系列智能车，最新一代 THMR-V 最高车速超过了 100 km/h[32]。

（2）技术突破阶段（2010 年 - 2020 年）：在这一阶段，各大科技公司和汽车制造商相继推出无人车产品和解决方案。国内无人车辆技术迎来快速发展期，涵盖了自动驾驶、智能交通管理、智能物流等多个领域。2011 年，中国第一汽车集团有限公司联合国防科技大学共同研发了红旗 HQ3 智能无人车辆，在后续 286 公里的高速公路自动驾驶实验中，平均车速为 87 km/h，最高车速达到了 170 km/h[33,34]。2015 年，百度公司开始进军无人驾驶领域，加大了对无人驾驶车辆相关技术的研发，并在后续推出了 Apollo 系列无人车辆[35,36]，如图 1.6 所示。



图 1.6 百度 Apollo 无人车

Figure 1.6 Baidu Apollo unmanned vehicle

（3）商业应用阶段（2020 年至今）：在这一阶段，政府相关政策支持和市场需求推动了无人车辆行业与技术的快速发展。无人车辆逐渐走向商业化应用，并涉及自动驾驶出租车、物流配送车辆、农业机器人等多个领域。2020 年，新能源汽车公司小鹏汽车推出新款小鹏 P7[37]，该车型搭载了包括摄像头、毫米波雷达等一系列传感器，可实现停车场内自动泊车。2021 年，蔚来汽车推出最新款 ET7，该车型搭载了最新的 Aquila 蔚来超感系统，进一步优化了车辆驾驶行为与感知能力[38]。2022 年，百度推出 Apollo 第六代量产无人车 Apollo

中国知网 https://www.cnki.net

RT6，该车具备 L4 级自动驾驶能力，并于同年发布“萝卜快跑”无人出租车出行服务，首批测试城市涵盖北京、上海、广州、深圳、重庆、长沙、沧州等，无人车辆行驶区域包括景区、学校及园区等[39,40]。国内无人驾驶领域开始迎来蓬勃发展阶段。

1.3 无人车辆路径规划研究现状

无人驾驶车辆路径规划以现有地图作为参考，基于此对起始位置和目标位置进行识别。对于环境地图信息的已知程度在路径规划模块的设计起着重要的作用。根据车辆对环境信息的已知程度，路径规划可分为两类：第一类，无人驾驶车辆已知当前地图上的所有信息，包括各障碍物信息、可行道路信息等，并在此情况下进行规划，这种类型被称为全局路径规划(Global Path Planning)[41-43]。第二类，无人驾驶车辆对当前环境缺乏全部或部分先验信息。因此，在搜索过程中无人车辆必须实时依靠各类传感器感知当前环境信息，并获取障碍物的位置，建立实时地图，规划出一条通向目标位置的合适路径。这种类型的路径规划称为局部路径规划(Local Path Planning)[44-46]。

在算法应用层面上，二者并没有严格的界限区别，同一算法通过不同调参配置可分别应用于二者。路径规划部分依据上层感知模块所获得的环境地图模型进行路径的规划计算，得出的路径输出给执行控制层遵循行驶，因此，路径规划的好坏直接制约着智能车辆的行驶表现。

1.3.1 A*算法研究现状

根据算法原理，目前无人车辆的路径规划方法大致可分为：基于采样的方法（如 RRT、PRM），基于生物启发式的方法（如遗传算法、蚁群算法、神经网络算法、粒子群算法、混合蛙跳算法等），基于节点的方法（如 Dijkstra、A*、D*），以及基于数学模型的方法（如 DWA、APF）[47-54]。其中，基于节点的 A*算法具有计算效率高、规划路径短的优点，因而被广泛应用于机器人、无人车辆路径规划领域中，但 A*算法存在规划路径冗余点较多、路径不平滑、转角过大等问题。

针对 A*算法效率这一问题，很多学者都对 A*算法进行了研究，并提出了多种改进的 A*算法，如 Block A*、Theta A*、REA*、HPA*等多种高效算法。加拿大阿尔伯塔大学的 Yap 等[55]通过引入 LDDB 算法策略建立了 Block A*算法，实现了 A*算法速度的提高。Nash 等[56,57]通过改进 A*算法建立了 Theta A*算法，在保持优秀搜索速度的同时实现了 A*算法任意角度的搜索，大幅减少了 A*算法规划出的路径的转角数及冗余点。但却使得算法复杂度陡增，计算压力大幅增高。针对此问题，后续研究人员进行了改进[58]。西北工业大学的 Zhang 等[59]针对 A*算法提出一种新的扩展策略——Rectangle expansion（矩形扩展），提高了算法速度，未考虑路径质量。加拿大阿尔伯塔大学的 Botea 等[60]提出一种层次 A*算法（HPA*），通过对地图预处理，实现分层级寻路，面对规模较大的地图时，大幅减少 A*算法路径搜索时间，A*算法搜索效率明显提升，不足之处在于其算法效率的提升是以牺牲路径最优性为

中国知网 https://www.cnki.net

代价的。浙江工业大学的赵晓等[61]在 A*算法基础上结合跳点搜索策略(JPS)，大幅减少了 A*算法搜索路径过程中的扩展节点数量，对算法速度有了质的提升，但未深入研究路径转角过大等问题。美国南加州大学的 Uras 等[62]通过对地图提前预处理，提高了 A*算法的路径搜索速度，但却使得算法实时动态性变差。摩苏尔大学的 Algfoor 等[63]通过一种新的加权策略，增加代价函数在代价函数中的权重，显著提升了 A*算法的路径搜索效率。

以上大部分研究其本质上都是选择牺牲部分路径最优性，通过建立新的路径搜索策略，使 A*算法路径搜索效率得到大幅提升。当然，对于路径最优性，也有不少学者从这一角度对 A*算法进行改进。如中国农业大学的曹如月等[64]通过调节 A*算法中的权重及拐角优化，在提高算法效率的同时有效降低了路径拐角数量。中国农业大学的劳彩莲等[65]利用关键点选取策略，通过相邻节点的斜率对路径方向进行判断，减少路径冗余节点，实现了路径平滑，但导致路径长度增大，非最优路径。合肥工业大学的李鑫等[66]通过修改代价函数，加入拐点惩罚因子，同时采用时空冲突约束，使路径拐点个数明显下降，规划出无冲突路径，结果也是导致路径长度增加。信息工程大学的欧阳明达等[67]通过引入非适配区，进而判断经 A*算法规划后的路径两点间连线是否通过非适配区，删除多余的路径节点，使路径转折减少，长度缩短。但未考虑二次规划路径与障碍物的距离，易与障碍物拐角发生碰撞。武汉科技大学的李晓露等[68]针对 A*算法提出一种新的启发搜索策略（将邻域父节点的选取范围扩大至当前点到起始点的整个支路），通过寻找真实代价 G 最小的安全路径，解决了规划路径长度非最优以及冗余转折较多的问题，但未对算法效率进行优化。其他与此类似优化 A*算法路径长度与转折角度的方法还有采用步长分割[69]、建立新的代价函数[70]等

也有不少研究人员，是基于路径规划特殊应用场景进行改进的，如北京交通大学的陈光荣等[71]基于 A*改进算法对四向移动机器人路径搜索进行了研究，针对于特定场景，对 A*算法进行了改进，取得了一定的效果，未深入研究普遍场景。上海工程技术大学的路永鑫等[72]针对电力应急机器人通过修改 A*算法代价函数，引入安全威胁代价，同时利用梯度下降法，使机器人远离障碍物并安全到达目标点。但路径明显变长，且转折点增多，不利于机器人运动。

以上各研究人员针对 A*算法的改进，在一定程度上均取得了一定的效果，对于无人车辆亦或机器人路径规划都有一定的应用价值与现实意义。

1.3.2 非平坦地形条件下路径规划研究现状

上述基于平坦环境等结构化场景的各研究成果，在各场景中都默认地面高度不发生改变，但随着无人驾驶领域的扩大，对于非平坦地形环境下无人车辆路径规划的研究变得愈发重要。2022 年 8 月 15 日，科技部印发了《科技部关于支持建设新一代人工智能示范应用场景的通知》，《通知》要求进一步拓展自动驾驶需求，实现复杂环境场景下的自动驾驶以及开展露天矿矿车无人驾驶示范应用[73]。与结构化道路环境相比，露天矿场等非平坦环境最大特征在于环境地形的复杂性以及多样性[74]。

中国知网 https://www.cnki.net

目前，针对非平坦地形等三维环境下路径规划问题，众多研究学者取得了一定的研究成果。针对环境模型描述的问题，北京理工大学的张浩杰等[75]针对三维环境设计了一种变维度状态空间，通过维持关键区域高维状态空间其他区域低维化，提出了变维度状态空间的增量式路径规划方法，有效提高了机器人路径规划速度。波兰 Poznan 大学的 Belter 等[76]考虑野外环境地形条件，基于六足机器人通过性建立相关语义环境地图，实现机器人安全路径规划，不足之处在于未对提高算法效率进行更深一步研究。大连理工大学的闫飞等[77]采用自适应可变阈值聚类算法，利用面向拓扑结构和高程图单元的分级匹配策略，构建了全局一致性的拓扑高程地图，以此建立双重环境约束，实现室外复杂环境下移动机器人路径规划。北京工业大学的黄志清等[78]针对非平坦地形条件，通过高程信息与障碍物信息图层的分离，建立了一种双分辨率 2.5D 分层栅格地图，在此基础上重新定义了非平坦地形下 A*算法代价函数，提升了非平坦地形下机器人路径规划的安全性。上述研究通过所提出的不同环境模型实现了对三维环境地形的描述，大大丰富了现有三维环境路径规划中地图模型理论体系，并基于此从不同角度实现对非平坦地形等三维环境下路径规划的优化。但以上方法均存在一定局限性，如：所建立环境模型复杂性过高，会造成部分信息冗余，不利于路径规划效率提升，或建立环境模型会丧失部分环境信息，导致所规划路径最优性、安全性有所下降。

而基于常用地图模型，目前研究大多从路径规划算法评价指标为切入点。其中，在路径能耗方面：阿联酋沙迦大学的 Saad 等[79]考虑无人驾驶车辆在野外地形条件下的能量消耗，建立相关能量耗散模型，引导 Dijkstra 算法规划出能量损失较少的可行路径，但与此同时，算法容易产生局部最优解。浙江工业大学的殷建军等[80]考虑距离能耗约束，建立数字高程模型（Digital Elevation Model, DEM）地图下相关能量损耗模型，引导 A*算法完成路径的搜索，减少了复杂环境下农业机器人的能量消耗，实现了能耗最优路径规划，但未考虑机器人自身的运动学与动力学约束，从而降低了路径的可行性与安全性。中国香港理工大学的 Ganganath 等[81]针对丘陵地形，通过对 DEM 降低维度的方式，依据能量成本代价函数规划出一条能量损耗较少的路径，但由此不可避免带来了路径安全性下降。哈尔滨工业大学（威海）的 Liu 等[82]考虑车辆滚动阻力系数对于规划路径通过性以及车辆运动能量损耗的影响，将滚动阻力系数加入 A*算法代价函数计算中，实现了野外环境下基于 DEM 环境地图模型的车辆路径规划，但未考虑环境地形特征对车辆通过性的约束，不利于规划路径的最优性。

此外，也有不少学者从效率角度出发，对现有算法进行改进，以期提高算法效率。在这方面，山东大学的张慧等[83]利用 DEM 对 TOF 相机所感知的环境信息进行地形描述，分析地面坡度、粗糙度和起伏度等地形信息，采用增量式 A*算法有效提高了路径规划算法效率，但使用了二维平面的曼哈顿距离作为代价函数，不符合三维环境的信息特征，易造成路径最优性有所下降。信息工程大学的冯世盛等[84]通过对 DEM 进行地形量化，考虑越野车辆坡道通行阈值建立了环境地图模型，对 Dijkstra 算法融合了方向指向以及分段处理策略，实现了不同越野场景下路径规划算法的快速响应，但未考虑环境地形其他条件约束对车辆通过性的影响，算法存在一定的局限性。而对于机器人，亦或无人车辆而言，通过性决定了路径可

中国知网 https://www.cnki.net

行性以及安全性。针对规划路径的通过性，深圳大学的 Zhang 等[85]基于部分已知的先验环境地图信息，依据地形通过性提出了一种改进代价函数的 A*算法，实现了非平坦地形下轮式机器人的路径规划。哈尔滨工业大学的徐鹏等[86]从地面力学角度出发，提出表征地面法向松软特性和切向摩擦特性的参数化指标，以通过性为优化目标，实现了六足机器人安全路径规划。以上二者研究的不足之处在于均未涉及对算法效率的提升改进。

1.4 本文主要研究内容

当前，对于路径算法研究大多集中于机器人领域，也涌现了大量优秀的算法，但与机器人领域不同，智能车辆路径规划不仅仅需要考虑规划效率、路径质量，还应当考虑车辆运动学、动力学等多种约束对路径的影响。同时，随着各种智能车辆在农业、林业、军事方面得到大量应用，智能车辆的路径规划不应只局限于二维简单环境，因此研究复杂环境下智能车辆全局路径规划具有重要意义。本文研究内容主要包括：

（1）针对如何高效实现复杂环境下智能车辆路径规划这一问题，以智能车辆在复杂环境下的路径规划为研究目标，设计一种路径规划方法并完成仿真、试验评价，以实现复杂环境下智能车辆路径规划。

（2）选择目前应用较为广泛的 A*算法为基础算法进行研究改进。在复杂平坦环境中以二值化的栅格地图为标准环境地图模型，针对传统 A*算法所存在规划路径冗余点较多、路径不平滑、转角过大、环境地图过大时效率低下等问题进行研究改进。

（3）通过建立新的路径搜索策略近一步提高 A*算法路径规划效率，并选择合适的算法对规划好的路径进行冗余点剔除以实现路径的进一步优化，在此基础上采用路径平滑算法对规划好的路径进行平滑处理，最终规划出一条适合的智能车辆行驶路径，基于 Matlab 完成仿真评价后选择合适的试验场景完成试验评价分析。

（4）在非平坦地形下的复杂环境中选择采用 DEM（Digital Elevation Model，数字高程模型）为标准环境地图模型。针对当环境地图分辨率过大时能较为清楚反映出环境细节但会导致 A*算法路径规划效率低下，但环境地图分辨率过小时虽然能显著提高路径规划的效率，却会使得环境信息有所缺失，从而规划出危险路径，降低了路径的安全性这一问题，建立新的地图环境模型。

（5）研究改进复杂非平坦环境下 A*算法的路径搜索策略，在保证路径安全性的前提下能有效提高规划效率。分析地形环境对智能车辆通过性的影响，综合考虑智能车辆最大爬坡度、最大阶跃高度、陡峭度对路径的限制，通过添加相关约束完成非平坦地形下智能车辆 3 维路径规划研究。对改进的算法在 Matlab 仿真环境下完成仿真研究，之后选择合适的试验场景完成试验评价分析。

中国知网 https://www.cnki.net

1.5 本章小结

本章主要介绍了本文研究背景与意义，并简要回顾了无人车辆发展历程，总结了目前无人车辆的研究现状，然后深入无人车辆研究热点之一的路径规划，介绍了目前无人车辆路径规划的相关研究现状。最后确定了本文主要研究内容与技术路线。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

第二章 环境地图模型与路径规划算法

本章主要内容为介绍无人车辆路径规划体系中涉及的环境地图模型与相关路径规划算法理论。首先对路径规划进行问题描述，其次介绍路径规划问题中常用到的几种环境地图模型，最后介绍了几种常用的路径规划算法相关理论。

2.1 路径规划的定义

无论是无人车辆还是机器人，其决策体系中路径规划问题均可描述为：在完全已知或部分已知且存在障碍物的运动环境中，按照所需决策指标（如时间、能耗、距离等）寻找出一条由起始点至终点的安全无碰撞的最优可行路径[87]。

在运动环境状态空间 C 中，各种障碍物占据的空间定义为障碍物空间 C_{obs}，除此以外的其他状态空间为自由空间 C_{free}，三者关系为：

$$C_{free} = C / C_{obs} \qquad \text{式 (2.1)}$$

无人车辆的路径规划即在自由空间 C_{free} 中规划出一条由起始位姿状态 q_s 至终点位姿状态 q_g 的安全路径 $path$，即：

$$path = C\left[q_s, q_g\right] \in C_{free} \quad \text{且} \quad path \cap C_{obs} = \varnothing \qquad \text{式 (2.2)}$$

除此以外，路径规划问题实际应用中还应注意以下要求：

(1) 算法具备良好的路径搜寻速度；

(2) 算法在不同环境下均具有良好的规划效果；

(3) 路径距离长度应尽可能短；

(4) 路径应尽量平滑并避免不必要的转角；

(5) 路径与各障碍物不发生碰撞并尽可能保持适量安全距离；

(6) 路径满足机器人或无人车辆运动约束条件，符合运动要求。

2.2 环境地图模型

环境地图模型是指用于描述机器人所处运动环境状态空间的抽象化表示，其包含了该环境中所有的静态、动态元素环境信息，比如障碍物、自由区域、环境边界等。环境地图的建立属于 SLAM 中的重要一环，其通过机器人自身所搭载的各种传感器（如可见光相机、激光雷达、毫米波等）获取周围环境信息，提取环境相关特征，将各种环境信息组合后建立相关环境信息表征，准确反映该环境中的元素信息。目前常用的地图类型有：点云地图[88]、栅格地图[89]、八叉树地图[90]以及数字高程模型[91]。

中国知网 https://www.cnki.net

2.2.1 点云地图

点云是组成点云地图的最小单元，其为一组在三维空间中离散的点，每一组点在包含最基本的三维空间坐标 x，y，z 的同时还记录所在区域 r，g，b 色彩信息，因此，点云中的每一个点都具有 $[x,y,z,r,g,b]^{\mathrm{T}}$ 的形式。作为一种典型的度量地图，点云地图状态表达较为直观，地图状态空间中被占据的地方存在点云，没有点云的地方即为自由空间。同时，点云地图可以较为清晰地描述环境中各物体间的位置关系，并在一定条件下准确反映物体的表面信息，如图 2.1 所示。

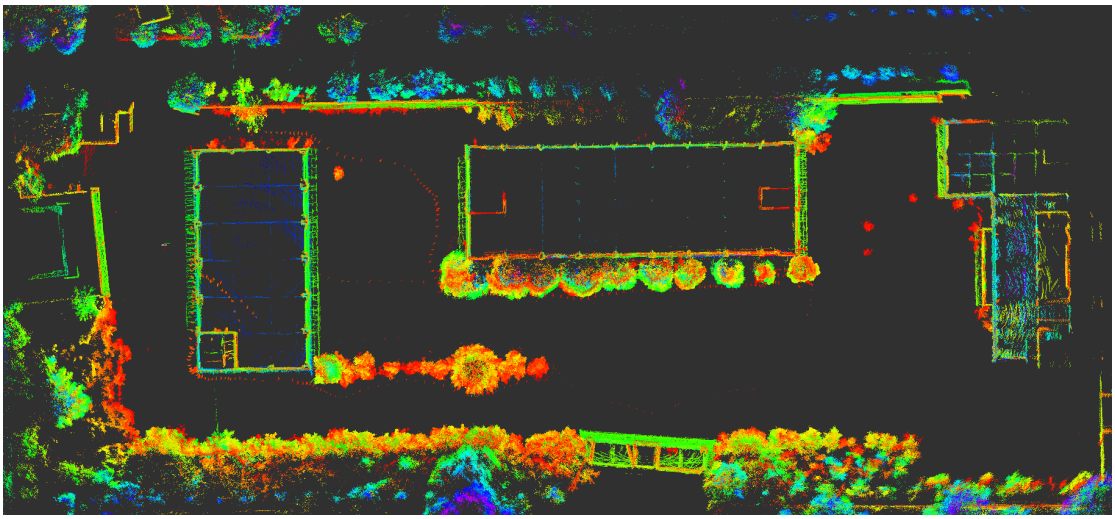


图 2.1 点云地图

Figure 2.1 Point cloud map

目前，点云地图主流构建为采用 RGB-D 相机进行稠密建图，建图时将 RGB-D 数据转换为点云数据，然后进行拼接，将离散点云组合完成点云地图的构建。空间中各点与 RGB-D 相机图像中的像素点存在以下投影关系：

$$Z_c\begin{bmatrix}u\\v\\1\end{bmatrix}=\boldsymbol{K}\begin{bmatrix}X_{\mathrm{c}}\\Y_{\mathrm{c}}\\Z_{\mathrm{c}}\end{bmatrix}=\begin{bmatrix}f_x&0&c_x\\0&f_y&c_y\\0&0&1\end{bmatrix}\begin{bmatrix}X_{\mathrm{c}}\\Y_{\mathrm{c}}\\Z_{\mathrm{c}}\end{bmatrix} \quad \text{式 (2.3)}$$

式（2.3）中，$[X_{\mathrm{c}},Y_{\mathrm{c}},Z_{\mathrm{c}}]^{\mathrm{T}}$ 为空间中一点在 RGB-D 相机坐标系下的坐标，其图像上投影的像素坐标为 $[u,v]^{\mathrm{T}}$，$\boldsymbol{K}$ 为 RGB-D 相机内参矩阵；f_x、f_y、c_x、c_y 为内参矩阵具体参数。

若已知像素坐标 $[u,v]^{\mathrm{T}}$，求该点在 RGB-D 相机坐标系下的坐标即为：

$$\begin{cases}Z_c=\dfrac{d}{s}\\X_c=\dfrac{Z_c(u-c_x)}{f_x}\\Y_c=\dfrac{Z_c(v-c_y)}{f_y}\end{cases} \quad \text{式 (2.4)}$$

中国知网 https://www.cnki.net

式（2.4）中，d 为深度图像其深度值；s 为比例系数。

通过式（2.4）计算每个像素点在相机坐标系下的坐标，即可得到整张图像的点云。计算完毕各帧点云坐标信息后，将各帧点云进行拼接，完成点云地图的构建。若已知空间中一点在世界坐标坐标系下坐标为 $\boldsymbol{P}_{\mathrm{w}}$，在 RGB-D 相机坐标系下坐标为 $\boldsymbol{P}_{\mathrm{c}}$，在图像中的坐标为 $\boldsymbol{p}_{uv}$，则各坐标系的转换关系如下：

$$s\boldsymbol{p}_{uv} = \boldsymbol{K}\boldsymbol{P}_{\mathrm{c}} = \boldsymbol{K}\boldsymbol{T}_{\mathrm{cw}}\boldsymbol{P}_{\mathrm{w}} \quad \text{式 (2.5)}$$

$$\boldsymbol{P}_{\mathrm{w}} = \boldsymbol{T}_{\mathrm{cw}}^{-1}\boldsymbol{P}_{\mathrm{c}} \quad \text{式 (2.6)}$$

式（2.5）（2.6）中，$\boldsymbol{T}_{\mathrm{cw}}$ 为世界坐标系转换至 RGB-D 相机坐标系下的变换矩阵。

通常，在点云地图构建过程中，第一帧点云将被定义为关键帧，该帧点云对应的坐标系定义为世界坐标系，后续其他帧点云拼接、配准将以该帧点云为基准。假设第 i 帧关键帧点云为 Q_i，第 i 帧关键帧的 RGB-D 相机位姿为 $\boldsymbol{T}_i$，第 j 帧关键帧点云为 Q_j，第 j 帧关键帧的 RGB-D 相机位姿为 $\boldsymbol{T}_j$。两帧点云拼接时，首先应当统一坐标系，将各帧点云分别转换坐标系至世界坐标系下，然后进行拼接，得到新的点云：

$$Q^{*} = \boldsymbol{T}_i^{-1}Q_i + \boldsymbol{T}_j^{-1}Q_j \quad \text{式 (2.7)}$$

通过上述过程，点云地图完成建立。显然，点云地图有着数据丰富，能准确描述环境信息等优点，但也存在信息冗余，存储数据量较大的问题，不利于路径规划任务的快速完成，将直接影响到路径规划的效率以及准确性。

因此，在机器人路径规划问题具体实践过程中，点云地图通常不能直接用于路径规划，需要将其抽象化为其他存储简单、数据量小、环境信息表征准确的环境地图模型，如栅格地图模型。

2.2.2 栅格地图

栅格地图是机器人路径规划方法中常用的环境地图模型。机器人工作环境中任意一点存在两种状态，即存在障碍物或不存在障碍物，栅格地图通过将机器人工作环境离散化为若干独立的正方形栅格，每一个栅格都对应着真实工作环境中的具体位置，依据真实环境位置是否存在障碍物将对应的栅格赋予被占据或空闲状态，所有被赋予状态后的栅格共同组成了环境地图模型，如图 2.2 所示。

在数学上，通过对栅格赋值可将栅格地图表示为一个数值矩阵，大大降低环境地图存储占用空间。在栅格地图中，处于被占据状态的栅格用黑色表示，对应数值矩阵中的值为 1；处于空闲状态的栅格用白色表示，对应数值矩阵中的值为 0。因此，栅格地图的数学模型可表示为：

中国知网 https://www.cnki.net

$$M=\begin{pmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{pmatrix},\ a_{ij}=0,1 \qquad \text{式 (2.8)}$$

式（2.8）中，M 为整个环境地图模型，m 和 n 分别为环境地图栅格化后每行、每列栅格数，a_{ij} 为 (i,j) 处栅格。其中 $a_{ij}=0$ 表示空闲状态栅格，不存在障碍物；$a_{ij}=1$ 表示被占据状态栅格，存在障碍物。

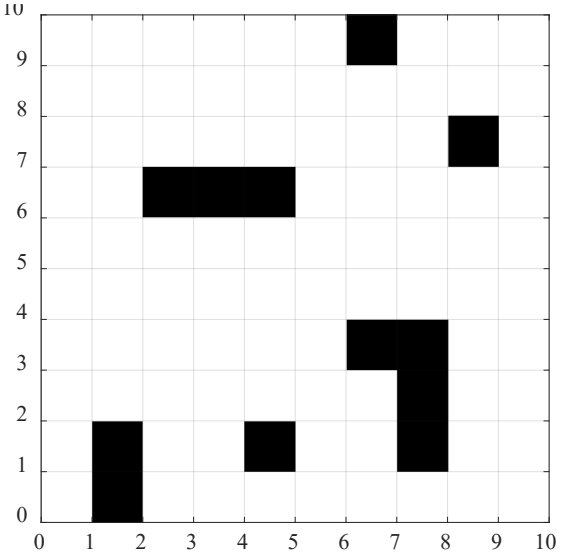


图 2.2 栅格地图

Figure 2.2 Grid map

对于 M 中的每一个栅格，定义 $P(s=0)$ 为空闲状态栅格 $a_{ij}=0$ 的概率，同理，定义 $P(s=1)$ 为被占据状态栅格 $a_{ij}=1$ 的概率，二者之和为 1。因此，每一个栅格的状态即为：

$$Grid(s)=\frac{P(s=0)}{P(s=1)} \qquad \text{式 (2.9)}$$

式（2.9）中，*Grid*(*s*)为传感器观测值 *z* 未更新之前的栅格状态。当传感器观测值 *z* 更新之后，相应栅格状态 *Grid*(*s*|*z*)更新为：

$$Grid(s\mid z)=\frac{P(s=0\mid z)}{P(s=1\mid z)} \qquad \text{式 (2.10)}$$

根据贝叶斯公式，可知：

$$P(s=0\mid z)=\frac{P(z\mid s=0)P(s=0)}{P(z)} \qquad \text{式 (2.11)}$$

$$P(s=1\mid z)=\frac{P(z\mid s=1)P(s=1)}{P(z)} \qquad \text{式 (2.12)}$$

中国知网 https://www.cnki.net

将式（2.11）、（2.12）代入式（2.10）可以得到：

$$Grid(s|z)=\frac{P(z|s=0)}{P(z|s=1)}\cdot\frac{P(s=0)}{P(s=1)}=\frac{P(z|s=0)}{P(z|s=1)}Grid(s) \quad \text{式 (2.13)}$$

将式（2.13）等式两边同时取对数，可得：

$$\log Grid(s|z)=\log\frac{P(z|s=0)}{P(z|s=1)}+\log Grid(s) \quad \text{式 (2.14)}$$

式（2.14）中，$\log\frac{P(z|s=0)}{P(z|s=1)}$为测量值模型，该模型具有两种状态 L_{free} 与 L_{obs}，对应传感器对每一个栅格的观测结果：空闲状态、占据状态。即：

$$L_{free}=\log\frac{P(z=0|s=0)}{P(z=0|s=1)} \quad \text{式 (2.15)}$$

$$L_{obs}=\log\frac{P(z=1|s=0)}{P(z=1|s=1)} \quad \text{式 (2.16)}$$

若采用 $\log Grid(s)$ 表示栅格 s 的状态 S，式（2.14）可化简为：

$$S^{+}=S^{-}+\log\frac{P(z|s=0)}{P(z|s=1)} \quad \text{式 (2.17)}$$

式（2.17）中，S^{+}、S^{-}分别表示传感器测量值更新之后与之前栅格 s 的状态。由此，每一个栅格的状态更新过程简化为：

$$S^{+}=S^{-}+L_{free} \quad \text{或} \quad S^{+}=S^{-}+L_{obs} \quad \text{式 (2.18)}$$

经过上述过程，即可完成相关栅格地图的建立。同时，应当注意：对于每一个栅格的初始状态 S^{*}，默认其空闲状态与占据状态的概率均为 0.5，即：

$$S^{*}=\log Grid(s)=\log\frac{P(s=0)}{P(s=1)}=\log 1=0 \quad \text{式 (2.19)}$$

2.2.3 八叉树地图

八叉树地图最大特点在于能够随时进行压缩、更新，具备极高的灵活性。八叉树地图通过八叉树结构的数据形式来存储各栅格的占据概率，从而对空间环境进行描述，如图 2.3 所示。

八叉树结构通过对三维空间的几何实体进行体元剖分，从而形成一个具有根节点的方向图。如图 2.3 所示，通过根节点，树根向第一层进行扩展，扩展出八个节点，形成第一层。随后，第一层中各节点再向第二层进行扩展，同样扩展出八个节点，形成第二层。如此不断重复，直至扩展至叶子层。

中国知网 https://www.cnki.net

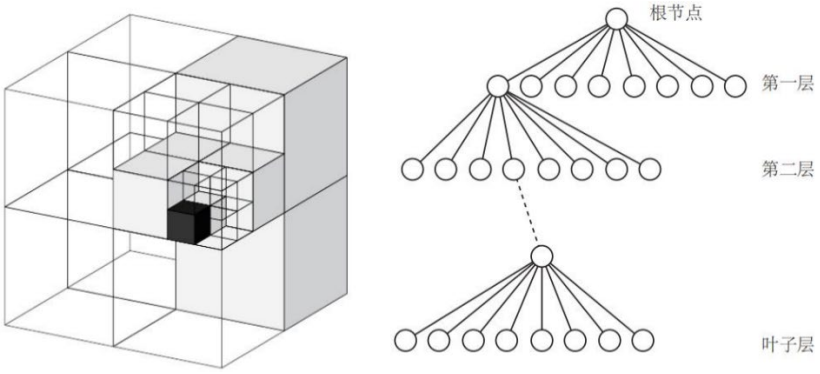


图 2.3 八叉树地图

Figure 2.3 Octomap

若对叶子层每个节点分配一个对应的栅格占据概率，则其对应的父节点的栅格占据概率为该父节点下所有子节点概率之和。对于已经确定被完全占据的节点，其栅格占据概率为1，相反，对于已经确定未被占据的节点，其栅格占据概率为0。对于一个叶子节点 n，在 1，2，…，t 的不同时刻，其观测数据分别为 z_1，z_2，…，z_t，则该叶子节点概率为：

$$P(n \mid z_{1:t}) = \left[1 + \frac{1-P(n \mid z_t)}{P(n \mid z_t)} \frac{1-P(n \mid z_{1:t-1})}{P(n \mid z_{1:t-1})} \frac{P(n)}{1-P(n)} \right]^{-1} \quad \text{式 (2.20)}$$

式（2.20）中，$P(n)$的先验概率为 0.5，由对数变换有：

$$\log\ it(p) = \ln(\frac{p}{1-p}) \quad \text{式 (2.21)}$$

$$\begin{aligned} \ln \frac{P(n \mid z_{1:t})}{1-P(n \mid z_{1:t})} &= -\ln \left[\frac{1-P(n \mid z_t)}{P(n \mid z_t)} \frac{1-P(n \mid z_{1:t-1})}{P(n \mid z_{1:t-1})} \frac{P(n)}{1-P(n)} \right] \\ &= \ln \left[\frac{P(n \mid z_{1:t-1})}{1-P(n \mid z_{1:t-1})} \right] + \ln \left[\frac{P(n \mid z_t)}{1-P(n \mid z_t)} \right] \end{aligned} \quad \text{式 (2.22)}$$

令

$$L(n \mid z_t) = \ln \left[\frac{P(n \mid z_t)}{1-P(n \mid z_t)} \right] \quad \text{式 (2.23)}$$

则式（2.22）改写为

$$L(n \mid z_{1:t}) = L(n \mid z_{1:t-1}) + L(n \mid z_t) \quad \text{式 (2.24)}$$

由式（2.24）可知，三维环境空间中任意一点，新的观测值可直接与原观测值相加，且各父节点栅格占据概率即对应子节点栅格占据概率之和。基于传感器所获得的观测数据，对八叉树地图中各对应节点进行实时更新，计算各节点的栅格占据概率，即可完成八叉树地图的整体构建。

中国知网 https://www.cnki.net

2.2.4 数字高程模型

对于简单环境，二值化的栅格地图模型常作为各路径规划算法的标准地图模型。但在一些具有起伏地形非平坦环境下，二维栅格地图描述环境特征有限，无法准确反映环境地形起伏变化，因此常用 DEM（Digital Elevation Model，数字高程模型）作为三维环境下进行路径规划的标准地图模型，如图 2.4 所示。DEM 通过离散点的方式，记录环境内各地形区域的高程值，从而表征环境地图特征。

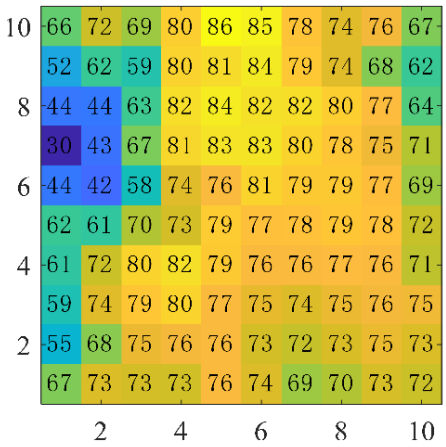


图 2.4 DEM 地图

Figure 2.4 Digital elevation map

DEM 模型描述如下：给定一个平面区域 D，其边界条件为∂D，在边界条件下将该区域依照栅格粒度δ划分为$m\times n$个网格，每个网格单元包含一个高程值H_{ij}，表示该位置的高度或深度，则该平面区域上的 DEM 可表示为一个函数$M:D\to\mathbb{R}$，满足：

$$M(x,y)=H_{ij} \tag{2.25}$$

式（2.25）中，(x,y)表示该网格单元的位置坐标，H_{ij}表示该位置坐标的高程值。以图 2.4 所示的10×10的 DEM 地图为例，坐标$(3,6)$处的高程值为 58，表示该单位栅格粒度内地形距离水平面高度为 58m。

以三维激光雷达建立 DEM 地图为例[77]，若激光雷达所采集的数据为$\{\boldsymbol{p}_1,\boldsymbol{p}_2,\cdots,\boldsymbol{p}_n\}$，$\boldsymbol{p}_i$为一个激光点数据的三维空间坐标，该组数据对应的协方差矩阵为$\{\sigma_1,\sigma_2,\cdots,\sigma_n\}$，$\sigma_i$为一个激光点数据的协方差矩阵，该矩阵由下式计算得到：

$$\sigma=\frac{1}{2}\begin{bmatrix} 2\Delta^{+}\cos^2\theta\cos^2\varphi & \Delta^{-}\sin 2\theta\cos\varphi & -\sin 2\varphi\left(\sigma_\rho^2-\Delta^{-}\sin^2\theta\right) \\ +2\sigma_\varphi^2A^2 & & +2\sigma_\varphi^2AB \\ \Delta^{-}\sin 2\theta\cos\varphi & 2\left(\sigma_\rho^2-\Delta^{-}\cos^2\theta\right) & \Delta^{-}\sin 2\theta\sin\varphi \\ -\sin 2\varphi\left(\sigma_p^2-\Delta^{-}\sin^2\theta\right) & \Delta^{-}\sin 2\theta\sin\varphi & 2\sin^2\varphi\left(\sigma_\rho^2-\Delta^{-}\sin^2\theta\right) \\ +2\sigma_\varphi^2AB & & +2\sigma_\varphi^2B^2 \end{bmatrix} \tag{2.26}$$

式（2.26）中，ρ为激光点到激光雷达光心的距离值，θ为激光雷达的扫描角度，φ为激

中国知网 https://www.cnki.net

光仰角；三者相互独立，且服从高斯白噪声分布，对应的均方差分别为 σ_ρ，σ_θ，σ_φ；∇ 为 $\boldsymbol{p}_c$ 对 $\boldsymbol{p}_p$ 的雅可比矩阵，σ_p 为 $\boldsymbol{p}_p$ 的误差协方差矩阵：

$$\boldsymbol{p}_c = [x, y, z]^{\mathrm{T}} \tag{2.27}$$

$$\boldsymbol{p}_p = [\rho, \theta, \varphi] \tag{2.28}$$

$$\Delta^{\pm} = \sigma_p^2 \mp \sigma_\theta^2 \rho^2 \tag{2.29}$$

$$A = -\rho\cos\theta\sin\varphi + b\cos\varphi - c\sin\varphi \tag{2.30}$$

$$B = -\rho\cos\theta\cos\varphi - b\cos\varphi - c\cos\varphi \tag{2.31}$$

对于平面区域 D 中的每个栅格单元 $M(i,j)$，其对应激光点的分布函数近似为正态分布：

$$P_i(x,y) \approx \mathrm{N}(\boldsymbol{p}_i^{xy}, \sigma_i^{xy}) \tag{2.32}$$

式（2.32）中，$\boldsymbol{p}_i^{xy}$ 为激光点 x、y 坐标，σ_i^{xy} 为激光点 x、y 的协方差矩阵。

假设激光点 $\boldsymbol{p}_i$ 为栅格单元 $M(i,j)$ 的第 k 个点，则激光点 $\boldsymbol{p}_i$ 对栅格单元 $M(i,j)$ 的作用因子为：

$$\begin{aligned}\mu_i &= \int_{X^-}^{X^+}\int_{Y^-}^{Y^+} P_i(x,y)dXdY \approx \int_{X^-}^{X^+}\int_{Y^-}^{Y^+} \mathrm{N}\left(\boldsymbol{p}_i^{xy}, \sigma_i^{xy}\right)dXdY \\ &\approx \left(X^+ - X^-\right)\left(Y^+ - Y^-\right)\mathrm{N}\left(\boldsymbol{p}_i^{xy}, \sigma_i^{xy}\right)\end{aligned} \tag{2.33}$$

式（2.33）中，X^+、X^-、Y^+、Y^- 为栅格范围常量，故计算时取 $\mu_i \propto \mathrm{N}(\boldsymbol{p}_i^{xy}, \sigma_i^{xy})$，同时，对栅格单元 $M(i,j)$ 中所有 μ 进行归一化，该栅格中所有激光点高度的加权平均值即为该栅格单元的高程值：

$$H_{ij} = \frac{1}{S_\mu}\sum_{i=1}^{k}\mu_i z_i \tag{2.34}$$

式（2.34）中，S_μ 为栅格单元 $M(i,j)$ 中所有激光点的作用因子之和。

2.3 路径规划算法

2.3.1 Dijkstra 算法

1956 年，荷兰计算机科学家 E.W.Dijkstra 提出了以其本人名字命名的 Dijkstra 算法。作为一种典型的广度优先搜索路径规划算法，Dijkstra 算法使用带权有向图的思想来求解机器人最短路径规划问题。Dijkstra 算法在规划时以路径起始点为中心，依次向外扩展，直至扩展到路径目标点为止，基于路径节点与权值边的关系建立整个路径网络图。

Dijkstra 算法基本思想为：首先定义路径起始点 S，该点即为路径顶点。然后定义两个

中国知网 https://www.cnki.net

基本列表 Q 与 R，其中，列表 Q 存储已计算完毕最短路径的顶点以及该顶点所对应的最短路径长度，列表 R 则存储还未计算完成的最短路径的顶点以及该顶点到路径起始点 S 的距离长度。初始时刻，Q 列表中只存储路径起始点 S，R 列表中则存储除路径起始点 S 以外的所有顶点，且 R 列表中的顶点的路径为路径起始点 S 到该顶点的路径；随后，从 R 列表中找出路径最短的顶点，并将其加入至 Q 列表中；然后，对 R 列表中的顶点以及相应顶点对应的路径进行更新，并找出 R 列表中路径最短的顶点，并将其加入至 Q 列表中；最后，更新 R 列表中所有顶点及顶点对应的路径。重复上述操作，直至对所有顶点完成遍历。

Dijkstra 算法路径规划的详细步骤如下：

步骤 1：初始化

创建一个空的已访问列表 Q，用于存储已经找到最短路径的节点。

创建一个空的距离列表 R，用于存储每个节点到起始节点的距离。起始节点 S 的距离设置为 0，其他节点的距离设置为无穷大。

创建一个空的父节点列表 P，用于存储每个节点的前驱节点。初始情况下，所有节点的前驱节点为空。

步骤 2：选择起始节点

选择起始节点 S，并将其加入已访问列表 Q 中。

步骤 3：更新距离和父节点

遍历起始节点 S 的邻域节点，并更新它们到起始节点 S 的距离。

如果通过当前节点到达邻域节点的距离比已记录的距离要短，则更新邻域节点的距离，并将当前节点设置为邻域节点的父节点。

步骤 4：选择下一个节点

从未访问过的节点中选择距离起始节点最近的节点作为下一个节点，并将其加入已访问列表 Q 中。

步骤 5：重复步骤 3 和步骤 4

重复执行步骤 3 和步骤 4，直到所有节点都被访问过或者没有可用节点。

步骤 6：生成最短路径

从目标节点开始，沿着每个节点的父节点回溯，直到回到路径起始节点 s。如此，便能得到从路径起始点 S 到路径目标点 G 的最短路径。

不同扩展策略 Dijkstra 算法路径规划结果图如图 2.5 所示。

Dijkstra 算法具有以下优点：

(1) 可以找到单源最短路径问题的最优解：Dijkstra 算法可以确保找到从起始节点到目标节点的最短路径，即使图中存在负权边。

(2) 算法简单易懂：Dijkstra 算法的基本思想简单明了，易于理解和实现。

(3) 适用范围广泛：Dijkstra 算法适用于有向图或无向图，并且可以处理带有非负权重的边的情况。

中国知网 https://www.cnki.net

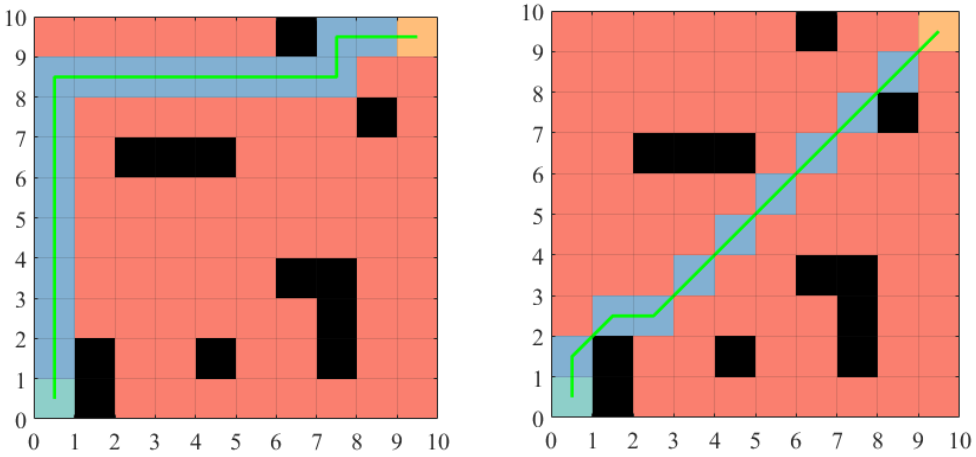


图 2.5 不同扩展策略 Dijkstra 算法路径规划结果

Figure 2.5 Path planning results of Dijkstra's algorithm with different expansion strategies

但同时，Dijkstra 算法也存在以下缺点：

(1) 时间复杂度高：Dijkstra 算法在每次迭代中需要选择具有最小距离的节点，并更新与该节点相邻的节点的距离。在稠密图中，Dijkstra 算法的时间复杂度为 $O(V^2)$。而在稀疏图中，Dijkstra 算法时间复杂度最小为 $O((V+E)\log V)$，过高的时间复杂度制约着算法的效率。

(2) 对负权边的处理困难：由于 Dijkstra 算法假设所有边的权重均为非负值，因此算法不能正确处理带有负权边的图，若图中存在负权边，则可能导致算法得出错误的最短路径。

(3) 只能处理单源最短路径问题：Dijkstra 算法只能计算从单个起始节点到其他所有节点的最短路径，无法应用于多源最短径问题。

2.3.2 Best First Search 算法

Best First Search 路径规划算法是一种启发式搜索算法，也被称为最佳优先搜索算法。与 Dijkstra 算法不同的是，最佳优先搜索算法不是从起始点开始扩展，而是选择具有最小代价的节点进行扩展，并在扩展过程中使用一个估价函数来评估每个节点到目标的距离。这个估价函数可以是启发式函数或者直接测量两个节点之间的距离。

最佳优先搜索算法的基本思想是：首先定义路径起始点 S 和路径目标点 G，然后定义一个基本列表 Q，其中，列表 Q 存储待处理的节点。初始时刻，Q 列表中只存储路径起始点 S；随后，从 Q 列表中找出具有最小代价的节点，并将其加入至已访问节点列表 R 中；然后，对该节点的邻域节点进行扩展，并使用估价函数来确定每个邻域节点到目标点的距离，并将它们加入 Q 列表中；重复上述操作，直至找到目标点 G 或者 Q 列表为空。

最佳优先搜索算法的详细步骤如下：

步骤 1：初始化

创建一个空的已访问节点列表 R，用于存储已经找到最短路径的节点。

创建一个包含路径起始点 S 的待处理列表 Q。

步骤 2：选择下一个节点

从待处理列表 Q 中选择具有最小代价的节点作为下一个节点，并将其加入已访问节点

中国知网 https://www.cnki.net

列表 R 中。

步骤 3：扩展邻域节点

遍历当前节点的邻域节点，并使用估价函数来确定每个邻域节点到路径目标点 G 的距离。

将邻域节点按照估价函数的值从小到大排序，并加入待处理列表 Q 中。

步骤 4：重复步骤 2 和步骤 3

重复执行步骤 2 和步骤 3，直到找到路径目标点 G 或者待处理列表 Q 为空。

步骤 5：生成最短路径

从目标节点开始，沿着每个节点的父节点回溯，直到回到起始节点。从而得到从路径起始点 S 到路径目标点 G 的最短路径。

不同扩展策略最佳优先搜索算法路径规划结果如图 2.6 所示：

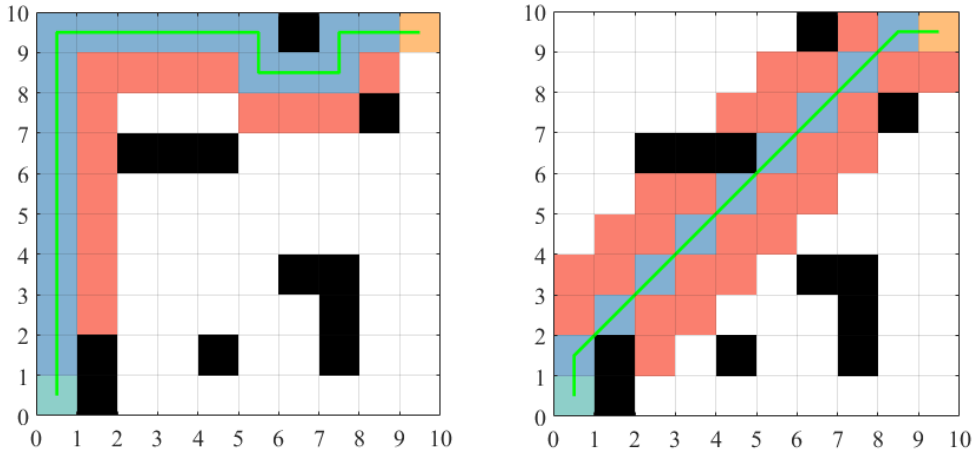


图 2.6 不同扩展策略最佳优先搜索算法路径规划结果

Figure 2.6 Path planning results of BFS's algorithm with different expansion strategies

最佳优先搜索算法具有以下优点：

(1) 与 Dijkstra 算法相比，由于最佳优先搜索算法只扩展具有最小代价的节点，而非扩展所有节点，因此最佳优先搜索算法可以较之更快地规划出最短路径。

(2) 最佳优先搜索算法可以使用任何代价函数来评估每个节点到目标的距离，因此算法具有较高的灵活性。

(3) 最佳优先搜索算法可以在不完全探索整个搜索空间的情况下即时返回最佳路径，并在局部路径规划问题中使用。

与此同时，最佳优先搜索算法也存在一些缺点：

(1) 由于算法只考虑每次扩展的具有最小代价的节点，最佳优先搜索算法可能陷入局部最优解。

(2) 由于算法只关注代价最小的节点，最佳优先搜索算法可能会忽略某些节点，并会导致在节点密集的区域出现搜索偏差。

(3) 最佳优先搜索算法没有任何措施来防止搜索空间中的循环，因此可能会导致算法陷

中国知网 https://www.cnki.net

入死循环，无法规划出路径。

2.3.3 A*算法

A*算法是一种典型的启发式路径规划搜索算法，于 1968 年由 Nilsson 提出，用于解决图中两点之间的最短路径问题。与 Dijkstra 算法及最佳优先搜索算法相比，由于 A*算法引入了代价函数，能够更加智能地搜索最短路径，并充分考虑路径代价，在追求路径规划效率的同时保证路径最优性。

A*算法的基本思想为：通过综合考虑当前节点到目标节点的估计距离和已经走过的路径长度，选择下一个节点进行扩展。在每一次扩展时，根据启发式函数的评估值选择最有可能接近目标的节点。这样可以减少搜索空间，从而更快地规划出最短路径。因此，代价函数的设计是 A*算法的关键之一。

A*算法通过所定义的代价函数来引导完成路径的搜索规划，其代价函数可表示为：

$$f(n)=g(n)+h(n) \qquad \text{式 (2.35)}$$

式（2.35）中：n 为当前节点，$f(n)$ 为当前节点 n 的代价函数，$g(n)$ 为路径起始点 S 至当前节点 n 的实际代价，$h(n)$ 为代价函数，表示当前节点 n 至路径目标点 G 的预估代价。

一般来说，A*算法代价函数需要满足以下几个条件：

(1) 非负性：代价函数必须是一个非负函数，即对于任意节点 n，$h(n)\geq 0$。

(2) 准确性：代价函数应当尽量准确地估计节点 n 到路径目标点 G 的距离。

(3) 高效性：代价函数的计算时间应当尽量短。

常用的代价函数有以下几种：

曼哈顿距离（Manhattan Distance）：两点之间横向和纵向的距离之和。适用于在网格地图上进行路径规划。

$$h(n)=\left|x_n-x_g\right|+\left|y_n-y_g\right| \qquad \text{式 (2.36)}$$

欧几里得距离（Euclidean Distance）：两点之间的直线距离。适用于在连续空间中进行路径规划。

$$h(n)=\sqrt{(x_n-x_g)^2+(y_n-y_g)^2} \qquad \text{式 (2.37)}$$

切比雪夫距离（Chebyshev Distance）：两点之间横向和纵向坐标差值的最大值。适用于在网格地图上进行路径规划，且适应斜向规划。

$$h(n)=\max\left(\left|x_n-x_g\right|,\left|y_n-y_g\right|\right) \qquad \text{式 (2.38)}$$

式（2.36）至（2.38）中：(x_n,y_n) 为当前节点 n 的坐标，(x_g,y_g) 为路径目标点 G 的坐标。

中国知网 https://www.cnki.net

代价函数 $h(n)$ 的选择对 A*算法的搜索行为起着至关重要的作用。代价函数 $f(n)$ 构建完成后，导入环境地图模型，确定起始点 S 与目标点 G 后便可开始路径搜索。

A*算法路径规划的具体实现步骤如下：

步骤 1：初始化

创建一个空的开放列表 Open List，用于存储待扩展的节点。

创建一个空的关闭列表 Closed List，用于存储已经扩展过的节点。

将路径起始点 S 加入开放列表 Open List 中，并设置路径起始点 S 的代价值为 0。

步骤 2：选择下一个节点

从开放列表 Open List 中选择代价值最小的节点作为当前节点，并将其加入关闭列表 Closed List 中。

步骤 3：判断路径目标点 G

如果当前节点为路径目标点 G，则搜索结束，生成最短路径。

步骤 4：扩展邻域节点

遍历当前节点的邻域节点，并计算它们的代价值。

如果邻域节点不在开放列表 Open List 中，则将其加入开放列表 Open List，并设置其代价值和父节点。

如果邻域节点已经在开放列表 Open List 中，比较当前路径长度与已记录的路径长度，选择较短的路径更新代价值和父节点。

步骤 5：重复步骤 2 至步骤 4

重复执行步骤 2 至步骤 4，直到找到路径目标点 G 或者开放列表 Open List 为空，表示无法到达路径目标点 G。

步骤 6：生成最短路径

从路径目标点 G 开始，沿着每个节点的父节点回溯，直到回到路径起始点 S，得到从路径起始点 S 到路径目标点 G 的最短路径。

不同规划策略的 A*算法路径规划结果如图 2.7 所示。

相对于 Dijkstra 算法与 Best First Search 算法而言，A*算法具有以下优点：

(1) 最优性：A*算法能够保证找到最短路径，即找到一条代价最小的路径。由于 A*算法综合考虑了节点的预估代价与实际代价，因此在选择下一个节点进行扩展时，能够有效地减少搜索空间。

(2) 完备性：由于 A*算法会遍历所有可能的路径直到找到最优解或者确定无解，则若地图中至少存在一条连接起点和终点的路径，A*算法必然能够规划出一条可行路径。

(3) 启发式引导：通过引入代价函数，使 A*算法具有目标导向地进行搜索，更有利于朝着目标节点前进，从而减少不必要的搜索开销，提高搜索效率。

(4) 灵活性：A*算法的代价函数可以根据具体问题进行设计和调整，以适应不同的搜索环境和场景。这使得 A*算法在各种应用领域都有广泛的适用性。

中国知网 https://www.cnki.net

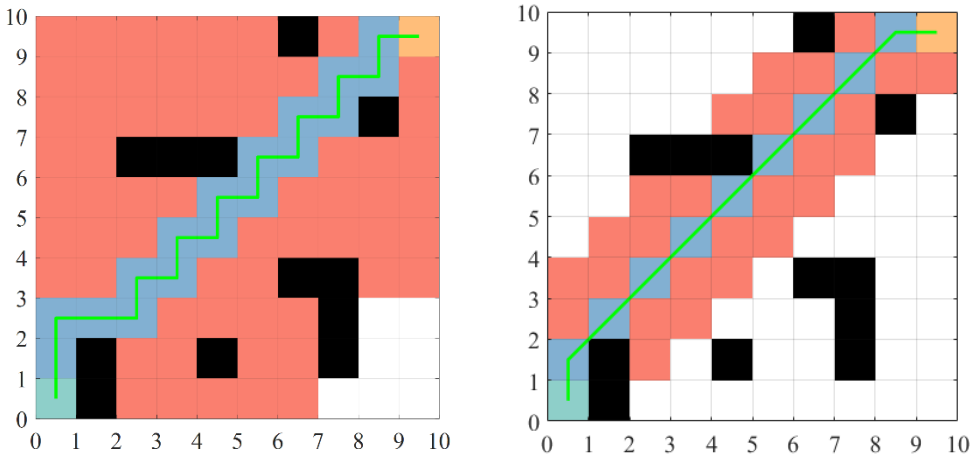


图 2.7 不同扩展策略 A*算法路径规划结果

Figure 2.7 Path planning results of A* algorithm with different expansion strategies

与此同时，A*算法也存在如下缺点：

(1) 代价函数选取困难：A*算法的性能和搜索效率很大程度上依赖于代价函数的选择和设计。如果代价函数不准确或者不合理，可能会导致搜索结果不够优化，甚至无法找到最优解。

(2) 内存消耗大：A*算法需要维护开放列表和关闭列表，以及节点间的关系信息。在处理大规模问题时，需要消耗较多的内存资源。

(3) 时间复杂度大：A*算法的时间复杂度与搜索空间的大小紧密相关。如果搜索空间很大，A*算法可能会消耗较长的搜索时间。

(4) 算法具有偏向性：A*算法在选择下一个节点进行扩展时，更倾向于朝着目标节点前进，从而忽略了对其他方向的探索。

2.3.4 PRM 算法

PRM（Probabilistic Road Map，概率路图）算法是由 Lydia Kavraki 与 Jean-Claude Latomde 提出的一种基于图搜索算法。PRM 算法的基本思想是通过随机采样创建一个节点集合，并利用这些节点构建一个图表示环境。然后，通过连接节点之间的有效路径，形成一个带权有向图。最后，使用 Dijkstra 或 A*等最短路径搜索算法，在图上搜索从起始节点到目标节点的最短路径。

PRM 算法的详细步骤如图 2.8 所示。

步骤 1：采样节点

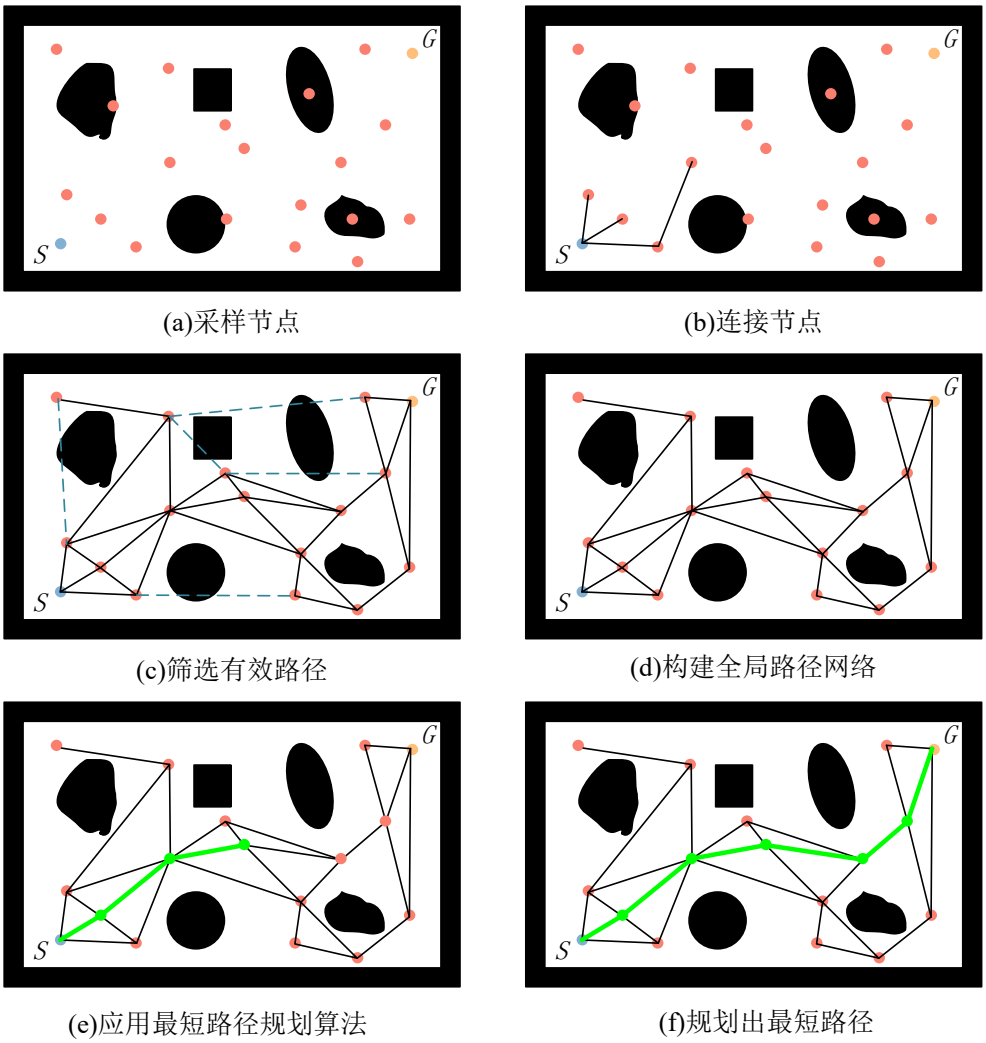
PRM 算法首先需要确定路径规划的搜索空间。根据路径规划问题的约束条件，例如地图边界和障碍物位置，确定出一个合适的搜索空间。然后，在该搜索空间中随机采样一组节点，并将其作为候选节点。

步骤 2：连接节点

对于每个候选节点，判断其是否与周围的节点相连。对于连续空间中的节点，使用距离判断两个节点是否相连；对于离散空间中的节点，则使用可达性分析来判断两个节点是否相

中国知网 https://www.cnki.net

连。如果两个节点之间可以相连，则在它们之间添加一条边，表示二者之间存在一条可行路径，以此形成一个以候选节点为中心的局部路径网络。



(a)采样节点　(b)连接节点

(c)筛选有效路径　(d)构建全局路径网络

(e)应用最短路径规划算法　(f)规划出最短路径

图 2.8 PRM 算法路径规划步骤

Figure 2.8 PRM algorithm path planning steps

步骤 3：筛选有效路径

连接节点后，对路径进行筛选，去除不符合约束条件或无效的路径。例如，可以排除与障碍物相交的路径、超出机器人运动能力范围的路径，以及其他不符合特定约束条件的路径。此步骤可以减少搜索空间，并提高后续路径搜索的效率。

步骤 4：构建全局路径网络

在筛选得到的有效路径中，将所有路径网络合并成一个全局路径网络，即得到了表示整个路径空间的图结构。图中的节点表示路径上的关键点，边表示路径的连接关系。基于该全局路径网络，从而更加全面地描述路径规划问题，并为后续的路径搜索算法提供搜索基础。

步骤 5：应用最短路径算法

在全局路径网络上应用最短路径算法，例如 Dijkstra 算法或 A*算法，搜索出起始节点

中国知网 https://www.cnki.net

和目标节点之间的最短路径。最短路径算法通过考虑节点之间的距离、边的权重以及其他约束条件，从而确定最短路径。

步骤 6：生成最短路径

在获得最短路径后，通过节点回溯的方式生成完整的路径。从目标节点开始，沿着每个节点的前驱节点回溯，直到回到起始节点，得到了从起始节点到目标节点的最短路径。

不同采样数下 PRM 算法路径规划结果如图 2.9 所示：

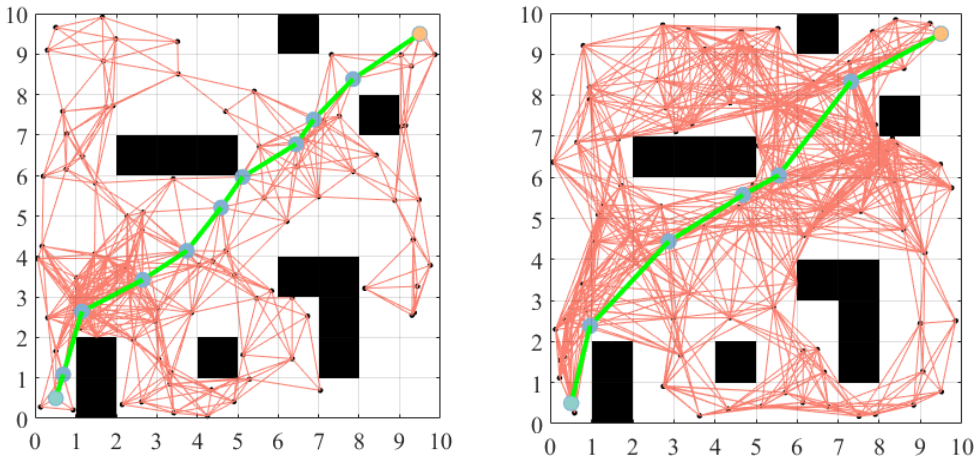


图 2.9 不同采样数下 PRM 算法路径规划结果

Figure 2.9 Path planning results of PRM algorithm with different number of samples

总体而言，PRM 算法具有以下优缺点：

优点：

(1) 应用范围广：PRM 算法适用于多种环境和问题领域，包括离散和连续空间中的路径规划。PRM 算法能够处理高维、复杂的环境，并应用于非凸障碍物和多目标路径规划。

(2) 高效性：PRM 算法在预处理阶段通过采样和连接节点的方式构建全局路径网络。因此，在实际路径规划时，只需在离线完成的全局路径网络上应用最短路径算法就能完成规划任务，从而避免了实时搜索整个路径空间的开销，提高了路径搜索的效率。

(3) 简化问题：PRM 算法通过筛选有效路径和构建全局路径网络的步骤，可以减少搜索空间并排除无效路径，从而简化了路径规划问题。这一步骤也使得后续的最短路径搜索更加高效，并同时降低了路径规划问题的复杂性。

(4) 可扩展性：PRM 算法的精度和效率可以通过增加采样点数量来调节。在需要更精确路径规划结果时，可以增加采样点的数量，以获得更好的路径规划结果。这种可扩展性使得 PRM 算法能够适应不同应用场景的需求。

缺点：

(1) 预处理开销大：PRM 算法的预处理阶段需要随机采样大量节点，并进行连接和筛选，以构建全局路径网络。这一步骤涉及大量的计算和内存开销，尤其是在复杂环境和高维空间中，预处理的时间和空间复杂度都较高。

(2) 实时性不足：PRM 算法的预处理阶段是离线完成的，即构建全局路径网络的过程在

中国知网 https://www.cnki.net

实时路径规划时并不参与。这意味着在实际应用中，如果环境发生变化，例如障碍物的位置或数量发生变化，就需要重新进行预处理，从而导致算法实时性降低。

(3) 无法有效应对动态环境：PRM 算法在构建全局路径网络时并未考虑环境的动态变化，因此对于动态环境下的路径规划较为困难。如果环境存在频繁变化的障碍物或者其他移动物体，PRM 算法无法有效地处理这些变化。

(4) 边界效应：PRM 算法对于边界上的路径规划存在一定的困难。由于边界上的节点无法与外部空间的节点相连，可能导致路径规划结果不准确或者无法找到合适的路径。

(5) 不保证最优性：PRM 算法能够找到起点到终点的路径，但并不能保证是最短路径。由于采样节点和连接方式的随机性，可能存在次优解。

(6) 结果随机性：由于 PRM 算法在初始阶段采用随机采样的策略，因此将会导致每一次在同一地图环境中会规划出不同的路径，规划结果具有随机性以及不确定性，无法应用于对路径规划结果要求一致的场景。

2.3.5 RRT 算法

RRT（Rapidly-exploring Random Tree，快速扩展随机树）路径规划算法是一种基于树形结构的快速搜索算法，它主要用于解决机器人路径规划问题。RRT 算法的基本思想是以机器人当前位置为根节点，随机生成一些采样点，并利用这些采样点逐步扩展出一颗树形结构。在扩展的过程中，RRT 算法通过避开障碍物和优化路径的方式，逐渐探索出一条从起点到终点的最优路径。

具体来说，RRT 算法主要分为两个阶段：生长阶段和连接阶段。在生长阶段，RRT 算法随机采样点，并将其加入到树形结构中。为了避免障碍物，RRT 算法会根据机器人的运动学模型，在采样点附近搜索一个可行的节点，并将其作为新的树的子节点。在连接阶段，RRT 算法会连接两个相邻的树节点，并检查该连接路径是否合法。如果路径无法通过障碍物，RRT 算法会在该路径上插入新的节点，直至路径可行为止。

RRT 算法的详细步骤如图 2.10 所示：

步骤 1：初始化

创建一个树 *Tree*，将机器人的起始位置作为树的根节点。将路径起始点添加到已访问节点集合 *V*。

步骤 2：生成随机点

生成一个随机采样点 q_{rand}，该采样点应该包含机器人运动空间的全部范围。

步骤 3：寻找最近邻节点

在树 *Tree* 中查找离采样点 q_{rand} 最近的节点 q_{near}。

步骤 4：路径可行性判断

判断是否可以从节点 q_{near} 直接到达采样点 q_{rand}，即判断路径上是否有障碍物。如果是，则返回执行步骤 2，否则，执行步骤 5。

中国知网 https://www.cnki.net

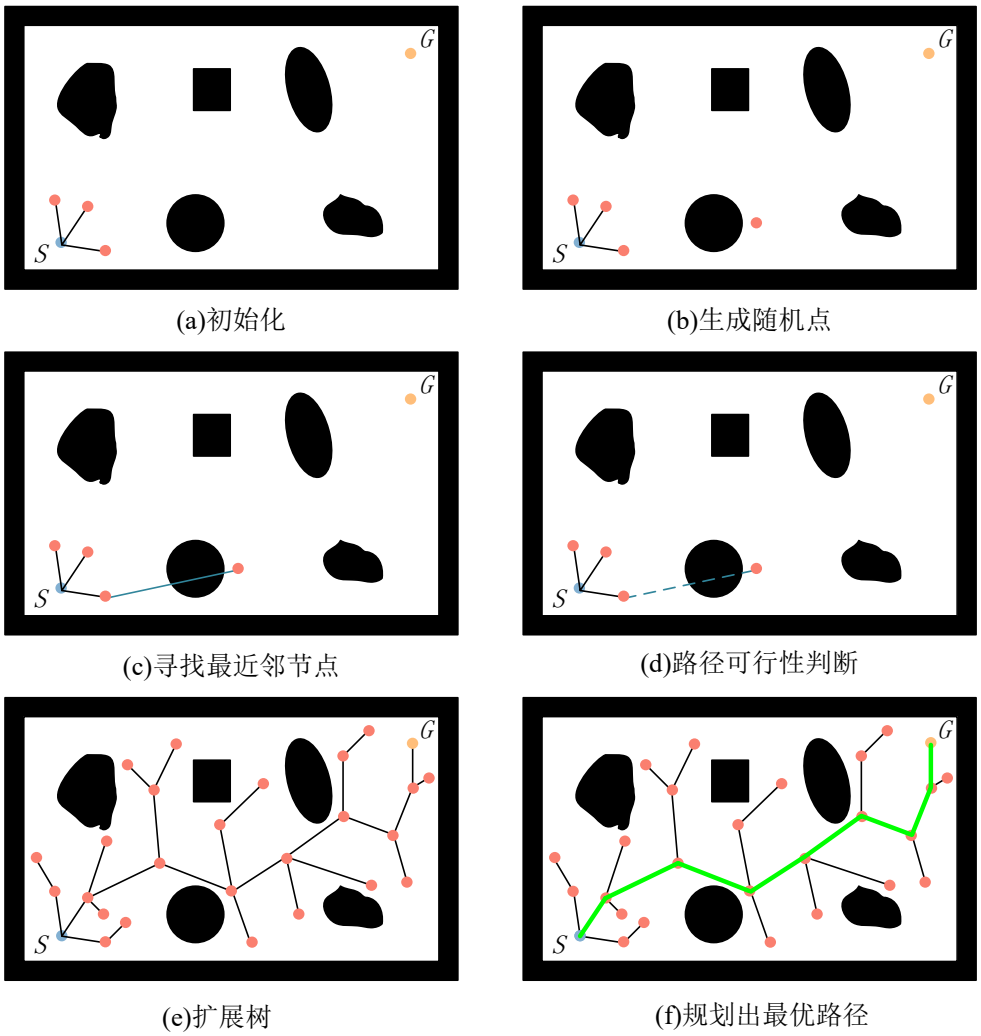


图 2.10 RRT 算法路径规划步骤

Figure 2.10 RRT algorithm path planning steps

步骤 5：扩展树 *Tree*

计算从节点 q_{near} 到采样点 q_{rand} 的连接路径，并将路径上的每个点都添加为新的节点 q_{new} 到树 *Tree* 中。

步骤 6：路径目标点判断

如果新节点 q_{new} 与路径目标节点相邻，则表示找到了一条可行路径，将新节点 q_{new} 添加到已访问节点集合 V，并执行步骤 7，否则，返回执行步骤 2。

步骤 7：根据树 *Tree* 中返回最优路径

从目标节点开始，沿着父节点指针一直回溯到起始节点，得到最优路径。

不同步长下 RRT 算法路径规划结果如图 2.11 所示：

相较于其他路径规划算法，RRT 算法具有以下优点：

(1) 高效性：RRT 算法能够快速构建一个树形结构，拥有较高的搜索效率，其随机采样和快速扩展的策略使得算法能够在较短的时间内找到可行解。

(2) 鲁棒性：RRT 算法对于非凸、高维度以及复杂的环境具有较好的适应性，能够处理

中国知网 https://www.cnki.net

复杂的障碍物布局，不易受到环境变化的影响。

(3) 易于实现：RRT 算法的思路简单直观，易于理解和实现。

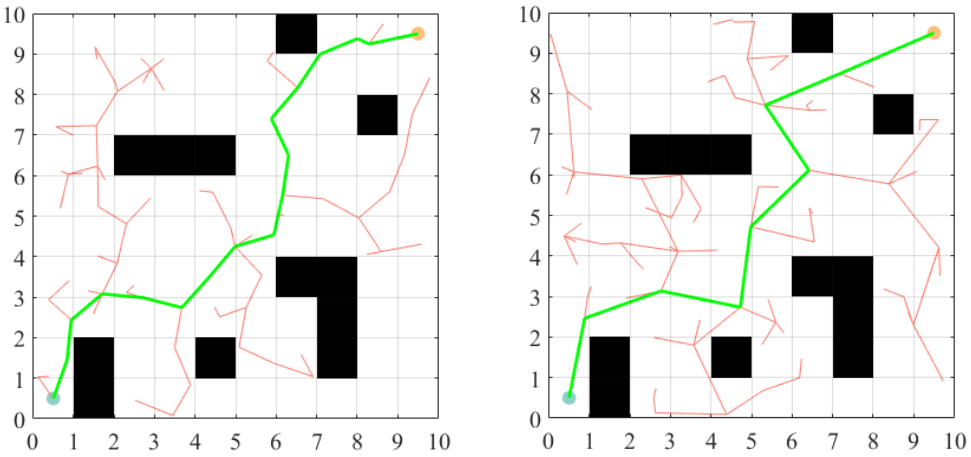


图 2.11 不同步长下 RRT 算法路径规划结果

Figure 2.11 Path planning results of RRT algorithm with different step sizes

与此同时，RRT 算法也具有以下缺点：

(1) 存在局部最优解：由于 RRT 算法的随机性，算法无法提供全局优化的保证，因此 RRT 算法在搜索空间较大的情况下，可能会陷入局部最优解而无法找到全局最优解。

(2) 路径质量不高：因 RRT 算法更注重探索整个搜索空间，而非追求最短路径，因此，RRT 算法生成的路径通常并不是最短路径。对于高精度路径规划的场景下，需要对 RRT 算法生成的路径进一步优化。

(3) 对采样密度敏感：RRT 算法对于采样密度的选择较为敏感。如果采样密度过低，可能会导致搜索效率降低；而采样密度过高，则会增加计算开销。因此，需要根据具体场景进行合理的采样密度选择。

2.3.6 人工势场法

人工势场法（Artifical Potential Field，APF）于 1986 年由 Khatib 提出[92]。人工势场法是一种物理虚拟力的方法，通过路径目标点与障碍物周围构造出相互作用力的引力场与斥力场，由引力与斥力叠加构建整个势场力，然后通过搜索势函数的梯度下降方向来规划出无碰撞的安全最优路径。由于人工势场法具有高效的实时控制性，可以实现平滑轨迹处理与实时路径规划，因此被广泛应用于机器人、无人驾驶等路径规划场景。

人工势场法的基本思想如图 2.12 所示：假设移动机器人处于虚拟势场中，并受到虚拟力的作用，其中各种障碍物对机器人产生斥力 F_{rep}，路径目标点 G 对机器人产生引力 F_{att}，两种虚拟力形成合力 F，该合力决定机器人的运动方向，引导机器人朝目标点运动并远离障碍物。

通常情况下，人工势场法所建立的势场为二维势场 (x,y)，忽略机器人运动方向 θ，并假定一个可微的势场函数 $U(q)$，对于势场中某一位置 $q=(x,y)$，其势场力为：

中国知网 https://www.cnki.net

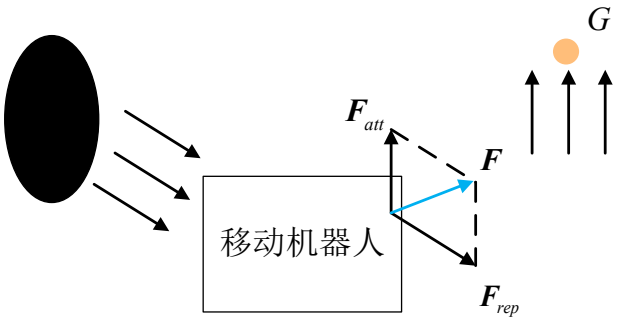


图 2.12 人工势场法机器人受力模型

Figure 2.12 Robot Force Modelling by Artificial Potential Field Method

$$F(q) = -\nabla U(q) \qquad \text{式 (2.39)}$$

式（2.39）中，$\nabla U(q)$ 为位置 q 处 U 的梯度向量：

$$\nabla U(q) = \begin{bmatrix} \dfrac{\partial U}{\partial x} \\ \dfrac{\partial U}{\partial y} \end{bmatrix} \qquad \text{式 (2.40)}$$

对于整个势场，定义为障碍物的斥力场与路径目标点的引力场之和：

$$U(q) = U_{att}(q) + U_{rep}(q) \qquad \text{式 (2.41)}$$

基于此，势场合力 F 即为引力 F_{att} 与斥力 F_{rep} 之和：

$$F(q) = F_{att}(q) - F_{rep}(q) = -\nabla U_{att}(q) + \nabla U_{rep}(q) \qquad \text{式 (2.42)}$$

对于势场中的吸引势位，将其定义为抛物线函数：

$$U_{att}(q) = \frac{1}{2} K_{att} \rho_G^2(q) \qquad \text{式 (2.43)}$$

式（2.43）中，K_{att} 为引力比例系数，$\rho_G(q)$ 为 Euclidean 距离 $\|q - q_G\|$。

由于吸引势位是可微的，因此引力 F_{att} 为：

$$F_{att}(q) = -\nabla U_{att}(q) = -K_{att} \rho_G(q) \nabla \rho_G(q) = -K_{att}(q - q_G) \qquad \text{式 (2.44)}$$

当机器人接近路径目标点 G 时，引力 F_{att} 将线性收敛至 0。

而对于排斥势位，该势位应当产生离开所有障碍物的斥力 F_{rep}，当机器人越靠近障碍物，排斥势位越强；当机器人越远离障碍物，排斥势位越弱，并在一定阈值外，该排斥势位不再对机器人产生斥力 F_{rep}。通常，将其定义为：

中国知网 https://www.cnki.net

$$U_{rep}(q)=\begin{cases}\frac{1}{2}K_{rep}\left[\frac{1}{\rho(q)}-\frac{1}{\rho_0}\right]^2, & \rho(q)\le\rho_0\\ 0, & \rho(q)>\rho_0\end{cases} \quad \text{式 (2.45)}$$

式（2.45）中，K_{rep}为斥力比例系数，$\rho(q)$为位置 q 与障碍物的最小距离，ρ_0为障碍物距离阈值。

若障碍物边界是凸的，且分段可微，则$\rho(q)$在自由空间中处处可微，其斥力为：

$$F_{rep}(q)=-\nabla U_{rep}(q)=\begin{cases}K_{rep}\left[\frac{1}{\rho(q)}-\frac{1}{\rho_0}\right]\frac{q-q_{obs}}{\rho^3(q)}, & \rho(q)\le\rho_0\\ 0, & \rho(q)>\rho_0\end{cases} \quad \text{式 (2.46)}$$

至此，势力场建立完成。当引力与斥力作用于移动机器人时，二者合力引导机器人远离障碍物而趋向于路径目标点，通过设置一个正比于场力向量的机器人移动速度向量，可平滑地引导机器人到达路径目标点。

人工势场法路径规划的具体实现步骤如下：

步骤 1：定义目标点和障碍物

首先确定路径规划的起点和目标点，并标记出环境中存在的障碍物。

步骤 2：建立势场函数

根据路径规划具体场景与评价指标，建立合适的势场函数，即引力势场函数和斥力势场函数。

步骤 3：计算合力

根据引力势场和斥力势场的叠加效果，计算机器人所受的合力，该合力的方向引导机器人运动方向。

步骤 4：更新机器人位置

根据合力的方向和大小，利用速度和时间来计算机器人的位移量，更新机器人的位置。

步骤 5：检查终止条件

检查机器人是否到达目标点或者与障碍物发生碰撞。如果满足终止条件，路径规划结束；否则，返回执行步骤 3，直到机器人到达目标点或者路径规划无法完成。基于人工势场法的路径规划结果如图 2.13 所示。

相较于其他算法，人工势场法具有以下优点：

(1) 算法理论清晰直观：人工势场法的思想直观易懂，容易实现和理解，使得路径规划问题变得直观清晰。

(2) 实时性强：由于人工势场法只需要根据当前环境计算势场和受力情况，而不需要事先建立完整的地图，因此人工势场法能够实时地响应环境变化，并运用于局部规划场景。

(3) 鲁棒性强：人工势场法对于环境中的障碍物变化具有一定的鲁棒性，能够在动态环

中国知网 https://www.cnki.net

境中实时规划路径。当障碍物发生变化时，势场会发生相应变化，算法可以通过调整受力情况以此避开障碍物。

(4) 可以处理复杂环境：人工势场法通过合理设计势场和受力函数，可以使算法在规避障碍物的同时并寻找到合适的路径，以应对复杂的环境和多个障碍物的情况。

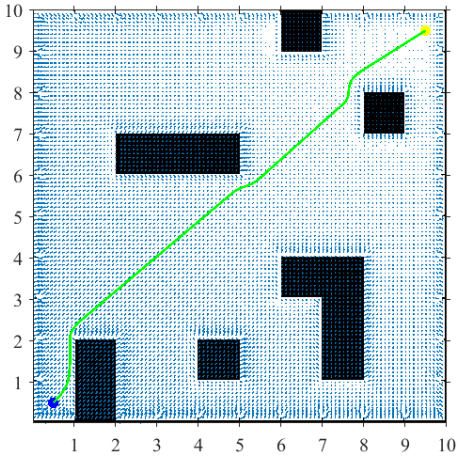


图 2.13 人工势场路径规划结果

Figure 2.12 Artificial potential field path planning results

与此同时，算法也有以下缺陷：

(1) 容易陷入局部最小值：当机器人接近目标时，势场可能导致机器人停留在局部最小值位置，无法到达目标点。

(2) 路径非最优：由于势场是基于当前环境信息所建立的，因此人工势场法生成的路径不一定是全局最优路径。在复杂环境中，机器人可能会绕远路或出现震荡现象。

(3) 震荡问题：人工势场法在避障过程中，可能会出现振荡或者停滞的情况。当机器人进入紧密障碍物区域时，受力计算可能导致机器人来回摇摆或无法继续前进。

(4) 势场函数建立困难：目前势场函数常依据经验建立，形式单一，在复杂环境中，如存在多个目标点或多个机器人的情况下，可能无法完成相关势场函数的建立。

2.4 本章小结

本章主要介绍了无人车辆路径规划体系中所涉及的环境地图模型和相关路径规划算法理论。首先对路径规划问题进行了描述，接着介绍了在路径规划问题中常用的几种环境地图模型，最后详细阐述了几种常用的路径规划算法及其相关理论。根据本章内容，综合考虑各算法特点以及无人车辆路径规划场景需求，后续研究本文将选择 A*算法作为主要研究对象，基于此完成复杂场景下无人车辆全局路径规划的研究。

中国知网 https://www.cnki.net

第三章 基于双邻域选择扩展策略的 A*路径规划算法

目前，针对无人车辆全局路径规划研究而言，其环境条件大多为复杂平坦环境，该环境条件的显著特征在于忽略地形高度变化，默认环境地面高度一致，环境中存在诸多不同类型、形状各异的障碍物。在该环境条件下，根据所需指标规划出一条最优全局路径。

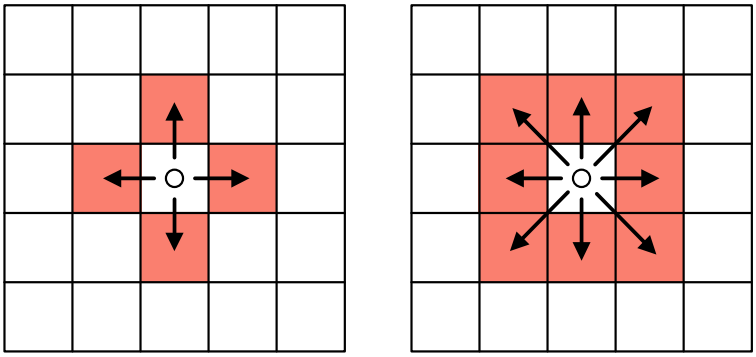
在第二章中，本文介绍了目前应用较为普遍、理论较为完善的几种路径规划算法。对于复杂平坦环境下无人车辆全局路径规划这一问题，综合考虑算法特性以及应用场景，本文选择 A*算法为主要研究对象，针对复杂平坦环境下无人车辆全局路径规划这一问题，对 A*算法进行改进。

3.1 双邻域选择扩展 A*路径规划算法

针对 A*算法存在的不足，下面，本文将从扩展策略、代价函数、冗余节点、路径平滑四个方面进行改进优化，以满足复杂平坦环境下无人车辆全局路径规划的需要。

3.1.1 改进邻域扩展策略

A*算法在路径搜索过程中，邻域扩展策略一般采用四邻域或八邻域的扩展策略。 四邻域扩展策略是向当前节点 n 四个方向进行扩展，每个方向之间夹角 90°，原理如图 3.1(a)所示，扩展邻域坐标集合可表示为 $E_n=\{(x_n\pm1, y_n),\ (x_n, y_n\pm1)\}$。采用四邻域扩展策略可以保证路径各节点之间路径是绝对安全的，不会规划出从障碍物间穿过的路径，缺点是节点扩展范围较小，算法迭代次数高，路径转折较多，且规划出的路径包含大量冗余点，如图 3.2(a)所示。



(a)四邻域扩展　　(b)八邻域扩展

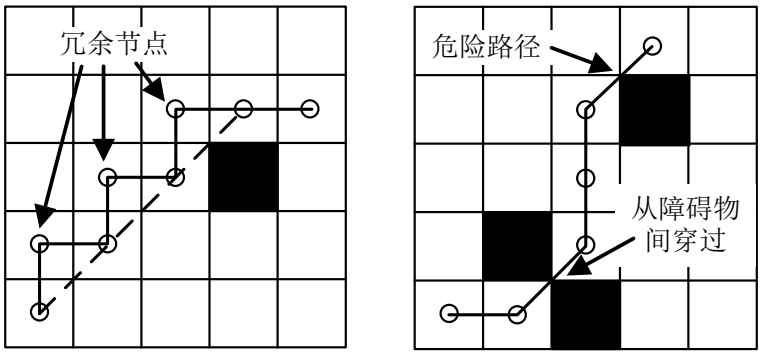
图 3.1 四邻域扩展与八邻域扩展示意图

Figure 3.1 Schematic diagram of four-neighborhood extension and eight-neighborhood extension

八邻域扩展策略在四邻域扩展策略的基础上增加了四个方向，每个方向之间夹角为 45°，原理如图 3.1(b)所示，其扩展邻域坐标的集合可表示为 $E_n=\{(x_n\pm1, y_n),\ (x_n, y_n\pm1),\ (x_n\pm1, y_n\pm1)\}$，相较于四邻域扩展策略，八邻域扩展策略迭代

中国知网 https://www.cnki.net

次数明显减少，有效提高了算法扩展效率，规划出的路径转折较少，冗余点数量减少，缺点是会规划出大量可能与障碍物拐角发生碰撞的危险路径以及从两障碍物间穿过的路径，使路径安全性降低，不符合机器人路径规划安全性要求，如图 3.2(b)所示。

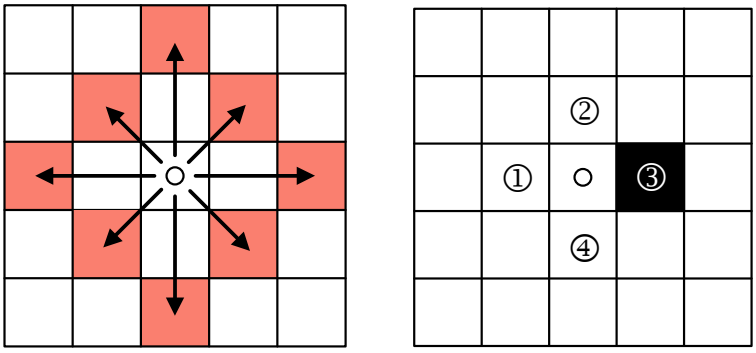


(a)冗余节点　　(b)危险路径

图 3.2 冗余节点与危险路径

Figure 3.2 Redundant nodes and hazardous paths

针对上述扩展策略存在的问题，本文提出了一种新的扩展策略。首先，引入斜八邻域扩展的概念，原理如图 3.3(a) 所示。其扩展邻域坐标集合可表示为 $E_n=\{(x_n\pm2,y_n),\ (x_n,y_n\pm2),\ (x_n\pm1,y_n\pm1)\}$。



(a)斜八邻域扩展　　(b)四邻域存在障碍物

图 3.3 四邻域-斜八邻域扩展

Figure 3.3 Four-neighborhood-slash-eight-neighborhood extension

斜八邻域扩展是在原有八邻域扩展策略的基础上，在 x 轴、y 轴方向上的节点扩展向外多扩展一个单位，越过四邻域扩展节点，较八邻域扩展在迭代次数不变的情况下使扩展范围更大。然后，将斜八邻域扩展与四邻域扩展结合，融合成一种全新的四邻域-斜八邻域双邻域选择扩展策略。

具体来说，在对当前节点 n 进行扩展子节点时，首先对当前节点四个方向即四邻域扩展方向四个节点（如图 3.3(b)中的节点①~④）进行判断，若该四节点任意节点存在障碍物（$a_{ij}=1$）或为路径的目标点（$a_{ij}=G$），例如图 3.3(b)中的③处存在障碍物，此时采用四邻域扩展策略，扩展邻域集合为 $E_n=\{(x_n\pm1,y_n),\ (x_n,y_n\pm1)\}$；若该四节点任意节点都不存在障碍物或路径目标点，此时采用本文提出的斜八邻域扩展策略，扩展邻域集合为

中国知网 https://www.cnki.net

$E_n = \{(x_n \pm 2, y_n),\ (x_n, y_n \pm 2),\ (x_n \pm 1, y_n \pm 1)\}$，通过上述判断四邻域节点是否存在障碍物或路径目标点后，在进行斜八邻域扩展时，可以保证扩展的八个方向任一方向搜索出的路径都是绝对安全可达的，且不会忽略路径目标点。同时，在相同地图环境下，四邻域-斜八邻域双邻域选择扩展策略迭代次数更少，路径更安全，如图 3.4 所示。四邻域-斜八邻域双邻域选择扩展策略大大提升了算法效率，同时解决了传统单一扩展策略所存在的安全性与冗余点较多的问题，为进一步优化算法奠定基础。

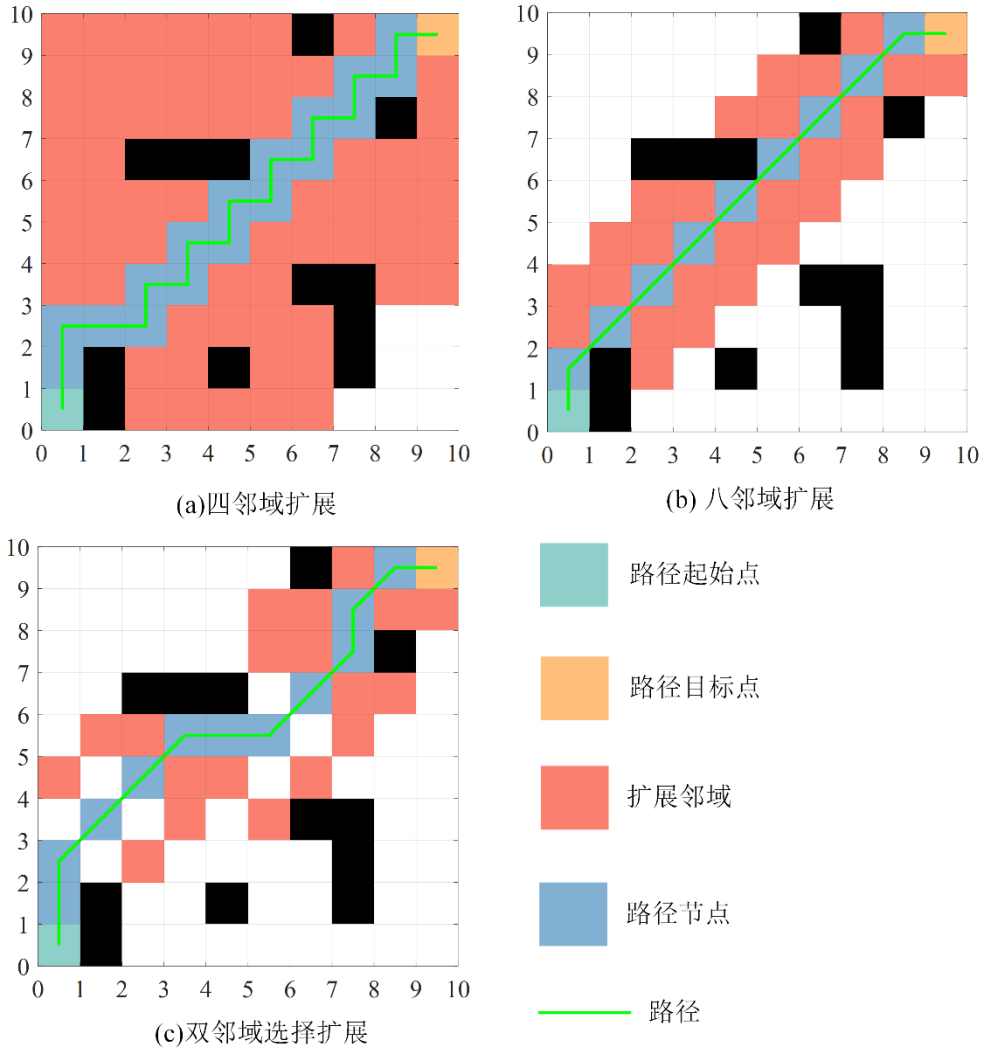


图 3.4 各扩展策略扩展示意图

Figure 3.4 Schematic diagram of the expansion of each expansion strategy

本文所提四邻域-斜八邻域双邻域选择扩展策略有如下定理：

定理 3.1：在同一幅地图中规划出同一条路径，四邻域-斜八邻域双邻域选择扩展策略的扩展次数不超过四邻域扩展或八邻域扩展。

证明：若规划出的一条路径长度为 M 个栅格单位，则

四邻域扩展次数为

$$T_a = M \qquad \text{式 (3.1)}$$

中国知网 https://www.cnki.net

八邻域扩展次数为

$$\frac{\sqrt{2}}{2}M \le T_b \le M \qquad \text{式 (3.2)}$$

四邻域-斜八邻域双邻域选择扩展策略扩展次数为

$$\frac{M}{2} \le T_c \le M \qquad \text{式 (3.3)}$$

整理式子（3.1）（3.2）（3.3）三式有

$$T_{c,\min} < T_{b,\min} < T_{a,\min} = T_{a,\max} = T_{b,\max} = T_{c,\max} \qquad \text{式 (3.4)}$$

定理 3.1 得证。

定理 3.2：在同一幅地图中，相同扩展次数下，四邻域-斜八邻域双邻域选择扩展策略的扩展路径长度不小于四邻域扩展或八邻域扩展。

证明：若扩展 N 次可规划出一条路径，则有

四邻域扩展路径长度为

$$L_a = N \qquad \text{式 (3.5)}$$

八邻域扩展路径长度为

$$N \le L_b \le \sqrt{2}N \qquad \text{式 (3.6)}$$

四邻域-斜八邻域双邻域选择扩展策略扩展路径长度为

$$N \le L_c \le 2N \qquad \text{式 (3.7)}$$

整理式子（3.5）（3.6）（3.7）三式有

$$L_{c,\min} = L_{b,\min} = L_{a,\min} = L_{a,\max} < L_{b,\max} < L_{c,\max} \qquad \text{式 (3.8)}$$

定理 3.2 得证。

根据定理 3.1 与定理 3.2 可知，在相同条件下，四邻域-斜八邻域双邻域选择扩展策略最优时较传统四邻域或八邻域扩展策略扩展次数更少，扩展范围更远。由式（3.1）-（3.8）计算得知，理论上扩展同一条路径，四邻域-斜八邻域双邻域选择扩展策略扩展次数较传统四邻域扩展最优时能减少 50%，较八邻域扩展能减少 29%；相同扩展次数下，四邻域-斜八邻域双邻域选择扩展策略扩展距离较传统四邻域扩展最大距离能增加一倍，较八邻域扩展能增加 41%。

为进一步验证本文所提四邻域-斜八邻域双邻域选择扩展策略的有效性，选取 GPPC（Grid based path planning competition）竞赛的数据进行测试[93]，具体选取 City/street maps

中国知网 https://www.cnki.net

数据集中的 30 幅栅格地图以及随机生成障碍比分别为 10%、20%、30%的各 10 幅栅格地图，共计 60 幅栅格地图作为本文测试数据集，所有测试地图大小均为 256×256，各扩展策略代价函数一致，测试结果如表 3.1 所示。

表 3.1 同一代价函数不同扩展策略对比

Table 3.1 Comparison of different expansion strategies for the same heuristic function

扩展次数	四邻域扩展	八邻域扩展	双邻域选择扩展		
			扩展次数	较四邻域扩展次数减小率	较八邻域扩展次数减小率
最大值	51729	7890	7486	99.32%	35.48%
最小值	12119	255	254	59.47%	0.00%
平均值	33812	1038	894	96.04%	13.60%

从表 3.1 中可以看出，较另外两种传统扩展策略，本文所提出的四邻域-斜八邻域双邻域选择扩展策略在路径搜索过程中能有效减少扩展次数，提高算法效率。如图 3.4 所示，在相同地图环境下，四邻域-斜八邻域双邻域选择扩展策略扩展次数更少，路径更安全，大大提升了算法效率，同时解决了传统单一扩展策略所存在的安全性与冗余点较多的问题，为进一步优化算法奠定基础。

3.1.2 代价函数优化

如 2.3.3 节所述，A*算法代价函数一般有三种，代价函数决定着算法搜索行为，三种代价函数在不同场景应用下各有优劣。文献[94]通过对三种代价函数进行比较，探究三种代价函数的特性后对代价函数进行了改进。本文在此基础上提出代价函数：

$$h(n)=\alpha h_1(n)+\beta h_2(n) \qquad \text{式 (3.9)}$$

式（3.9）中：

$$h_1(n)=\max\left(\left|x_n-x_g\right|,\ \left|y_n-y_g\right|\right) \qquad \text{式 (3.10)}$$

$$h_2(n)=\min\left(\left|x_n-x_g\right|,\ \left|y_n-y_g\right|\right) \qquad \text{式 (3.11)}$$

其中，α、β 为启发因子，可以通过调节其大小来改变算法的搜索行为，α、β 过大将会导致代价函数占比过大，使 A*算法退化为 BFS 算法，造成路径最优性方面有所下降。因此，基于本文提出的双邻域选择扩展策略，假设 $0\le\alpha,\beta\le5$，在 3.1.1 节所述测试数据中通过不同赋值寻求迭代次数与路径长度最优解，取 60 次测试平均值作为比较指标进行比较，具体数据如表 3.2 所示，结果如图 3.5 所示。

中国知网 https://www.cnki.net

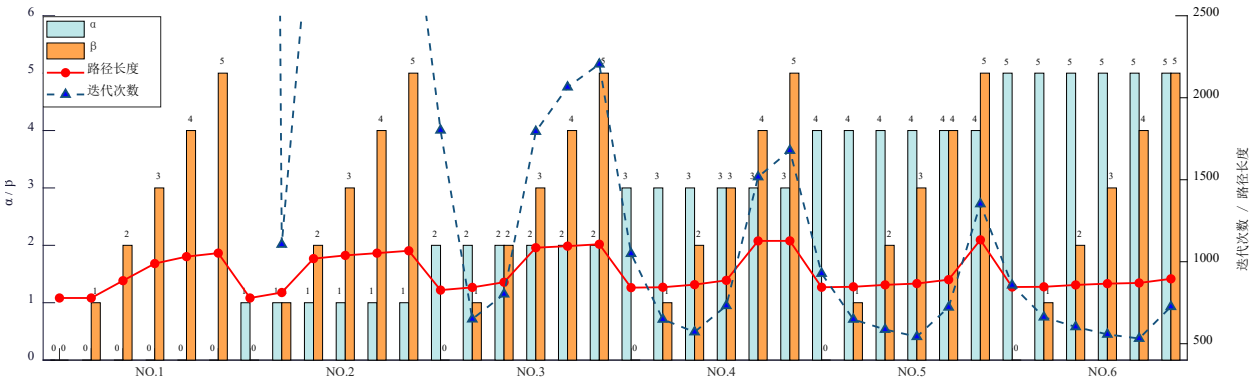


图 3.5 启发因子 α, β 与迭代次数及路径长度的关系

Figure 3.5 Heuristic factors α, β vs. number of iterations and path lengths

表 3.2 启发因子 α, β 与迭代次数及路径长度的关系具体数据

Table 3.2 Specific data on the heuristic factors α, β with respect to the number of iterations and path lengths

		β=0	β=1	β=2	β=3	β=4	β=5
扩展次数	α=0	50277	50103	20455	12662	9549	8022
	α=1	28142	1106	3338	3350	3394	3349
	α=2	1802	650	802	1794	2065	2205
	α=3	1049	648	571	732	1517	1678
	α=4	928	649	587	543	722	1353
	α=5	857	662	603	557	532	726
路径长度	α=0	389.44	389.44	442.22	494.41	515.53	526.26
	α=1	389.44	406.1	509.48	519.27	526.16	533.44
	α=2	413.51	421.77	437.5	542.76	547.54	553.37
	α=3	421.01	422.2	430.13	443.25	563.47	563.61
	α=4	422.22	423.52	429.48	433.46	445.33	566.66
	α=5	422.87	423.52	429.22	433.17	435.28	447.87

结合图 3.5 与表 3.2 可以看出，当 α、β 取初值都为 0 时，此时 A*算法退化为 Dijkstra 算法，路径最短，但平均迭代次数高达 50277 次，路径时间规划时间过长；随着 α、β 值的增大，迭代次数呈指数级下降，当 α=2、β=1 时，迭代次数与路径长度二者达到一个相对最优的情况。同时，考虑到代价函数 $h(n)$预估距离应小于等于当前节点到路径目标点的真实距离，α、β 二者之和不应过大。因此，改进后的代价函数为：

$$f(n)=g(n)+\alpha\left(\max\left(\left|x_n-x_g\right|,\ \left|y_n-y_g\right|\right)\right)+\beta\left(\min\left(\left|x_n-x_g\right|,\ \left|y_n-y_g\right|\right)\right) \qquad \text{式 (3.12)}$$

本文推荐取 α=2，β=1。

中国知网 https://www.cnki.net

通过对本文测试数据集进行测试，数据结果显示，在同一扩展策略下，本文所提代价函数较原始代价函数平均能够减少 42.28%的扩展次数。其中，在四邻域扩展策略、八邻域扩展策略、四邻域-斜八邻域双邻域选择扩展策略下，平均分别减少了 96.64%、19.64%、10.58%的扩展次数，具体数据如表 3.3 所示。

表 3.3 同一扩展策略下不同代价函数扩展次数对比

Table 3.3 Comparison of the number of expansions of different heuristic functions under the same expansion strategy

扩展策略	对比指标	最大值	最小值	平均值
四邻域扩展策略	原始代价函数扩展次数	51729	12119	33812
	改进代价函数扩展次数	4244	555	913
	较原始代价函数扩展次数减小率	98.87%	78.20%	96.64%
八邻域扩展策略	原始代价函数扩展次数	7890	255	1038
	改进代价函数扩展次数	6611	325	718
	较原始代价函数扩展次数减小率	74.24%	-58.69%	19.64%
四邻域-斜八邻域双邻域选择扩展策略	原始代价函数扩展次数	7486	254	894
	改进代价函数扩展次数	3822	319	650
	较原始代价函数扩展次数减小率	83.45%	-157.12%	10.58%

3.1.3 冗余点剔除策略

A*算法作为典型的基于节点的方法，所规划出的路径中包含着大量的冗余节点，这些冗余节点在一定程度上保证了路径的安全性，但同时因为大量冗余节点的存在，使规划出的路径非最优，路径转折较多，不满足路径规划最优性原则，不利于机器人运动。碰撞检测是概率路线图法（PRM）路径规划算法的核心内容[95]，基本思想如图 3.6 所示。

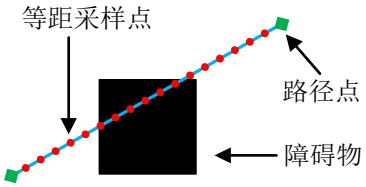


图 3.6 碰撞检测

Figure 3.6 Collision detection

在两路径点连线上进行等距采样，随后依次对若干等距采样点进行检测，是否有采样点

中国知网 https://www.cnki.net

处于障碍物中，如果有则认为该两路径点连接的路径会与障碍物发生碰撞，该路径不可行；如果没有，则认为该两路径点连接的路径不会与障碍物发生碰撞，该路径是可行的安全的。

本文将此碰撞检测算法引入到改进后的 A*算法中，对冗余点进行剔除，步骤如下：

Step1：获取经改进后的 A*算法规划出的路径

节点集合$\{p_0, p_1, p_2, \cdots, p_n\}$，其中 p_0 为路径起始点，p_n 为路径目标点；

Step2：建立一个空的最优路径列表（PATH list），并将 p_0 放入最优路径列表，同时定义 p_0 为碰撞检测点 1，p_i 为碰撞检测点 2（在本步骤中 $i=2$，碰撞检测点 2 就是节点 p_2）；

Step3：对两个碰撞检测点进行碰撞检测，如果会发生碰撞，则执行 Step4, 如果不会则执行 Step5；

Step4：将碰撞检测点 2（p_i）回溯第一个路径点 p_{i-1} 定义为碰撞检测点 1，并放入最优路径列表，返回执行 Step3；

Step5：判断碰撞检测点 2 是否为路径目标点，如果不是则将碰撞检测点 2（p_i）后第一个路径节点 p_{i+1} 定义为碰撞检测点 2，并返回执行 Step3；否则执行 Step6；

Step6：将碰撞检测点 2 放入最优路径列表，最终得到最优路径点列表集合$\{\hat{p}_0, \hat{p}_1, \hat{p}_2, \cdots, \hat{p}_m\}$，依次连接最优路径列表中的所有路径点，得到最优路径，结束冗余点剔除。

通过执行上述冗余点剔除策略后，可剔除路径列表中多余的路径点，降低路径点数量，缩短路径距离，减少不必要转弯，提高路径最优性。下面对本文所提冗余点剔除策略对降低路径成本的有效性进行理论说明。

假设改进后 A*算法规划出的路径点集合为$\{p_0, p_1, p_2, \cdots, p_n\}$，经冗余点剔除后的路径点集合为$\{\hat{p}_0, \hat{p}_1, \hat{p}_2, \cdots, \hat{p}_m\}$，因此原始路径长度成本为

$$L_1 = \sum_{i=0}^{n-1} \sqrt{(x_{p_i} - x_{p_{i+1}})^2 + (y_{p_i} - y_{p_{i+1}})^2} \qquad \text{式 (3.13)}$$

冗余点剔除后的路径长度成本为

$$L_2 = \sum_{j=0}^{m-1} \sqrt{(x_{\hat{p}_j} - x_{\hat{p}_{j+1}})^2 + (y_{\hat{p}_j} - y_{\hat{p}_{j+1}})^2} \qquad \text{式 (3.14)}$$

极限条件下，当原始路径节点中$\{p_1, p_2, \cdots, p_{n-1}\}$均为冗余节点时，此时，$\hat{p}_0 = p_0$，$\hat{p}_m = \hat{p}_1 = p_n$，即有：

$$L_2 = \sqrt{(x_{\hat{p}_0} - x_{\hat{p}_1})^2 + (y_{\hat{p}_0} - y_{\hat{p}_1})^2} = \sqrt{(x_{p_0} - x_{p_n})^2 + (y_{p_0} - y_{p_n})^2} \qquad \text{式 (3.15)}$$

由 A*算法路径规划特性可知，此时

$$L_1 \le \left| x_{p_0} - x_{p_n} \right| + \left| y_{p_0} - y_{p_n} \right| \qquad \text{式 (3.16)}$$

中国知网 https://www.cnki.net

路径成本减少率

$$\zeta = 1 - \frac{L_2}{L_1} \le 1 - \frac{\sqrt{(x_{p_0} - x_{p_n})^2 + (y_{p_0} - y_{p_n})^2}}{\left|x_{p_0} - x_{p_n}\right| + \left|y_{p_0} - y_{p_n}\right|} \quad \text{式 (3.17)}$$

当且仅当$\left|x_{p_0} - x_{p_n}\right| = \left|y_{p_0} - y_{p_n}\right|$，式（3.17）中$\zeta$存在最大值 0.29，即理论上通过冗余点剔除策略，最大能够减少 29%的路径成本。同时，为进一步验证理论，基于本文测试数据集，通过执行本文所提冗余点剔除策略后，路径成本可以得到不同程度的降低。不同扩展策略下经过冗余剔除策略后路径成本变化具体数据如表 3.4 所示。

表 3.4 冗余点剔除策略后路径成本变化

Table 3.4 Change in path cost after redundant point removal strategy

路径成本减少率	四邻域扩展	八邻域扩展	双邻域选择扩展
最大值	28.84%	11.35%	12.30%
最小值	17.34%	0.82%	0.97%
平均值	23.19%	5.71%	7.72%

3.1.4 三次 B 样条曲线路径平滑

经过执行冗余点剔除策略后，虽然路径节点数量大大降低，但 A*算法路径规划后的路径转折较大，过渡不平滑，依然不利于机器人运动，因此有必要对规划好的路径进一步平滑优化。 B 样条曲线具有既维持路径原基本形状的同时，又能对路径转角进行平滑处理的特性，因此被广泛用于路径平滑[96]，本文采用三次 B 样条曲线进行路径平滑。

B 样条曲线定义为：

$$\overline{P}(t) = \sum_{i=0}^{m} \hat{p}_i F_{i,k}(t) \quad \text{式 (3.18)}$$

式（3.18）中：$\hat{p}_i \ (i = 0,1,\cdots,m)$为 m+1 个控制顶点（路径点），$F_{i,k}(t)$为 k 阶 B 样条基函数。根据 de Boor-Cox 递推定义，$F_{i,k}(t)$可表示为：

$$F_{i,0}(t) = \begin{cases} 1 \ , \ t_i \le t < t_{i+1} \\ 0 \ , \ \text{others} \end{cases} \quad \text{式 (3.19)}$$

$$F_{i,k}(t) = \frac{t - t_i}{t_{i+k} - t_i} F_{i,k-1}(t) + \frac{t_{i+k+1} - t}{t_{i+k+1} - t_{i+1}} F_{i+1,k-1}(t) \quad \text{式 (3.20)}$$

式（3.20）中：$[t_i, t_{i+k+1}]$为$F_{i,k}(t)$的支撑区间，当将子区间$[t_i, t_{i+1}]$上整体参数 t 表示的基函数用局部参数$t \in [0,1]$表示后，带入(3.18)式并令 k=3，即可求得三次 B 样条曲线表达式，用矩阵表示为：

中国知网 https://www.cnki.net

$$\bar{P}(t)=\frac{1}{6}[t^3\ \ t^2\ \ t\ \ 1]\begin{bmatrix}-1 & 3 & -3 & 1\\ 3 & -6 & 3 & 0\\ -3 & 0 & 3 & 0\\ 1 & 4 & 1 & 0\end{bmatrix}\begin{bmatrix}\hat{p}_{i-3}\\ \hat{p}_{i-2}\\ \hat{p}_{i-1}\\ \hat{p}_i\end{bmatrix} \quad \text{式 (3.21)}$$

式（3.21）中，$t\in[0,1]$，$i=3,4,\cdots m$

通过三次 B 样条曲线对冗余点剔除后路径平滑处理的结果比较如图 3.7 所示，可以看出，改进后的算法能有效去除路径中的折点，路径平滑连续，对保证移动机器人或无人车辆在运动过程中速度、加速度的连续性和转向平稳是有利的。

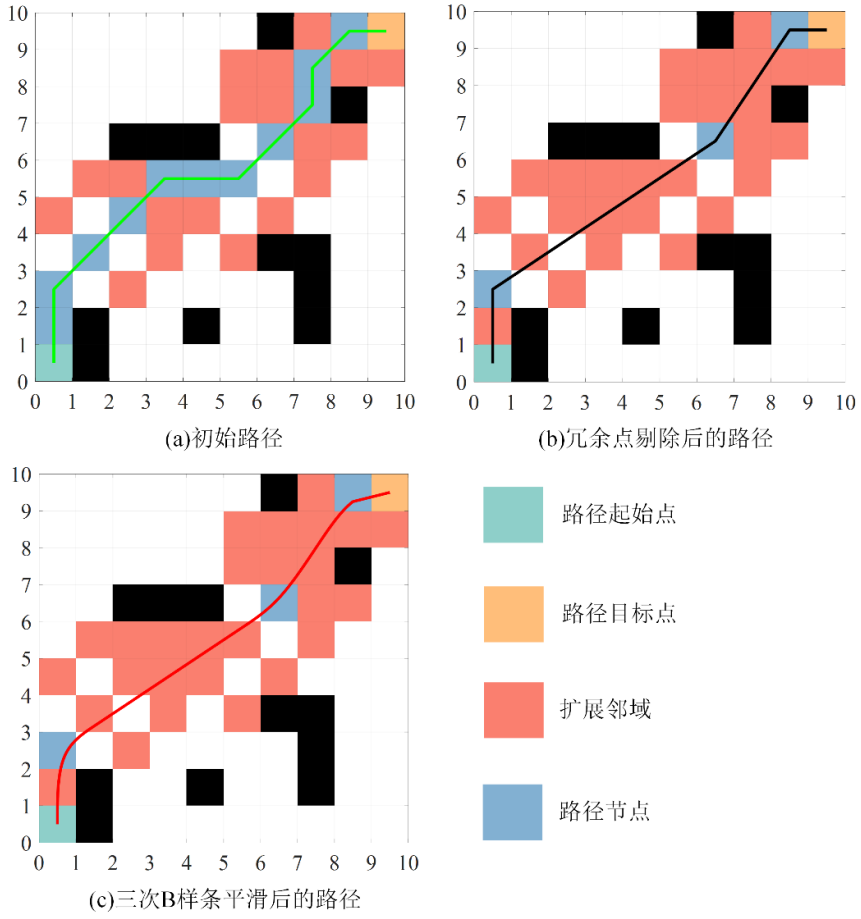


图 3.7 改进 A*算法冗余点剔除与路径平滑

Figure 3.7 Improved A* algorithm redundant point removal and path smoothing

3.1.5 算法流程

本文针对 A*算法所存在的问题，从代价函数优化、邻域扩展策略、冗余点剔除以及路径平滑四个方面对 A*算法进行了改进，改进后的 A*算法流程图如图 3.8 所示。

中国知网 https://www.cnki.net

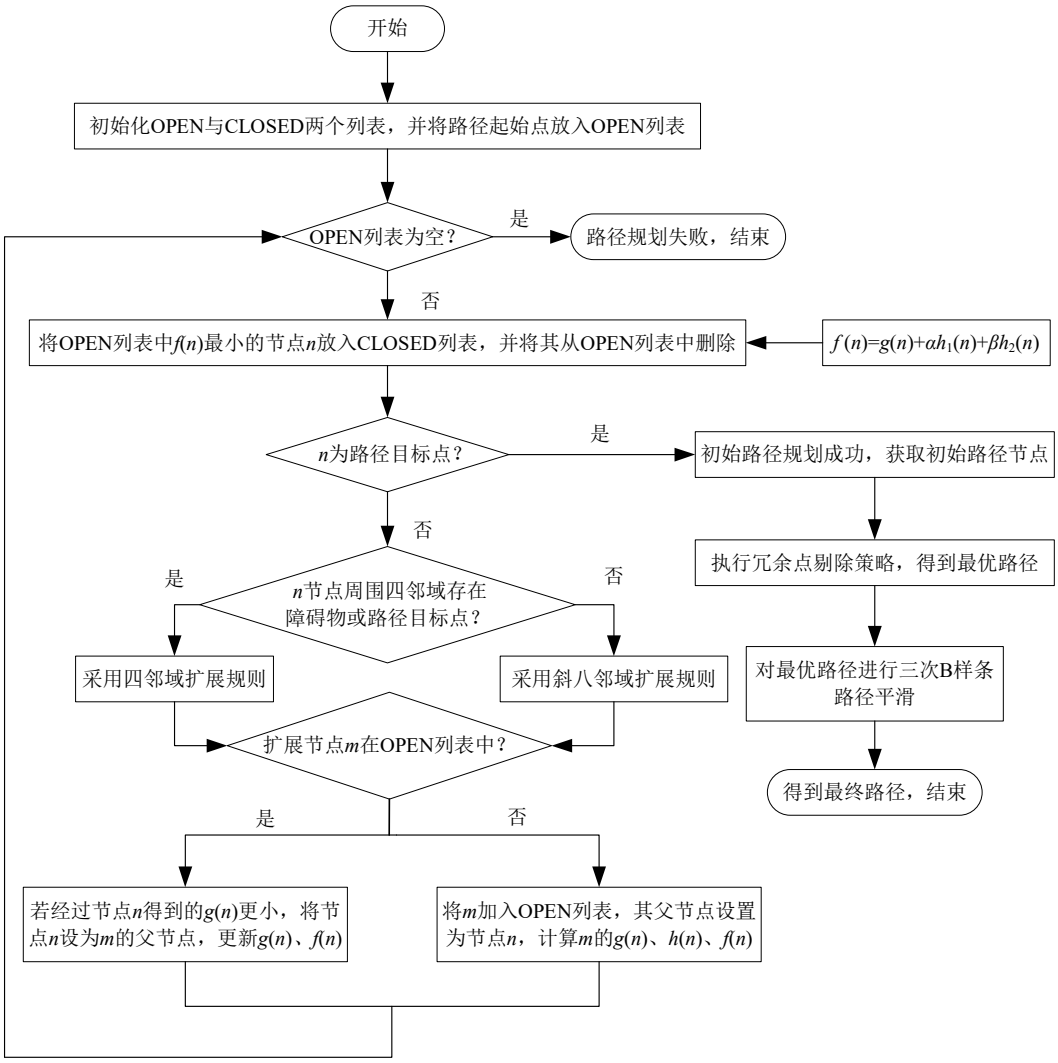


图 3.8 改进 A*算法流程图

Figure 3.8 Flowchart of the improved A* algorithm

3.2 仿真分析评价

在 3.1.2 节中，本文建立了新的代价函数，并通过大量栅格地图仿真测试迭代得到启发因子 α=2、β=1 时，迭代次数与路径长度二者达到一个相对最优的情况。故在本节的仿真与试验分析中，改进后的 A*算法的代价函数启发因子取值为 α=2、β=1。

首先通过计算机仿真对本文提出的改进的 A*算法进行评价分析，并与 Dijkstra、四邻域 A*算法、八邻域 A*算法进行比较。为更好地体现本文改进 A*算法的效果及地图适应性，分别设计了两种试验地图环境，即集中障碍物环境与随机障碍物环境。计算仿真的软件环境为 Matlab R2019b；仿真计算机主要配置为：Windows 10 操作系统，主频为 3.40GHz 的 Intel(R) Core(TM) i7.6700 CPU，内存 16GB。表 3.5 给出了 Dijkstra 算法、四邻域扩展 A*算法、八邻域扩展 A*算法以及本文提出的改进 A*算法分别在四种地图环境下进行路径规划的结果参数对比。仿真结果如图 3.9~图 3.12 所示，图中红色部分为路径规划过程中各算法扩展的节点，绿色线条为最终规划的路径。

中国知网 https://www.cnki.net

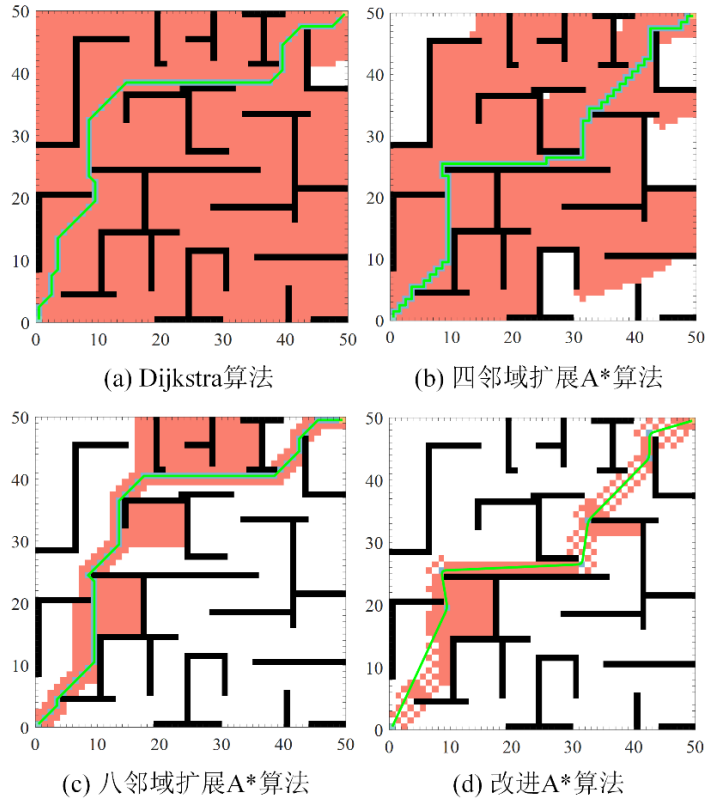


图 3.9 地图 1 的不同算法路径规划结果

Figure 3.9 Map 1 of the different algorithms path planning results

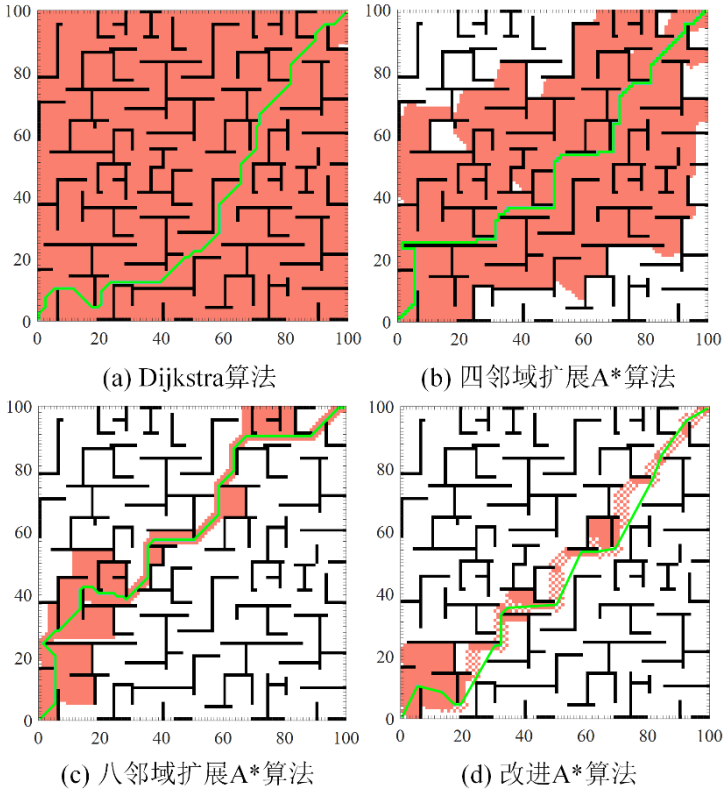


图 3.10 地图 2 的不同算法路径规划结果

Figure 3.10 Map 2 of the different algorithms path planning results

中国知网 https://www.cnki.net

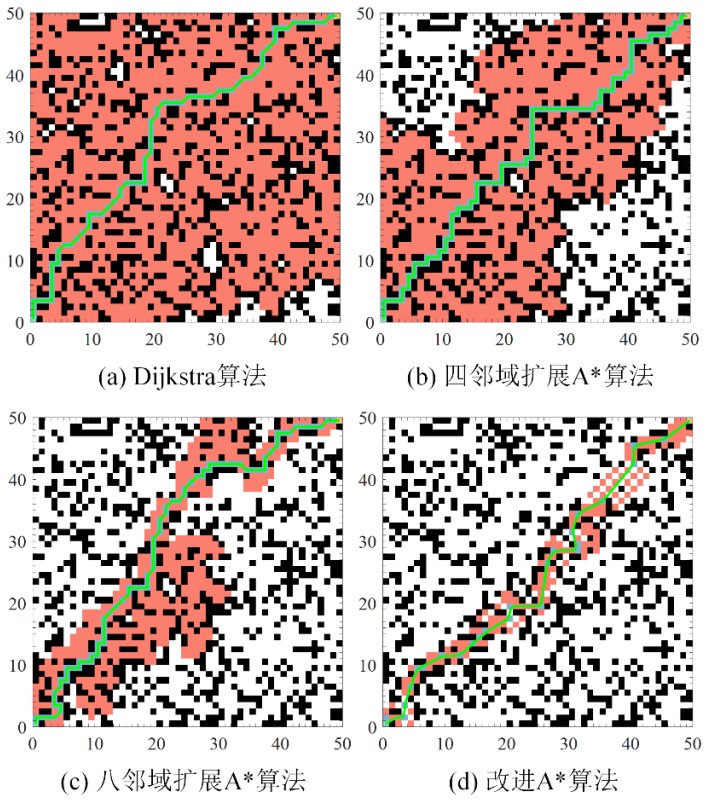


图 3.11 地图 3 的不同算法路径规划结果

Figure 3.11 Map 3 of the different algorithms path planning results

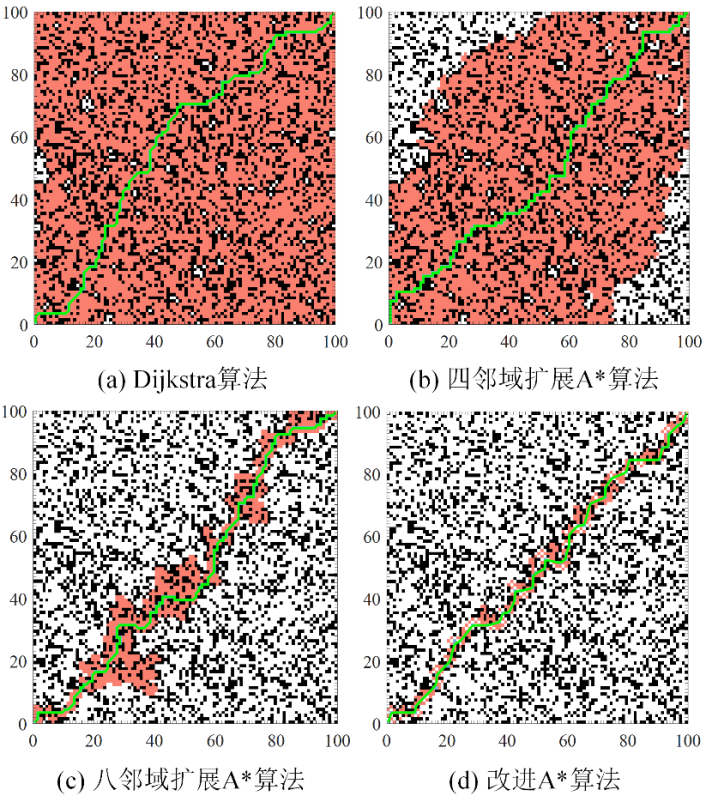


图 3.12 地图 4 的不同算法路径规划结果

Figure 3.12 Map 4 of the different algorithms path planning results

中国知网 https://www.cnki.net

表 3.5 各算法路径规划的具体数据对比

Table 3.5 Comparison of specific data for each algorithmic path planning

	地图	算法	扩展节点个数	路径长度/栅格单位	路径点个数	转角个数	搜索时间/ms
集中障碍物环境	地图 1 (50×50)	Dijkstra 算法	2134	86.53	77	15	14.56
		四邻域扩展 A*算法	1662	100.00	100	47	12.04
		八邻域扩展 A*算法	357	84.77	74	12	6.31
		本文改进 A*算法	154	81.64	8	6	2.10
	地图 2 (100×100)	Dijkstra 算法	8629	169.58	141	27	91.60
		四邻域扩展 A*算法	5750	206.00	206	75	52.72
		八邻域扩展 A*算法	1075	178.85	154	24	20.90
		本文改进 A*算法	510	163.25	17	8	6.72
随机障碍物环境	地图 3 (50×50)	Dijkstra 算法	1678	85.70	77	35	27.10
		四邻域扩展 A*算法	1114	98.00	98	45	18.30
		八邻域扩展 A*算法	329	91.46	84	47	8.57
		本文改进 A*算法	93	77.82	23	9	2.26
	地图 4 (100×100)	Dijkstra 算法	6840	176.33	161	68	89.59
		四邻域扩展 A*算法	5412	198.00	198	91	54.38
		八邻域扩展 A*算法	656	183.50	169	83	18.29
		本文改进 A*算法	218	159.82	43	22	3.01

其中，地图 1 与地图 2 分别为 50×50 和 100×100 的集中障碍物的栅格地图环境，地图 3 与地图 4 分别为 50×50 和 100×100 的障碍比 30%的随机障碍物栅格地图环境。其中，50×50 的地图设置起点与终点分别为(1,1)和(50,50)，100×100 的地图设置起点与终点分别为(1,1)和(100,100)。可以看出，改进后的 A*算法无论是在随机障碍物地图环境或是集中障碍物地图环境下，相较于其他三种算法路径规划结果性能指标方面都有了较大的提升。

在保证路径质量的基础上，改进后的 A*算法扩展节点数量相较于另外三种算法中的最优值平均减少了 60%，大大降低了计算压力，使得搜索时间减少一个数量级，大大提高了路径规划效率。同时，随着地图的增大，改进后的 A*算法在搜索效率方面提升的更加显著。仿真结果表明，改进后的 A*算法在不同的环境地图下，无论是搜索速度还是路径质量均优于其他三种算法，效果显著。

3.3 试验分析验证

通过上述仿真分析，初步验证了所提出的改进 A*算法的有效性，为进一步验证算法在实际应用中的可行性，基于实验室的智能车辆平台在现实环境中完成自主路径规划，对改进

中国知网 https://www.cnki.net

后的 A*算法进行了场地试验评价。试验用的智能车辆平台如图 3.13 所示，表 3.6 给出了智能车辆平台相关参数。该平台搭载 JHCTECH 公司生产的 BRAV-7521 工控机，操作系统为 Ubuntu18.04，基于 ROS 开发环境，采用 Robosense16 线激光雷达采集周围地图环境信息，利用 NDT（Normal Distributions Transform）算法[97]完成环境三维点云地图的构建与车辆定位。试验中通过将建立好的三维点云地图二维栅格化后生成栅格地图，在该地图上进行路径规划。



图 3.13 智能车辆试验平台

Figure 3.13 Intelligent vehicle test platform

表 3.6 智能车辆平台相关参数

Table 3.6 Intelligent vehicle platform related parameters

参数	数值	参数	数值
车身长度	1.92 m	轮胎直径	0.45 m
车身宽度	1.02 m	最大转角	0.489 rad
车身高度	0.93 m	最小转向半径	2.66 m
轴距	1.30 m	试验运动速度	0.3 m/s

选择实验室外的一块空地为试验场景一，如图 3.14(a)所示，起点楼栋的一侧门口，终点为实验室后门所在位置，以及校内一处建筑群中间的空地为试验场景二，整个试验场景二长约 150m，宽约 50m，如图 3.14(b)所示。



(a)试验场景一　　(b)试验场景二

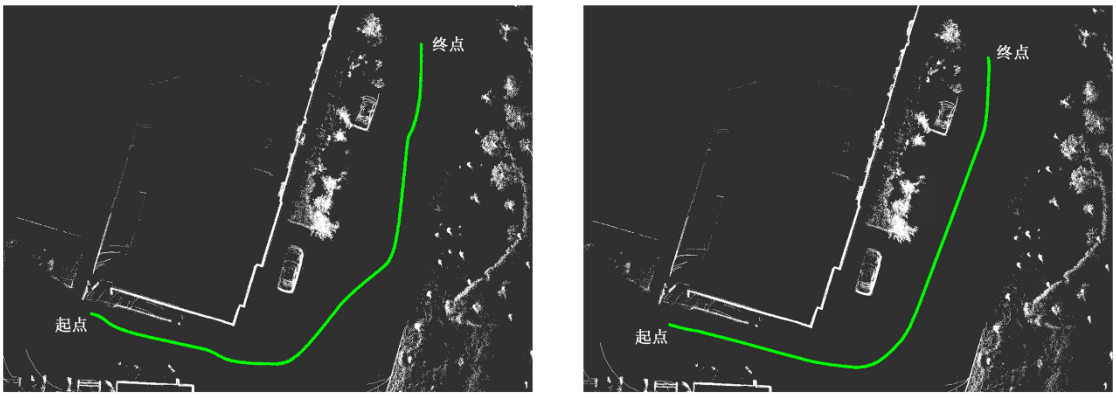
图 3.14 试验场地环境

Figure 3.14 Test site environment

中国知网 https://www.cnki.net

通过在同一试验环境下对比改进 A*算法与传统 A*算法路规划的效率和路径质量，对改进 A*算法的有效性与可行性进行评价。需要说明的是，在 ROS 官方提供的 navigation 导航功能包中，默认 A*算法采用的是八邻域扩展方式（使用 calculate Potential 函数对四邻域斜方向进行插值后搜索八个邻域节点），四邻域扩展方式应用较少，且规划的路径不满足车辆运动学约束，故为保证试验的客观性，在试验分析中，本文改进的 A*算法将与传统基于八邻域扩展的 A*算法进行对比。

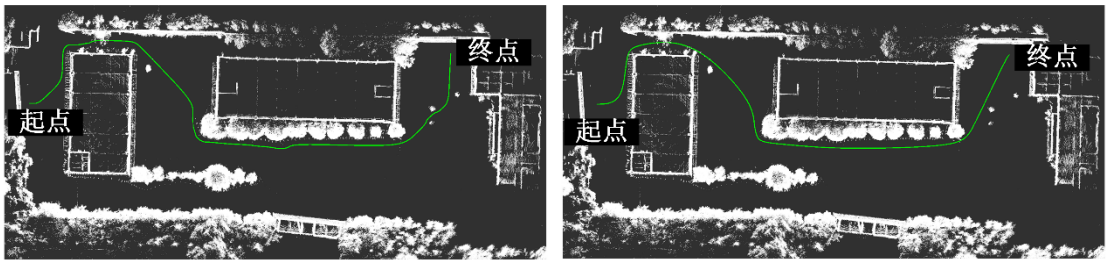
不同试验试验场景下试验结果如图 3.15 与图 3.16 所示。其中图 3.15(a)为试验场景一下传统的 A*算法路径规划结果，图 3.15 (b)分别为本文改进 A*算法的路径规划结果；图 3.16(a)为试验场景二下传统的 A*算法路径规划结果，图 3.16(b)为本文改进 A*算法的路径规划结果，绿色线条为两种算法规划的路径。不难看出，无论在哪一个环境下传统 A*算法规划的路径冗余点都较多，路径质量较差，改进 A*算法规划的路径较为平滑，无多余转角与冗余点，有利于无人车运动。



(a) A*算法路径规划结果　　(b) 改进A*算法路径规划结果

图 3.15 试验场景一场地试验结果比较

Figure 3.15 Comparison of test results for one site of the test scenario



(a) A*算法路径规划结果　　(b) 改进A*算法路径规划结果

图 3.16 试验场景二场地试验结果比较

Figure 3.16 Comparison of test results for two site of the test scenario

表 3.7 给出了不同场景下改进 A*算法与传统 A*算法的规划时间与路径长度的试验结果对比，可以看出在两个不同场景中改进的 A*算法路径搜索速度远快于传统的 A*算法，规划的路径也明显缩短。综合试验结果来看，改进后的 A*算法能够快速规划出一条质量较高且有利于机器人运动的路径，无论是搜索效率还是路径质量均优于原 A*算法，所提出的

中国知网 https://www.cnki.net

改进 A*算法是有效的可行的。

表 3.7 不同场景下 A*算法与改进 A*算法路径规划对比

Table 3.7 Intelligent vehicle platform related parameters

试验场景	算法	搜索时间/ms	路径长度/m
试验场景一	A*算法	302.11	57.71
	改进 A*算法	41.06	54.41
试验场景二	A*算法	887.76	181.76
	改进 A*算法	242.51	172.11

3.4 本章小结

本章针对 A*算法在路径规划过程中存在的扩展节点过多、路径冗余点过多等问题，对 A*算法进行了改进研究。提出了斜八邻域扩展的概念，与四邻域扩展结合组成一种新的双邻域选择扩展策略，在路径搜索过程中可以有效减少扩展节点的数量。为适应多种地图环境建立了新的代价函数，在相同地图环境下可以较经典 A*算法扩展的节点数量减少 50%以上，路径搜索速度提高一个数量级，算法效率明显提升。通过建立冗余点剔除策略与三次 B 样条曲线对初始路径进一步优化，剔除路径多余节点，减少路径转折，规划出一条符合无人车辆运动的最优路径。首先在四种不同障碍物的地图环境下对改进后的 A*算法进行了仿真分析，并与 Dijkstra、四邻域 A*算法、八邻域 A*算法进行了比较；然后，基于实验室的智能车试验平台进行了场地试验，对改进后的 A*算法进行了试验验证。结果表明，改进后 A*算法的路径搜索效率大幅提高，路径更有利于无人车辆运动，所提出的双邻域选择扩展 A*算法是可行的有效的。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

第四章 基于错栅格粒度地图的 A*路径规划算法

在上一章节中，本文研究了复杂平坦环境下无人车辆全局路径规划这一问题，基于环境特点以及算法特性选择了 A*算法作为主要研究对象，通过对传统 A*算法的各方面进行改进，实现了无人车辆在复杂平坦环境下进行高效率的全局路径规划，并使所规划路径质量得到进一步提升。

但是，随着无人车辆工作应用场景的日趋广泛，无人车辆的工作环境不仅仅局限于平坦复杂环境，越来越多的应用场景要求无人车辆应当考虑地形的复杂性，完成复杂非平坦环境下的全局路径规划。与结构化道路环境相比，非平坦环境最大特征在于环境地形的复杂性以及多样性。因此本章将继续基于 A*算法，并考虑地形高度变化，深入研究复杂非平坦环境下无人车辆全局路径规划这一问题。

4.1 错栅格粒度地图模型

传统复杂平坦环境下，二值化的栅格地图模型常作为各路径规划算法的标准地图模型。但在非平坦环境下，二维栅格地图描述环境特征有限，无法准确反映环境地形起伏变化，因此常用 DEM 作为三维环境下进行路径规划的标准地图模型。DEM 通过离散点的方式，记录环境内各地形区域的高程值，从而表征环境地图特征。DEM 分辨率与环境信息详实程度呈正比关系，分辨率越大，越能切实反映环境地形特征变化，基于此规划出的路径也更为贴合实际情况，不会因部分环境信息的缺失从而规划出危险路径。但过大的地图分辨率直接限制了路径规划算法的效率，使得算法实时性降低，如图 4.1 所示。

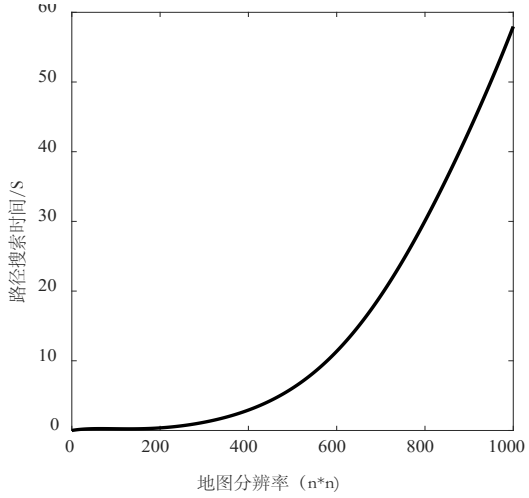


图 4.1 A*算法路径搜索时间与地图分辨率关系

Figure 4.1 A* algorithm path search time versus map resolution

本文针对非平坦地形环境的路径规划提出了一种错栅格粒度地图模型，其基本原理如

中国知网 https://www.cnki.net

图 4.2 所示，下面进行详细描述。

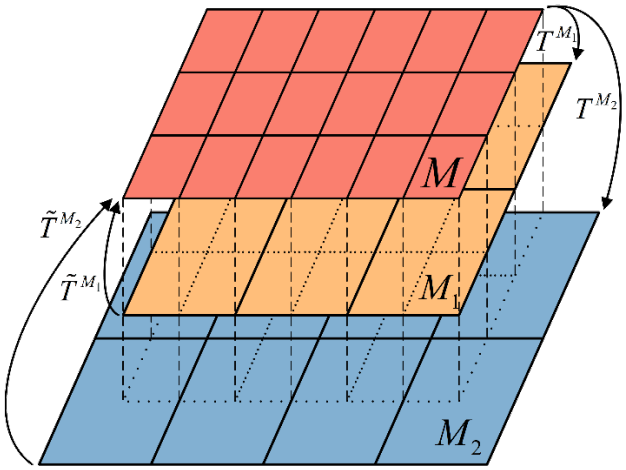


图 4.2 错栅格粒度地图模型示意图

Figure 4.2 Schematic diagram of interleaved granularity map model

定义 4.1：给定一个分辨率为$m\times n$的原始 DEM 地图M，其坐标集合记为C，由该坐标集合可映射出分辨率为$\lceil m/2\rceil\times\lceil n/2\rceil$的子 DEM 地图$M_1$的坐标集合$C_1$和分辨率为$\lceil (m+1)/2\rceil\times\lceil (n+1)/2\rceil$的子 DEM 地图$M_2$的坐标集合$C_2$（注：$\lceil\bullet\rceil$表示向上取整），具体定义如下：

$$\begin{cases} T^{M_1}: C\to C_1 \\ T^{M_2}: C\to C_2 \end{cases} \qquad \text{式 (4.1)}$$

式（4.1）中：T^{M_1}表示原始 DEM 地图M坐标集合C向子 DEM 地图M_1坐标集合C_1的映射；T^{M_2}表示原始 DEM 地图M坐标集合C向子 DEM 地图M_2坐标集合C_2的映射，C、C_1、C_2分别表达如下：

$$C=\left\{(x_k,y_k): x_k\in[1,n]\cap\mathbb{Z}^+, y_k\in[1,m]\cap\mathbb{Z}^+\right\} \qquad \text{式 (4.2)}$$

$$C_1=\left\{(x_{ok},y_{ok}): x_{ok}\in\left[1,\lceil n/2\rceil\right]\cap\mathbb{Z}^+, y_{ok}\in\left[1,\lceil m/2\rceil\right]\cap\mathbb{Z}^+\right\} \qquad \text{式 (4.3)}$$

$$C_2=\left\{(x_{tk},y_{tk}): x_{tk}\in\left[1,\lceil (n+1)/2\rceil\right]\cap\mathbb{Z}^+, y_{tk}\in\left[1,\lceil (m+1)/2\rceil\right]\cap\mathbb{Z}^+\right\} \qquad \text{式 (4.4)}$$

定义 4.2 映射T^{M_1}具体定义如下：

$$\begin{aligned} &T^{M_1}: C\to C_1 \\ &(x_k,y_k)\mapsto(x_{ok},y_{ok})=T^{M_1}(x_k,y_k)=\lceil(x_k/2,y_k/2)\rceil \end{aligned} \qquad \text{式 (4.5)}$$

定义 4.3 映射T^{M_2}具体定义如下：

$$\begin{aligned} &T^{M_2}: C\to C_2 \\ &(x_k,y_k)\mapsto(x_{tk},y_{tk})=T^{M_2}(x_k,y_k)=\lceil((x_k+1)/2,(y_k+1)/2)\rceil \end{aligned} \qquad \text{式 (4.6)}$$

中国知网 https://www.cnki.net

定义 4.4 子 DEM 地图M_1坐标集合C_1向过渡坐标集族A的映射定义为$\tilde{T}^{M_1}$，具体为：

$$\begin{aligned}&\tilde{T}^{M_1}:\ C_1 \to A\\&(x_{ok},y_{ok}) \mapsto A_{t1}=\tilde{T}^{M_1}(x_{ok},y_{ok})=S_1^{M_1}\times S_2^{M_1}\end{aligned} \quad \text{式 (4.7)}$$

A 以C_1为指标集，记为

$$A=\left\{A_{t1}\right\}_{t1\in C_1} \quad \text{式 (4.8)}$$

$S_1^{M_1}\times S_2^{M_1}$为 Descartes 乘积集合，$S_1^{M_1}$、$S_2^{M_1}$具体定义为：

$$S_1^{M_1}=\left\{x\mid x\in\left[2x_{ok}-1,\min(2x_{ok},n)\right]\cap\mathbb{Z}^+\right\} \quad \text{式 (4.9)}$$

$$S_2^{M_1}=\left\{y\mid y\in\left[2y_{ok}-1,\min(2y_{ok},m)\right]\cap\mathbb{Z}^+\right\} \quad \text{式 (4.10)}$$

定义 4.5 子 DEM 地图M_2坐标集合C_2向过渡坐标集族B的映射定义为$\tilde{T}^{M_2}$，具体为：

$$\begin{aligned}&\tilde{T}^{M_2}:\ C_2 \to B\\&(x_{tk},y_{tk}) \mapsto B_{t2}=\tilde{T}^{M_2}(x_{tk},y_{tk})=S_1^{M_2}\times S_2^{M_2}\end{aligned} \quad \text{式 (4.11)}$$

B 以C_2为指标集，记为

$$B=\left\{B_{t2}\right\}_{t2\in C_2} \quad \text{式 (4.12)}$$

$S_1^{M_2}$、$S_2^{M_2}$具体定义为：

$$S_1^{M_2}=\left\{x\mid x\in\left[2x_{tk}-2,\min(2x_{tk}-1,n)\right]\cap\mathbb{Z}^+\right\} \quad \text{式 (4.13)}$$

$$S_2^{M_2}=\left\{y\mid y\in\left[2y_{tk}-2,\min(2y_{tk}-1,m)\right]\cap\mathbb{Z}^+\right\} \quad \text{式 (4.14)}$$

通过定义 4.4 与定义 4.5，分别建立了子 DEM 地图M_1坐标集合C_1与子 DEM 地图M_2坐标集合C_2向过渡坐标集族A、B的映射，由于两子地图定义映射关系时参数略有不同，因此两子地图的栅格粒度将扩大一倍并在空间上形成交错，从而得到如下定理：

定理 4.1：若子 DEM 地图M_1中某一栅格区域与子 DEM 地图M_2中某一栅格区域共同在原始 DEM 地图M平面区域D中的映射存在交集，那么该交集区域唯一确定，其在原始 DEM 地图M中的坐标可由过渡坐标集族A与B唯一确定，即:

$$\begin{cases}\exists\, t_1\in C_1, t_2\in C_2: A_{t1}\cap B_{t2}\neq\varnothing\\(x_k,y_k)=A_{t1}\cap B_{t2}\end{cases} \quad \text{式 (4.15)}$$

至此，原始 DEM 地图与各子 DEM 地图中任一位置坐标转换关系确定，任给各地图中任一位置坐标，均可得到对应的原始地图坐标或过渡坐标集。下面，对各子 DEM 地图与陡

中国知网 https://www.cnki.net

峭度地图中对应位置坐标赋值，完成子 DEM 地图与其对应的陡峭度地图的建立。

若子 DEM 地图中某一位置坐标为(x_s, y_s)，则其对应的子 DEM 地图中的高程值为：

$$H_s = M_s(x_s, y_s) = \frac{\mathrm{sumH}\left(\tilde{T}^M(x_s, y_s)\right)}{\mathrm{size}\left(\tilde{T}^M(x_s, y_s)\right)} \quad \text{式 (4.16)}$$

对应的陡峭度地图中的值为：

$$\sigma_s = M_{\sigma s}(x_s, y_s) = \sqrt{\frac{\sum_{i=1}^{\mathrm{size}\left(\tilde{T}^M(x_s, y_s)\right)} \left(H_s - \mathrm{singleH}_i\left(\tilde{T}^M(x_s, y_s)\right)\right)^2}{\mathrm{size}\left(\tilde{T}^M(x_s, y_s)\right)}} \quad \text{式 (4.17)}$$

式（4.17）中：$\mathrm{sumH}(X)$ 表示 X 中所有位置坐标在原始 DEM 地图 M 中对应的高程值之和；$\mathrm{size}(X)$ 表示 X 中位置坐标个数；$\mathrm{singleH}_i(X)$ 表示 X 中第 i 个位置坐标在原始 DEM 地图 M 中的高程值（**注**：$i \in [1, \mathrm{size}(X)]$）；$M_s$ 与 $M_{\sigma s}$ 为子 DEM 地图 M_1 或 M_2 与其对应的陡峭度地图 $M_{\sigma 1}$ 或 $M_{\sigma 2}$，$\tilde{T}^M$ 为对应的映射关系 $\tilde{T}^{M_1}$ 或 $\tilde{T}^{M_2}$。

以上相关计算过程如图 4.3 所示。

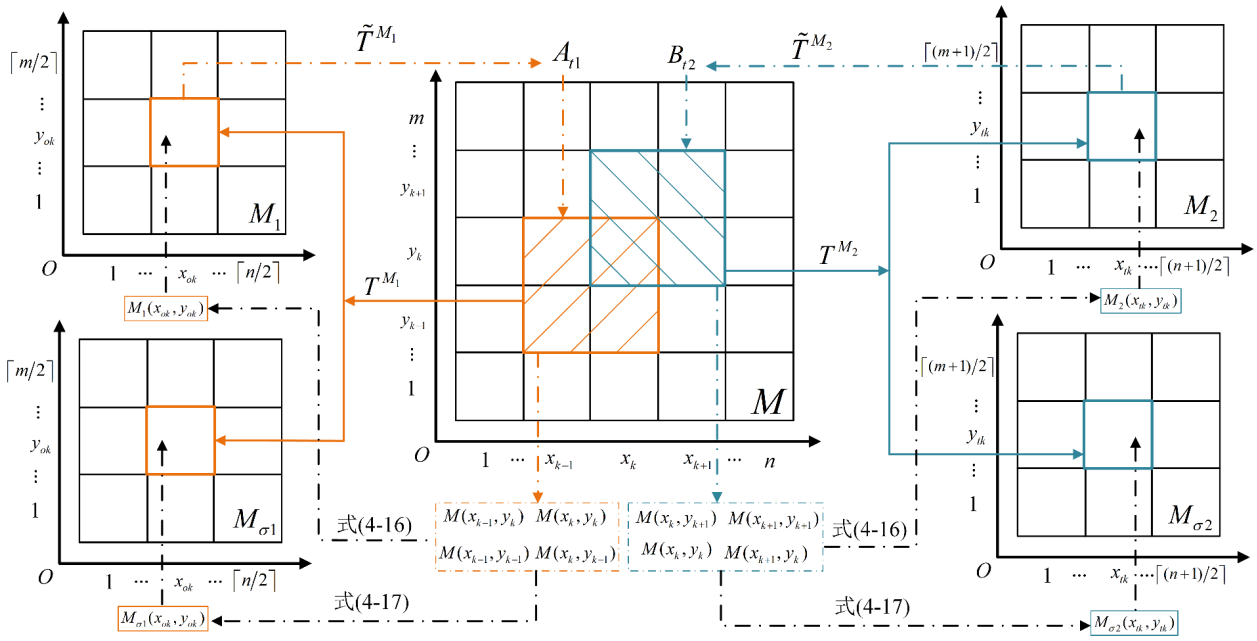


图 4.3 错栅格粒度地图模型计算过程

Figure 4.3 Interleaved granularity map model computation process

建立子 DEM 地图 M_1 与对应的陡峭度地图 $M_{\sigma 1}$ 及子 DEM 地图 M_2 与对应的陡峭度地图 $M_{\sigma 2}$ 的伪代码分别如算法 1 及算法 2 所示，二者流程相似，仅参数略有差别，应当注意区分。

中国知网 https://www.cnki.net

Algorithm 1 MakeSubmapOne

Input: Original map M
Output: Submap M_1 and Steepness map $M_{\sigma 1}$

function MakeSubmapOne(M)
  $[m, n] \leftarrow$ size(M)
  $M_1 \leftarrow$ Empty matrix
  $M_{\sigma 1} \leftarrow$ Empty matrix
  for $i = 1$ to $\lceil m/2 \rceil$ **do**
    for $j = 1$ to $\lceil n/2 \rceil$ **do**
      $CoordinateSet \leftarrow$ GetSubmapOneCoordinates(i, j, m, n)
      $M_1(i, j) \leftarrow$ The average of $CoordinateSet$
      $M_{\sigma 1}(i, j) \leftarrow$ The variance of $CoordinateSet$
    end for
  end for
  return M_1, $M_{\sigma 1}$
end function

function GetSubmapOneCoordinates(i, j, m, n)
  $CoordinateSet \leftarrow$ Empty set
  for $x = 2i - 1$ to $2i$ **do**
    for $y = 2j - 1$ to $2j$ **do**
      if $x \in [1, m]$ and $y \in [1, n]$ **then**
        $CoordinateSet \leftarrow CoordinateSet \cup \{(x, y)\}$
      end if
    end for
  end for
  return $CoordinateSet$
end function

Algorithm 2 MakeSubmapTwo

Input: Original map M
Output: Submap M_2 and Steepness map $M_{\sigma 2}$

function MakeSubmapTwo(M)
  $[m, n] \leftarrow$ size(M)
  $M_2 \leftarrow$ Empty matrix
  $M_{\sigma 2} \leftarrow$ Empty matrix
  for $i = 1$ to $\lceil (m + 1)/2 \rceil$ **do**
    for $j = 1$ to $\lceil (n + 1)/2 \rceil$ **do**
      $CoordinateSet \leftarrow$ GetSubmapTwoCoordinates(i, j, m, n)
      $M_2(i, j) \leftarrow$ The average of $CoordinateSet$
      $M_{\sigma 2}(i, j) \leftarrow$ The variance of $CoordinateSet$
    end for
  end for
  return M_2, $M_{\sigma 2}$
end function

function GetSubmapTwoCoordinates(i, j, m, n)
  $CoordinateSet \leftarrow$ Empty set
  for $x = 2i - 2$ to $2i - 1$ **do**
    for $y = 2j - 2$ to $2j - 1$ **do**
      if $x \in [1, m]$ and $y \in [1, n]$ **then**
        $CoordinateSet \leftarrow CoordinateSet \cup \{(x, y)\}$
      end if
    end for
  end for
  return $CoordinateSet$
end function

中国知网 https://www.cnki.net

基于算法 1 及算法 2，对图 2.4 所示 DEM 地图建立错栅格粒度地图模型如图 4.4 所示，可得到两幅子 DEM 地图以及对应的陡峭度地图。

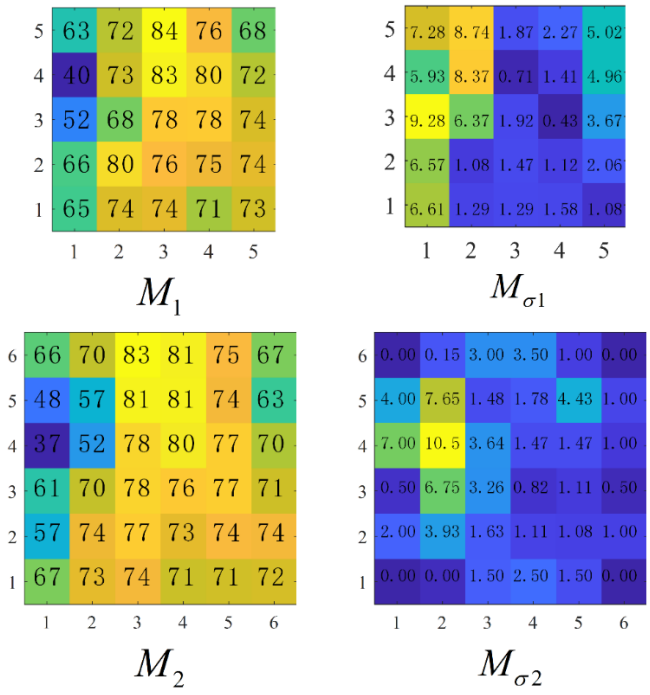


图 4.4 错栅格粒度地图分离实例

Figure 4.4 Example of interleaved granularity map model

4.2 IGA*算法

A*算法通过定义代价函数引导完成路径的规划，是一种典型的基于节点的启发式路径规划算法。A*算法开始规划路径前将会定义两个列表，一个开启列表（Open-List），存储待扩展节点；一个关闭列表（Closed-List），存储已扩展节点与环境地图障碍点。通过不断更新两个列表，从开启列表中选择代价函数 $F(n)$ 最小值的节点进行下一步扩展，直到搜索到路径目标点，完成路径搜索，规划出最短路径。

A*算法代价函数可表示为：

$$F(n)=G(n)+H(n) \tag{4.18}$$

式（4.18）中：$G(n)$ 为路径起始点 S 至当前节点 n 的实际代价值；$H(n)$ 为当前节点 n 至路径目标点 G 的预估代价值；二者共同组成了当前节点 n 的总代价值 $F(n)$。

本章基于所述的错栅格粒度地图模型及 A*算法基本理论，提出一种能在 DEM 地图下高效、安全实现三维复杂非平坦地形路径规划的错栅格粒度 A*（IGA*）路径规划算法。

4.2.1 地形通过性评估

结合三维环境下地形地势特点，结合错栅格粒度地图模型，本文从地形坡度、地面阶跃高度、地形陡峭度三个方面对路径节点进行通过性评估，以此建立 IGA*算法代价函数。

中国知网 https://www.cnki.net

4.2.1.1 地形坡度

最大爬坡度作为车辆重要的动力性评价指标，若坡度过大，车辆将无法通过。由于 DEM 地图是连续的，地图上各地形节点相互影响，相互制约，如图 4.5 所示。

H_1	H_2	H_3
H_4	n	H_6
H_7	H_8	H_9

图 4.5 地形坡度计算关系

Figure 4.5 Relationships for calculating terrain slopes

因此考虑地形坡度影响时应当综合当前地形节点周围其他连续地形的影响，本文采用对 DEM 误差具有一定平滑和过滤作用的三阶反距离平方权差分来计算地形坡度，即

$$\theta_n = \arctan\sqrt{f_x^{\,2} + f_y^{\,2}} \qquad \text{式 (4.19)}$$

式（4.19）中，f_x 为横坐标轴方向高度变化量，f_y 为纵坐标轴方向高度变化量。具体计算为

$$f_x = \left(H_3 - H_1 + 2(H_6 - H_4) + H_9 - H_7\right)/(8\delta) \qquad \text{式 (4.20)}$$

$$f_y = \left(H_7 - H_1 + 2(H_8 - H_2) + H_9 - H_3\right)/(8\delta) \qquad \text{式 (4.21)}$$

式（4.20）（4.21）中：H 为各地形节点高程值，δ 为栅格粒度。

地形坡度代价函数记为：

$$g_{\text{slope}}(\theta_n) = \begin{cases} \dfrac{\theta_n}{\theta_{\max}} & \theta_n \le \theta_{\max} \\ \infty & \theta_n > \theta_{\max} \end{cases} \qquad \text{式 (4.22)}$$

式（4.22）中，$\theta_{\max}$ 为车辆能通过的最大临界坡度。

4.2.1.2 地面阶跃高度

上述地形坡度，在一定程度上能反映出两地形节点之间的高度差，但现实情况下往往存在坡度满足通过条件，高度差过大，导致车辆产生跌落或间隙失效等危险工况。因此，对路径代价进行计算时应当考虑两地形节点间的地面阶跃高度值，即：

$$\Delta h_n = \frac{\left|H_n - H_{n-1}\right|}{\delta D(n-1, n)} \qquad \text{式 (4.23)}$$

中国知网 https://www.cnki.net

式（4.23）中，H_n为节点 n 的地形高程值，H_{n-1}为节点$n-1$的地形高程值；$D(n-1,n)$为节点$n-1$到节点 n 两路径点的 xy 平面坐标距离，具体计算为：

$$D(n-1,n)=\sqrt{(x_n-x_{n-1})^2+(y_n-y_{n-1})^2} \quad \text{式 (4.24)}$$

地面阶跃高度代价函数记为：

$$g_{\text{stepwise}}(\Delta h_n)=\begin{cases}\dfrac{\Delta h_n}{\Delta h_{\max}}, & \Delta h_n \le \Delta h_{\max}\\ \infty, & \Delta h_n > \Delta h_{\max}\end{cases} \quad \text{式 (4.25)}$$

式（4.25）中，$\Delta h_{\max}$为车辆能通过的最大临界阶跃高度。

4.2.1.3 地形陡峭度

车辆行驶路径的地面平坦程度会影响车辆的通过性、平顺性、操稳性，乃至于安全性。本文选择地形陡峭度作为车辆行驶路径地面平坦程度的评价指标。得益于上述 4.1 节中错栅格粒度地图模型的建立，本文将直接使用各子地图对应的陡峭度地图中各地形节点值σ_n作为陡峭度值，地面陡峭度代价函数记为：

$$g_{\text{steep}}(\sigma_n)=\begin{cases}\dfrac{\delta^{-1}\sigma_n}{\sigma_{\max}}, & \delta^{-1}\sigma_n \le \sigma_{\max}\\ \infty, & \delta^{-1}\sigma_n > \sigma_{\max}\end{cases} \quad \text{式 (4.26)}$$

式（4.26）中，$\sigma_{\max}$为车辆能通过的最大临界陡峭度。

4.2.2 IGA*算法代价函数

通过对路径节点进行地形坡度、地面阶跃高度、地形陡峭度三个方面通过性评估，本节为 IGA*算法建立以下代价函数：

$$f(n)=g(n)+h(n) \quad \text{式 (4.27)}$$

式（4.27）中

$$g(n)=g(n-1)+g(n-1,n) \quad \text{式 (4.28)}$$

$$g(n-1,n)=L(n-1,n)\left(1+g_{\text{terrain}}(n)\right) \quad \text{式 (4.29)}$$

式（4.29）中，$L(n-1,n)$为节点$n-1$到节点 n 的欧几里得距离，$g_{\text{terrain}}(n)$为节点 n 的地形代价函数分别计算如下：

$$L(n-1,n)=\sqrt{\left((x_n-x_{n-1})^2+(y_n-y_{n-1})^2\right)\delta^2+(H_n-H_{n-1})^2} \quad \text{式 (4.30)}$$

中国知网 https://www.cnki.net

$$g_{\text{terrain}}(n)=e_1 g_{\text{slope}}(\theta_n)+e_2 g_{\text{stepwise}}(\Delta h_n)+e_3 g_{\text{steep}}(\sigma_n) \quad \text{式 (4.31)}$$

式（4.31）中，e_1、e_2、e_3 分别为地形坡度、地面阶跃高度、地形陡峭度的权重，三者之和等于 1。

为保证算法效率，预估代价函数应快速引导算法完成路径规划任务，此时若再对地形坡度、地面阶跃高度进行预估计算意义不大，反而会降低算法效率。而由于各地形节点的地面陡峭度在错栅格粒度地图中已经计算完毕，并存储在各子 DEM 地图对应的陡峭度地图中，无需计算，仅需提取对应的值代入即可，因此本文预估代价函数为：

$$h(n)=L(n,G)\left(1+e_3 g_{\text{steep}}(\sigma_n)\right) \quad \text{式 (4.32)}$$

4.2.3 代价函数的一致性与可纳性

为保证算法的高效性及路径最优，IGA*算法代价函数应当满足可纳性、一致性条件，因此有如下定理：

定理 4.2：IGA*算法代价函数满足可纳性条件：

$$h(n)\le g(G)-g(n) \quad \text{式 (4.33)}$$

证明：由式(4.29)与式(4.32)可知

$$g(G)-g(n)=\sum_{i=n+1}^{G} L(i-1,i)\left(1+g_{\text{terrain}}(i)\right) \quad \text{式 (4.34)}$$

$$h(n)=L(n,G)\left(1+e_3 g_{\text{steep}}(\sigma_n)\right)=\int_0^{L(n,G)}\left(1+e_3 g_{\text{steep}}(\sigma_n)\right)dl \quad \text{式 (4.35)}$$

当当前节点距离目标点最短直线距离的路径为最优路径时，实际路径距离与预估距离二者相等，否则实际路径距离大于预估距离，即

$$\sum_{i=n+1}^{G} L(i-1,i)\ge\int_0^{L(n,G)} dl \quad \text{式 (4.36)}$$

且由式(4.31)可知

$$g_{\text{terrain}}(n)-e_3 g_{\text{steep}}(\sigma_n)\ge 0 \quad \text{式 (4.37)}$$

联合式(4.34)~(4.37)，即有

$$h(n)\le g(G)-g(n) \quad \text{式 (4.38)}$$

定理 4.2 得证。

定理 4.3：IGA*算法代价函数满足一致性条件：

$$h(n)\le\left(g(n+1)-g(n)\right)+h(n+1) \quad \text{式 (4.39)}$$

中国知网 https://www.cnki.net

证明：根据式(4.27)得

$$f(n+1)=g(n+1)+h(n+1)=g(n)+g(n,n+1)+h(n)-h(n,n+1) \quad \text{式 (4.40)}$$

由定理 4.2 可知 $g(n,n+1)\geq h(n,n+1)$，故

$$f(n)\leq f(n+1) \quad \text{式 (4.41)}$$

即

$$h(n)\leq\big(g(n+1)-g(n)\big)+h(n+1) \quad \text{式 (4.42)}$$

定理 4.3 得证。

4.2.4 IGA*算法策略

在 4.1 节中，本文建立了错栅格粒度模型，该模型包括两个子 DEM 地图以及对应的两个陡峭度地图。其中，陡峭度地图已应用于 IGA*算法代价函数中，在算法规划过程中可直接使用，无需重复计算，在一定程度上保证了算法的高效性。而对于两个子 DEM 地图，二者互为交错，对环境信息的描述整体类似，但又存在差异，该差异部分即表示此区域地形变化较为复杂，对路径安全性影响较大，不容忽略。因此，考虑路径的最优性与安全性，IGA*算法将在两个子 DEM 地图中进行规划，并规划出两条子路径。对于地形相对平坦的区域，规划出的两子路径将较为一致，而对于地形较为复杂的区域，由于对应的子 DEM 地图描述存在差异，也将导致子路径出现分歧，该分歧部分在一定程度上客观反映了此区域内地形的复杂性，故为保证路径最优性，此区域内两子路径均应当予以舍弃。综上及前文所述错栅格粒度地图模型，本文建立以下 IGA*算法策略，算法伪代码如算法 3 所示。

需要注意的是，算法 3 伪代码中“IGA*I”与“IGA*II”的基本流程及算法体系与经典 A*算法完全一致，主要区别在于路径节点代价值的计算函数为 4.2.2 节中本文所建立的代价函数式（4.27）。其中，两子算法区别在于，“IGA*I”算法用于在子 DEM 地图中规划子路径，路径节点代价计算时考虑路径节点地形粗糙度，粗糙度的值为子 DEM 地图对应的粗糙度地图中的值，而“IGA*II”算法主要用于两子路径 *path*1、*path*2 转换归一化后，由于子路径分歧，针对分歧部分舍弃导致路径中间出现断点的情况，对初始路径 *Path* 进行缺值补齐，以此保证路径的连续性，与“IGA*I”算法不同的是，在计算路径节点代价时，路径节点地形粗糙度 σ_n 统一取 0。执行“IGA*II”算法进行缺值补齐操作的判别条件为：

$$D(i,i+1)\neq 1 \,\&\, D(i,i+1)\neq\sqrt{2} \quad \text{式 (4.43)}$$

当初始路径 *Path* 中两路径节点 *i*，*i*+1 满足上式条件时，即证明两路径点在二维平面坐标系下非邻域关系，两路径点间存在其他路径点，因此需要执行上述条件的判别，进而对初始路径 *Path* 进行缺值补齐，规划出一条完整的路径 *PATH*。

中国知网 https://www.cnki.net

Algorithm 3 IGA*

Input: M, P_s, P_g
Output: $PATH$

function IGA*(M, P_s, P_g)
  $[M_1, M_{\sigma 1}] \leftarrow$MakeSubmapOne$(M)$
  $[M_2, M_{\sigma 2}] \leftarrow$MakeSubmapTwo$(M)$
  $[P_{os}, P_{og}] \leftarrow T^{M_1}[P_s, P_g]$
  $[P_{ts}, P_{tg}] \leftarrow T^{M_2}[P_s, P_g]$
  $path1 \leftarrow$ IGA*I$(M_1, M_{\sigma 1}, P_{os}, P_{og})$
  $path2 \leftarrow$ IGA*I$(M_2, M_{\sigma 2}, P_{ts}, P_{tg})$
  $\{A_{t1}\}_{t1 \in pah1} \leftarrow \tilde{T}^{M_1}(path1)$
  $\{B_{t2}\}_{t2 \in pah2} \leftarrow \tilde{T}^{M_2}(path2)$
  $Path \leftarrow \bigcup_{(t1,t2)} (A_{t1} \bigcap B_{t2})$
  for $i = 1 \rightarrow size(Path) - 1$ **do**
    if $D(Path(i), Path(i+1)) \neq 1 \& D(Path(i), Path(i+1)) \neq \sqrt{2}$ **then**
      $Missing - values$ of $Path(i)$ and $Path(i+1) \leftarrow$IGA*II$(M, Path(i), Path(i+1))$
    end if
  end for
  $PATH \leftarrow$ All $Missing - values$ are added to $Path$
  return $PATH$
end function

function IGA*I(M, M_σ, P_s, P_g)
  Using the improved heuristic function
  In M, the $path$ of P_s to P_g is planned by A*
  return $path$
end function

function IGA*II(M, P_s, P_g)
  Using the improved heuristic function
  $\sigma_n \equiv 0$
  In M, the $path$ of P_s to P_g is planned by A*
  return $path$
end function

4.3 仿真分析评价

为验证本文所建立的错栅格粒度地图模型的可行性以及基于此模型所提出的 IGA*算法路径规划方法的有效性与普适性，下面进行仿真实验分析。为切实比较 IGA*算法的性能，本文选择与文献[82]、文献[85]所改进算法进行对比分析。其中，文献[82]通过将车辆滚动阻力系数添加至 A*算法代价函数中，完成非平坦环境下无人车辆路径规划，而文献[85]考虑轮式机器人非平坦地形下通过性，对 A*算法代价函数进行了改进，二者所研究的对象、环境地形、算法与本文一致，对比分析更显公允。

4.3.1 有效性分析

针对 IGA*算法的有效性，本文将随机选择四种不同的环境对 A*算法、文献[82]、文献[85]所改进的 A*算法以及本文 IGA*算法进行仿真实验测试和评价，其中计算仿真的软件环境为 Matlab R2019b；计算机主要配置为：Windows 10 操作系统，主频为 3.40GHz 的 Intel(R) Core(TM) i7.6700 CPU，内存 16GB。四种仿真实验环境地图数据来源于美国国家航空航天局（National Aeronautics and Space Administration，NASA）官网所公布的全球 DEM 数据集

中国知网 https://www.cnki.net

NASADEM_HGT v001[98]，其中，Map1、Map2 分辨率为 600×600，Map3、Map4 分辨率为 1200×1200。为切实比较四种算法的性能，本文选择对比 3 种评价指标，即单位路径高程变化；单位路径地面陡峭度变化；算法规划时间。其中，依据图 4.5 所示的地形节点位置关系地面陡峭度定义为：

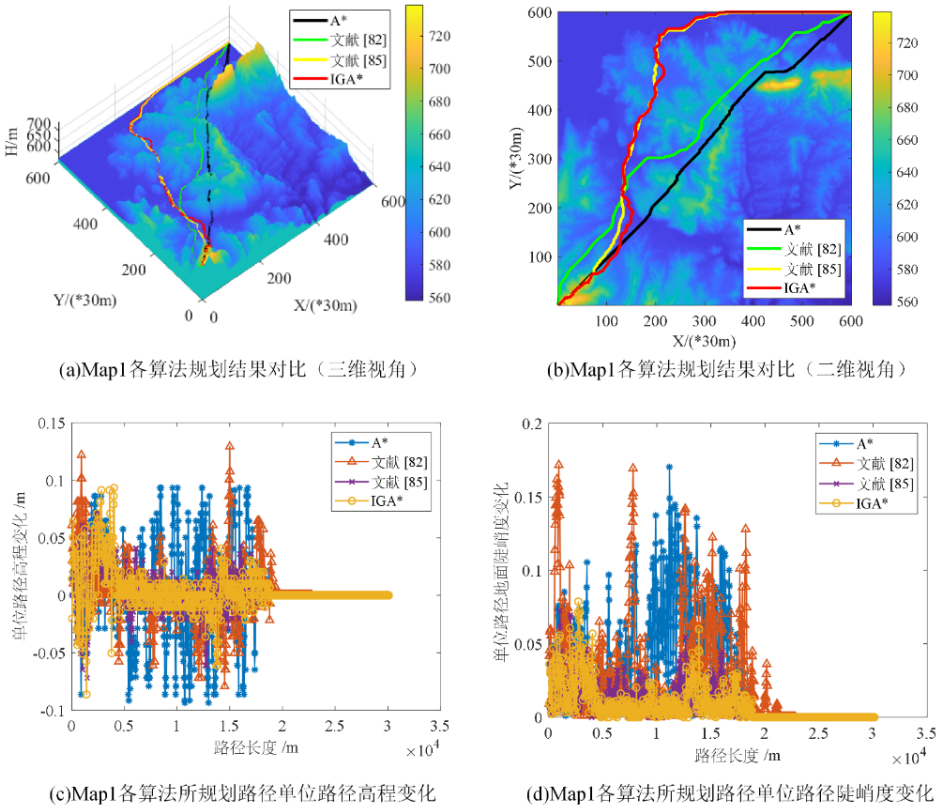
$$\hat{\sigma}_n = \frac{1}{3\delta}\sqrt{\sum_{k=1}^{9}\left(\sum_{k=1}^{9} H_k/9 - H_k\right)^2} \qquad \text{式 (4.44)}$$

针对上述四种仿真实验环境，选择各地图原点处为路径起始点，对角线最远端为路径目标点，分别使用四种算法进行路径规划仿真分析。选择四轮越野无人车辆作为仿真对象，其中，IGA*算法参数取值如表 4.1 所示。各地图环境不同算法规划的结果及对比如图 4.6~图 4.9 所示，各算法仿真结果评价指标对比如表 4.2 所示。

表 4.1 IGA*算法参数取值

Table 4.1 IGA* algorithm parameter values

参数	值	参数	值
θ_{max}	0.20	e_1	0.25
$\triangle h_{max}$	0.50	e_2	0.40
σ_{max}	0.33	e_3	0.35



(a)Map1各算法规划结果对比（三维视角）

(b)Map1各算法规划结果对比（二维视角）

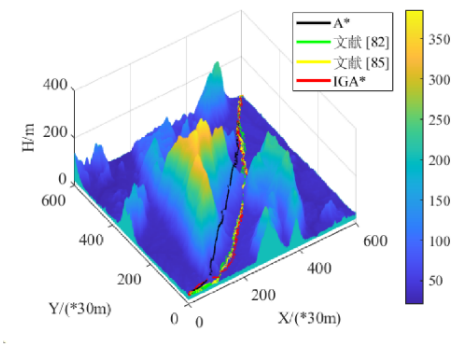
(c)Map1各算法所规划路径单位路径高程变化

(d)Map1各算法所规划路径单位路径陡峭度变化

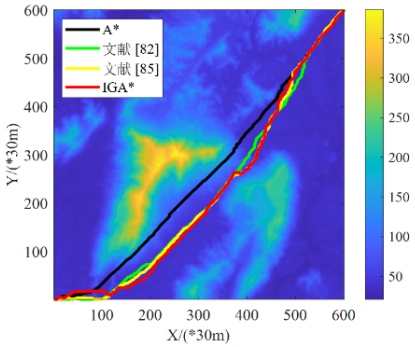
图 4.6 Map1 各算法实验结果对比

Figure 4.6 Comparison of the test results of each algorithm in Map1

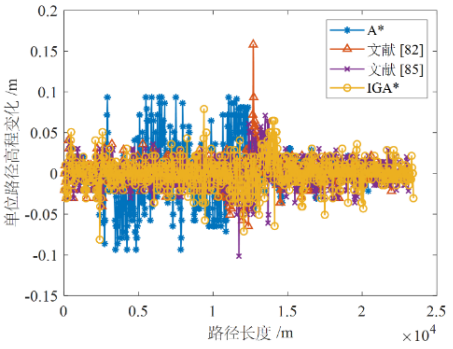
中国知网 https://www.cnki.net



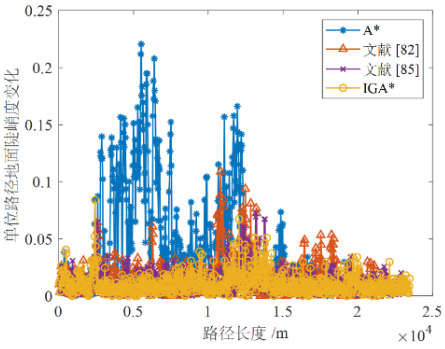
(a)Map2各算法规划结果对比（三维视角）



(b)Map2各算法规划结果对比（二维视角）



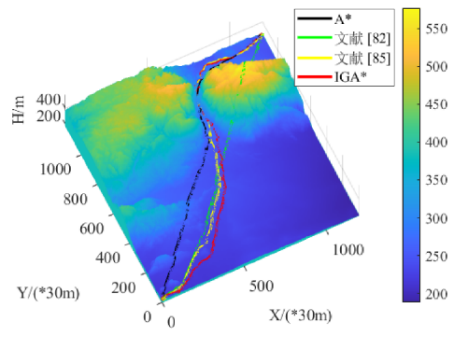
(c)Map2各算法所规划路径单位路径高程变化



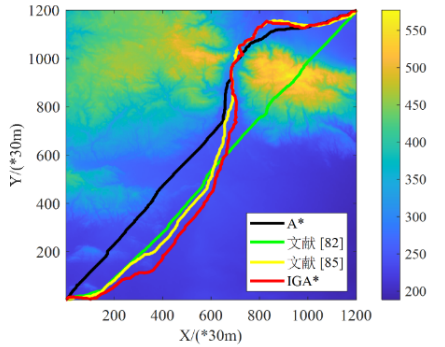
(d)Map2各算法所规划路径单位路径陡峭度变化

图 4.7 Map2 各算法实验结果对比

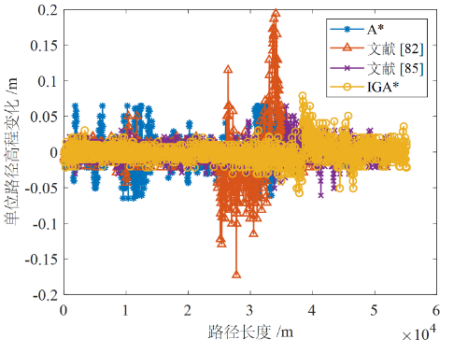
Figure 4.7 Comparison of the test results of each algorithm in Map2



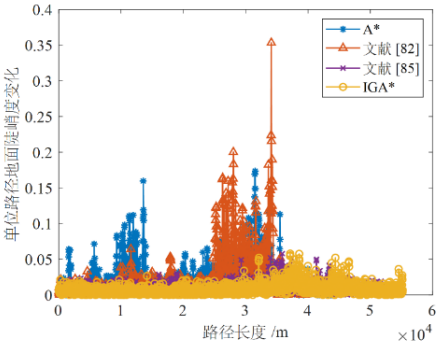
(a)Map3各算法规划结果对比（三维视角）



(b)Map3各算法规划结果对比（二维视角）



(c)Map3各算法所规划路径单位路径高程变化

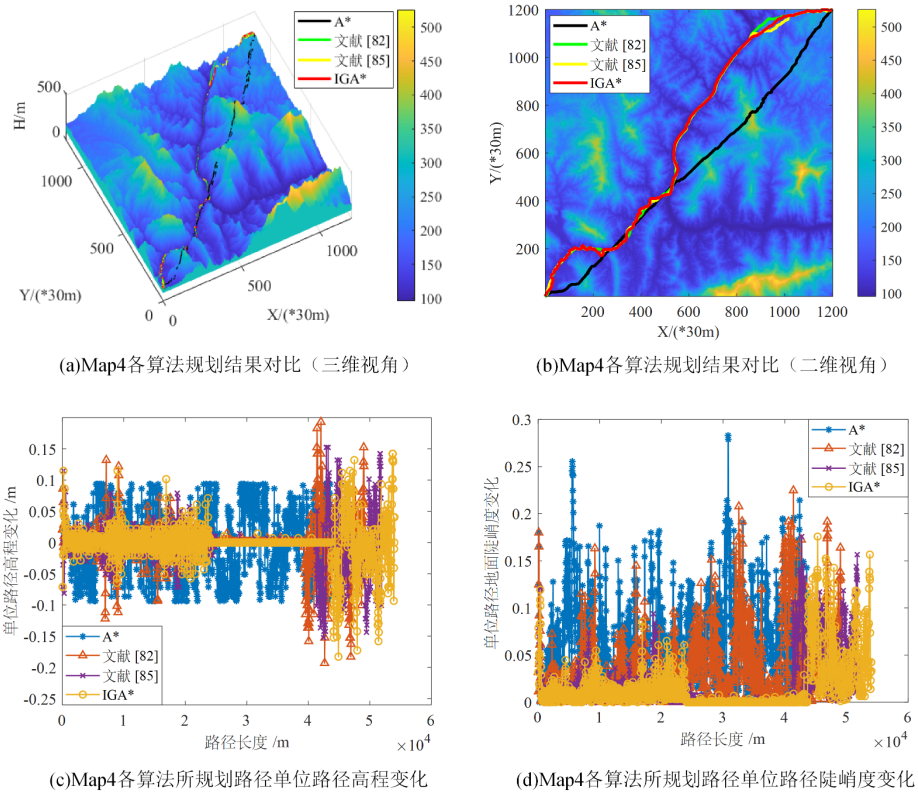


(d)Map3各算法所规划路径单位路径陡峭度变化

图 4.8 Map3 各算法实验结果对比

Figure 4.8 Comparison of the test results of each algorithm in Map3

中国知网 https://www.cnki.net



(a)Map4各算法规划结果对比（三维视角）

(b)Map4各算法规划结果对比（二维视角）

(c)Map4各算法所规划路径单位路径高程变化

(d)Map4各算法所规划路径单位路径陡峭度变化

图 4.9 Map4 各算法实验结果对比

Figure 4.9 Comparison of the test results of each algorithm in Map4

结合表 4.2 与图 4.6~图 4.9 的结果不难看出，本文提出的 IGA*算法相较于传统 A*算法无论是在规划效率还是路径质量方面都有较大提升。其中，在路径质量方面，得益于在代价函数计算中加入了对坡度、地面阶跃高度以及地面陡峭度的衡量，在同一环境下，IGA*算法在路径规划过程中对坡度大小、地面高度落差以及地面陡峭度较为敏感，算法能有效避开不利于路径质量的路径点。

IGA*算法与传统 A*算法相比，所规划出的路径单位路径高程变化平均减少 61.2%，最多可减少 73.5%，单位路径地面陡峭度变化平均减少 73.2%，最优时减少 82.9%。同时，通过数据比对分析，不难发现文献[82]、文献[85]所改进 A*算法较传统 A*算法在路径质量方面也均取得了一定的优化效果。但是，本文的 IGA*算法与二者相比，优化效果更为明显，在单位路径高程变化评价指标方面，IGA*算法相较于二者平均分别减少了 20.1%、16.3%，在单位路径地面陡峭度变化评价指标方面，平均分别减少了 56.5%、19.7%，算法所规划路径质量得到了进一步提升。IGA*算法的路径质量均优于另外三种算法，更有利于无人车辆行驶过程中的通过性、稳定性以及对于乘员的舒适性体验。

在算法效率方面，IGA*算法相较于 A*算法有了大幅提升，4 个环境中平均减少了 65.5%的搜索时间，最大可减少 88.7%，算法效率明显提升，且通过对比不同大小地图效率提升程度，可以发现随着地图由 600×600 增大至 1200×1200，相同地图规模下算法平均减少的时间由 51.4%增大至 79.8%，算法效率提升效果显著。

中国知网 https://www.cnki.net

表 4.2 各算法实验结果评价指标对比

Table 4.2 Comparison of evaluation indexes of the test results of each algorithm

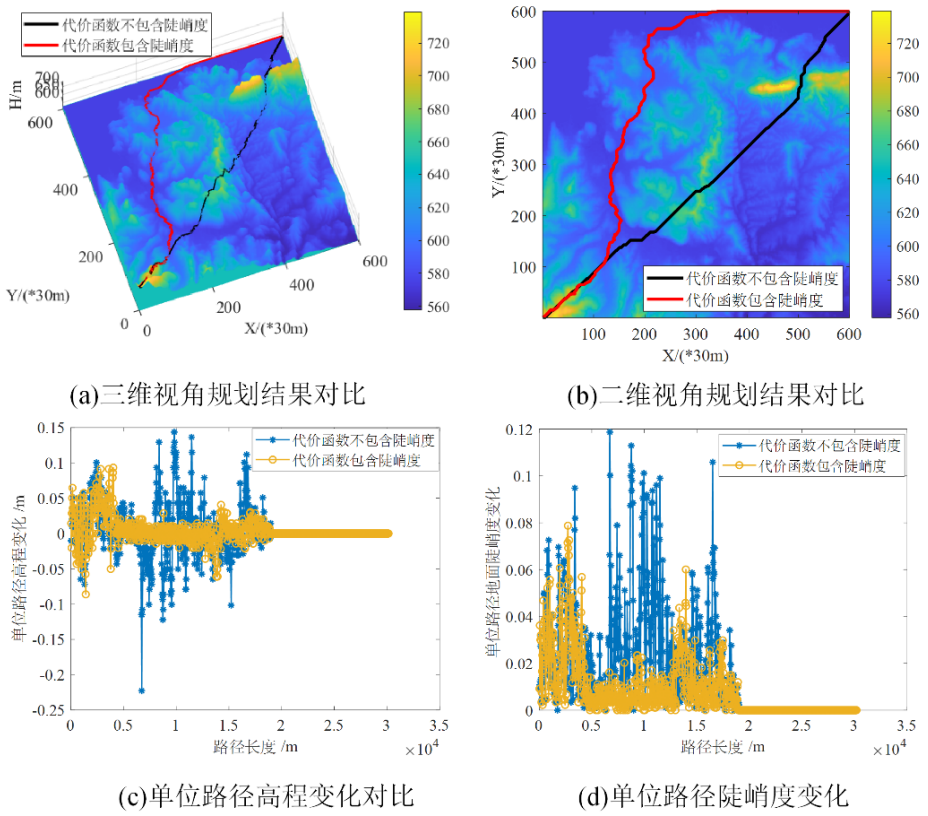
仿真地图	算法	规划时间/s	单位路径高程变化/m		单位路径地面陡峭度变化量	
			绝对值最大值	绝对值平均值	最大值	平均值
Map1	A*	11.61	0.093	0.034	0.17	0.041
	文献[82]	26.08	0.129	0.016	0.172	0.029
	文献[85]	97.01	0.072	0.01	0.071	0.009
	IGA*	4.11	0.093	0.009	0.078	0.007
Map2	A*	9.66	0.093	0.023	0.221	0.041
	文献[82]	17.42	0.158	0.009	0.109	0.015
	文献[85]	72.85	0.101	0.013	0.072	0.013
	IGA*	5.98	0.081	0.011	0.084	0.011
Map3	A*	232.24	0.064	0.014	0.173	0.02
	文献[82]	317.61	0.193	0.017	0.353	0.022
	文献[85]	744.83	0.064	0.009	0.057	0.01
	IGA*	67.72	0.079	0.007	0.057	0.008
Map4	A*	152.43	0.093	0.045	0.283	0.064
	文献[82]	278.97	0.193	0.014	0.225	0.035
	文献[85]	670.07	0.152	0.017	0.175	0.019
	IGA*	17.15	0.182	0.014	0.175	0.015

与文献[82]所改进的 A*算法相比，IGA*算法在进一步提升路径质量的基础上，搜索时间较之节省了 65.7%至 93.8%不等。同时，在四个地图环境中，文献[85]所改进的 A*算法与 IGA*算法均有效避开高度较高的区域，选择平坦区域进行规划，二者所规划出的路径较为一致，但在算法效率上，IGA*算法平均规划时间仅为其规划时间的 6%，这是由于文献[85]所改进 A*算法只针对代价函数计算进行了优化，未对算法策略进行改进，从而导致算法在路径搜索过程中需要进行大量复杂计算，维持路径代价节点列表，使得其相较于 A*算法在路径质量提升的同时，路径搜索时间大幅增加，造成算法效率低下，具有一定的局限性。而本文所提 IGA*算法从地图理论模型描述、算法策略以及代价函数计算三方面均进行改进优化，使得算法兼顾路径质量与算法效率，能同时保证二者的最优性。

对于本文所提出的错栅格粒度地图模型，在本章第二节中已详细论述其在 IGA*算法中的核心作用，其一是基于该模型中的陡峭度地图，直接提取路径点的陡峭度，并将其加入 IGA*算法代价函数中计算路径代价，引导算法规划时避开陡峭度较大的区域。下面讨论该

中国知网 https://www.cnki.net

陡峭度对于路径规划的结果影响。在 Map1 中，将 IGA*算法代价函数中去除地面陡峭度代价函数，不再考虑地面陡峭度对于路径规划结果的影响，规划结果如图 4.10 所示。



(a)三维视角规划结果对比　(b)二维视角规划结果对比

(c)单位路径高程变化对比　(d)单位路径陡峭度变化

图 4.10 在 Map1 中去除陡峭度前后规划结果对比

Figure 4.10 Comparison of planning results before and after removing steepness in Map1

从结果对比图中不难看出，在去除陡峭度代价函数后，路径规划结果产生了较大改变，路径长度有所缩短，但路径整体陡峭度急剧攀升，单位路径陡峭度平均值增大至 0.026，较原路径增大了 188%。由于去除陡峭度函数的影响进而也导致平均路径高程变化这一指标相较于原路径也增大了 200%，使得路径安全性、最优性下降。这一结果也从侧面印证了错栅格粒度地图中的陡峭度地图对 IGA*算法路径规划结果起到了至关重要的作用。

而错栅格粒度地图另一重要作用则是通过其建立的两子 DEM 地图分别规划后归一化生成初始路径，并在此路径基础上规划出最终路径。在 4.2.4 节中，本文讨论了通过生成两子路径进而规划出初始路径的重要意义。为进一步验证该理论，同样选择在 Map1 中，分别规划出子路径 1、子路径 2 以及最终路径，规划结果对比如图 4.11 所示。

可以看出，通过两个子地图规划出的两条子路径走向大致相同，个别复杂区域出现分歧，这是由于两子地图建立过程中参数有所差异而导致的。对于路径中相同的部分，直接归一化转化后可生成初始路径，对于分歧部分则在初始路径上重新规划，缺值补齐，规划出最终路径。得益于错栅格粒度地图的建立，通过以上策略在不仅能在提高算法效率的同时，也能进一步提高路径的安全性与最优性。

中国知网 https://www.cnki.net

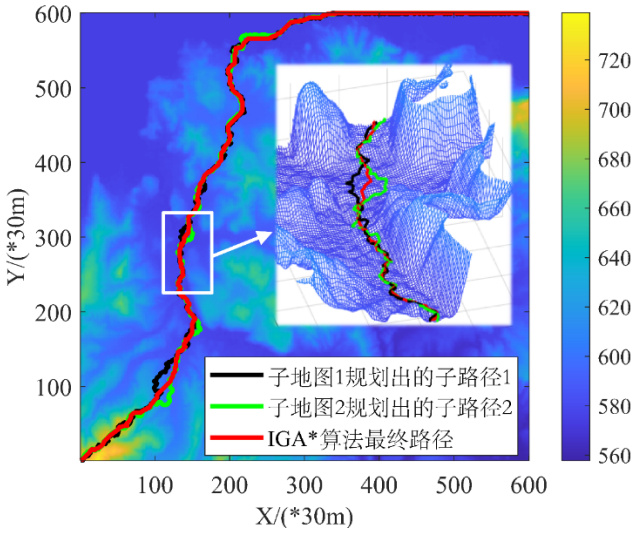


图 4.11 两条子路径与最终路径对比

Figure 4.11 Comparison of the two subpaths with the final path

4.3.2 普适性分析

针对 IGA*算法的普适性，本章随机生成从 5×5 至 1000×1000 不同分辨率大小的地图各 5 幅，共计 1000 幅地图，规划出从各地图原点处至对角线最远端的路径，各算法参数以及计算机配置与前文所述一致。除单位路径高程变化、单位路径地面陡峭度变化、算法规划时间三个评价指标外，引入规划路径长度作为第四个评价指标，各评价指标取平均值。

仿真结果变化如图 4.12~图 4.15 所示。

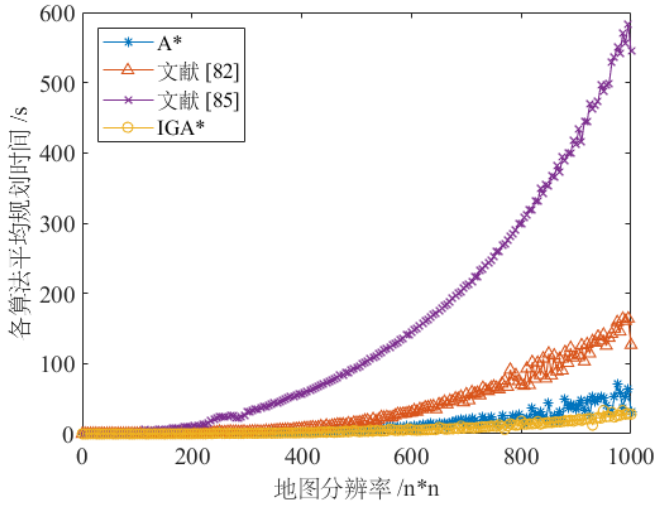


图 4.12 不同地图分辨率下各算法规划时间变化

Figure 4.12 Variation of planning time for each algorithm at different map resolutions

中国知网 https://www.cnki.net

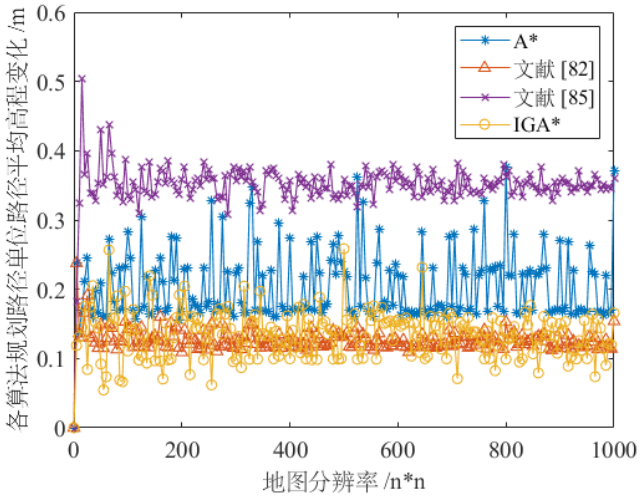


图 4.13 不同地图分辨率下各算法规划路径平均高程变化

Figure 4.13 Variation of average elevation of paths by algorithms under different map resolutions

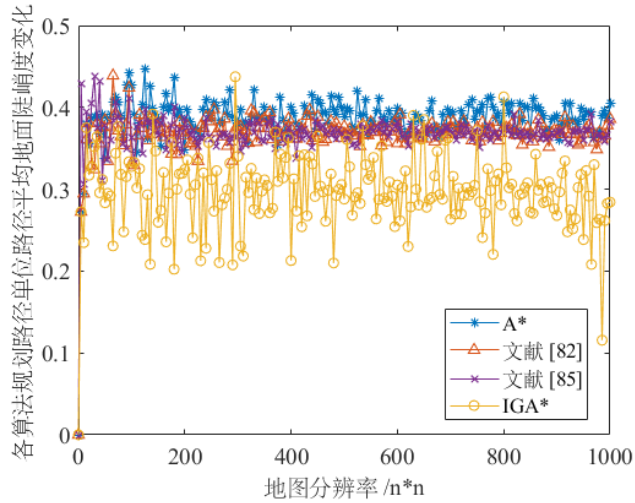


图 4.14 不同地图分辨率下各算法规划路径平均地面陡峭度变化

Figure 4.14 Variation of average ground steepness of paths by algorithms at different map resolutions

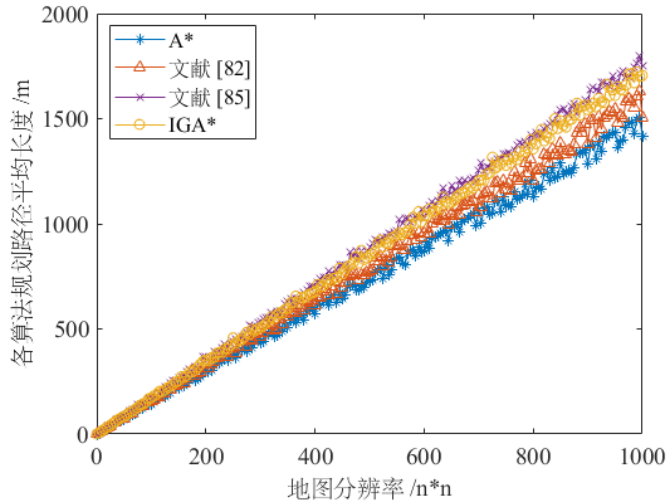


图 4.15 不同地图分辨率下各算法规划路径长度变化

Figure 4.15 Variation of planned path lengths of each algorithm under different map resolutions

中国知网 https://www.cnki.net

不难看出，在算法效率上，随着地图规模的增大，各算法所需时间呈指数级增长，其中IGA*算法规划所需时间的增长速率明显小于另外三种算法，在大规模地图环境下，依旧保持其高效性。与此同时，在单位路径高程变化、单位路径地面陡峭度变化两个方面，IGA*算法所规划路径的值相较另外三个算法均维持在一个较低的区间，路径较为平坦，也正因此，IGA*算法所规划路径会绕开部分不平坦区域，导致路径长度有所增加，其路径长度增量略高于文献[82]，但小于文献[85]。这源自路径长度与路径质量二者之间不可调和的矛盾，任意一个路径规划算法若要规划出平坦路径，则必然会导致路径长度的增加。

针对 IGA*算法，若不考虑路径质量，期望缩短路径长度，仅需对其代价函数中的 $g_{\text{terrain}}(n)$ 函数前添加一个小于 1 的权重 α 即可。

$$g(n-1,n)=L(n-1,n)\left(1+\alpha g_{\text{terrain}}(n)\right) \qquad \text{式 (4.45)}$$

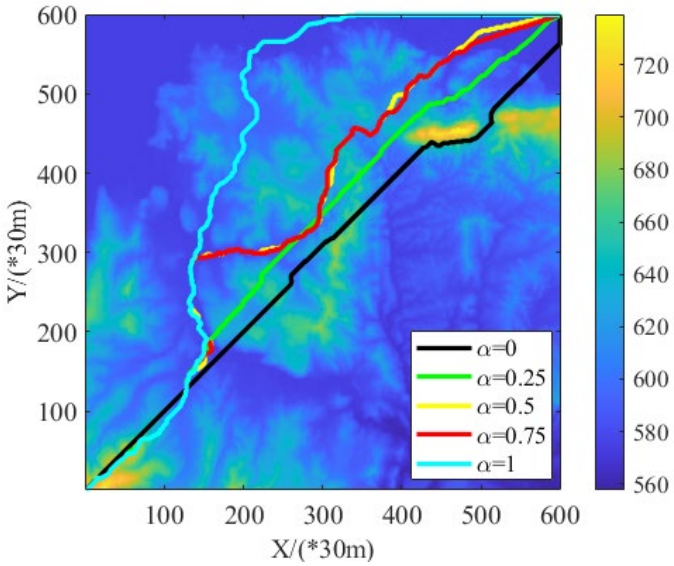


图 4.16 不同 α 值的 IGA*算法规划结果对比

Figure 4.16 Comparison of planning results of IGA* algorithm with different values of α

不同 α 值规划结果如图 4.16 所示。

可以看出，随着 α 值的减小，路径平坦程度开始降低，相应的路径长度也开始缩短。同时，得益于 IGA*算法策略，无论 α 值如何变化，不同权重下的算法规划时间均保持在 2.66s~4.67s 之间不等，IGA*算法依旧维持着其高效性。

4.4 试验分析评价

通过上述仿真分析，初步验证了所提出的 IGA*算法的有效性与普适性，为进一步验证算法在实际应用中的可行性，基于实验室的全地形智能车辆平台在现实环境中完成自主路径规划，对 IGA*算法进行场地试验评价。试验用的全地形智能车辆平台如图 4.17 所示，该车采用差动转向方式，可实现原地转向操作，无最小转弯半径，故不必考虑阿克曼转向等相关车辆运动学约束。表 4.3 给出了全地形智能车辆平台相关参数。

中国知网 https://www.cnki.net



图 4.17 全地形智能车辆

Figure 4.17 All terrain intelligent vehicle

表 4.3 全地形智能车辆相关参数

Table 4.3 Parameters related to all-terrain intelligent vehicles

参数	数值	参数	数值
车身长度	1.92 m	轮胎直径	0.55 m
车身宽度	1.54 m	轮距	1.26 m
车身高度	1.09 m	底盘高度	0.3 m
轴距	1.37 m	车厢长度	1.76 m

该全地形智能车辆搭载 JHCTECH 公司生产的 BRAV-7521 工控机，操作系统为 Ubuntu18.04，基于 ROS 开发环境，采用 Robosense16 线激光雷达采集周围地图环境信息，利用 NDT 算法完成环境三维点云地图的构建与车辆定位。试验中通过将建立好的三维点云地图高程化后生成 DEM 地图，在该地图上进行路径规划。

选择校内一复杂全地形环境作为试验场地，如图 4.18 所示。



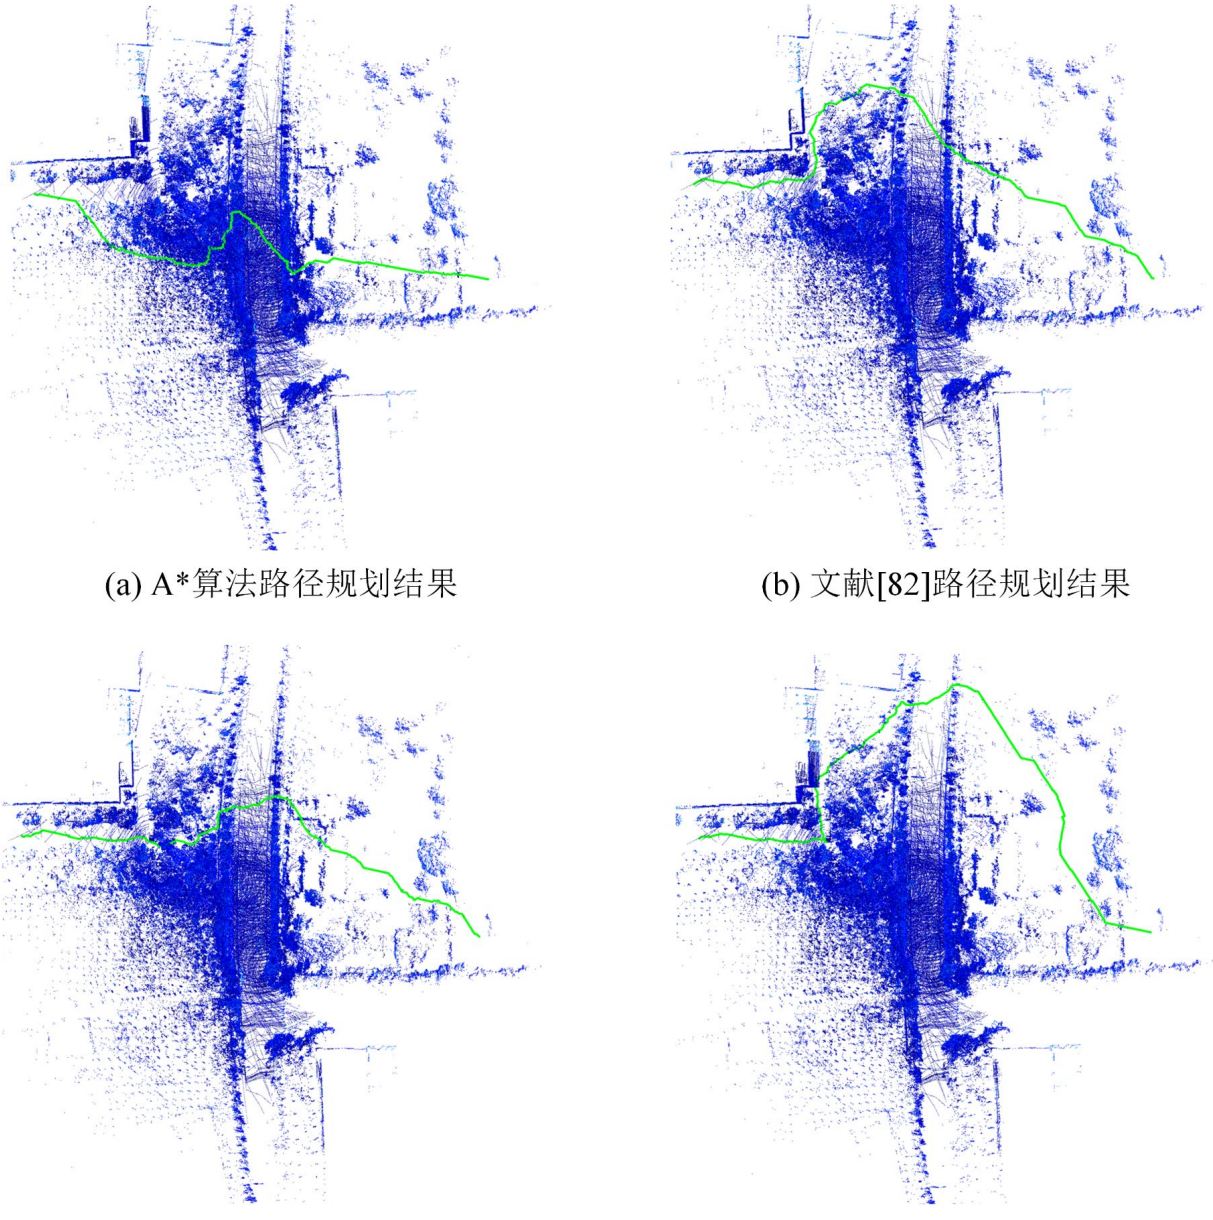
图 4.18 全地形试验场地

Figure 4.18 All-terrain test site

中国知网 https://www.cnki.net

该环境包含水泥地面、沥青路面、房屋建筑、草地、灌木、树林、泥土等多种环境特征，符合全地形环境要求，起点为房屋建筑一侧的平坦水泥地面，终点为泥土荒地中央一位置，从起始点到终点需经过树林、灌木丛、沥青路面等，通过在同一试验环境下对比 IGA*算法与其他 A*算法路规划的效率和路径质量，对 IGA*算法的有效性与可行性进行评价。

不同算法在该试验场景下规划结果如图 4.19 所示。蓝色为环境点云，绿色为不同算法规划出的路径。



(a) A*算法路径规划结果　(b) 文献[82]路径规划结果

(c) 文献[85]路径规划结果　(d) IGA*算法路径规划结果

图 4.19 全地形试验不同算法路径规划结果

Figure 4.19 Path planning results of different algorithms for all-terrain tests

其中，不同算法所规划路径参数对比如图 4.20~图 4.21 所示。

中国知网 https://www.cnki.net

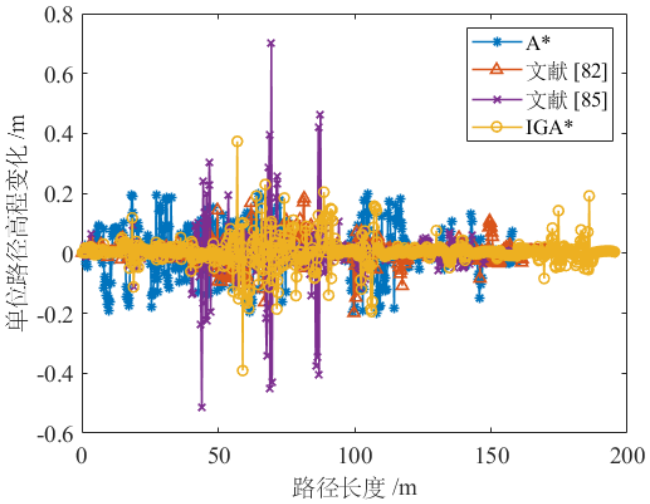


图 4.20 不同算法所规划路径单位路径高程变化

Figure 4.20 Change in path elevation per unit of path planned by different algorithms

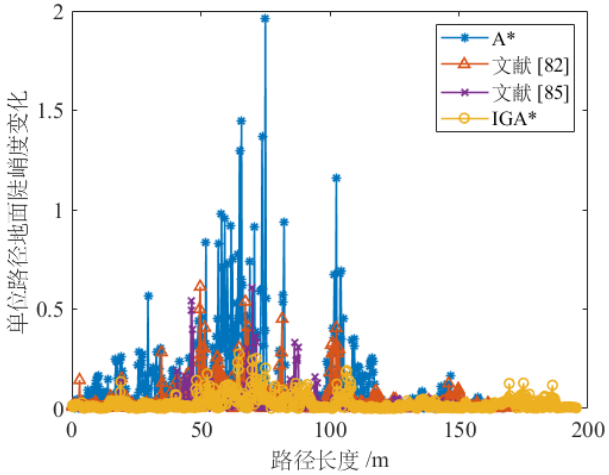


图 4.21 不同算法所规划路径单位路径地面陡峭度变化

Figure 4.21 Variation of ground steepness per unit path for paths planned by different algorithms

表 4.4 给出了各算法所规划路径的具体对比数据。

表 4.4 各算法规划路径数据对比

Table 4.4 Comparison of path planning data by algorithms

算法	规划时间/s	单位路径高程变化/m		单位路径地面陡峭度变化量	
		绝对值最大值	绝对值平均值	最大值	平均值
A*	47.77	0.199	0.047	1.96	0.116
文献[82]	71.56	0.198	0.019	0.613	0.042
文献[85]	192.89	0.703	0.032	0.608	0.031
IGA*	33.57	0.391	0.024	0.275	0.027

结合图 4.19~图 4.21 以及表 4.4 分析，不难看出，IGA*算法在现实环境中依旧保持其高

中国知网 https://www.cnki.net

效性及路径最优性，综合评价优于 A*算法以及文献[82]、文献[85]所改进的 A*算法。在场地试验中，相较于 A*算法，IGA*规划时间减少了 29.7%，IGA*算法所规划出的路径单位路径高程变化平均减少了 48.9%，单位路径地面陡峭度变化量平均减少了 76.7%，路径规划算法效率及路径质量得到了进一步提升。而相较于同样是基于 A*算法改进的文献[82]所提算法，IGA*规划时间减少了 53.1%，IGA*算法所规划出的路径单位路径高程变化与其相差不大，二者平均值差值约为 0.005，而单位路径地面陡峭度变化量平均减少了 35.7%，对比文献[85]所提算法，IGA*规划时间减少了 82.6%，IGA*算法所规划出的路径单位路径高程变化平均减少了 25%，单位路径地面陡峭度变化量平均值二者相差不大，差值约为 0.004，但 IGA*算法较其依旧降低了 12.9%。通过此次环境试验分析评价，进一步证明了本文所提 IGA*算法的有效性及可行性，在复杂非平坦环境地形条件下，IGA*算法能够为无人车辆快速规划出一条安全、可靠的行驶路径。

4.5 本章小结

本章针对非平坦地形环境下无人车辆路径规划问题，提出了一种错栅格粒度地图模型，并基于该地图模型提出了一种改进的 A*路径规划算法即 IGA*算法。首先依据 DEM 建立错栅格粒度地图模型，对地形环境进行描述，然后针对非平坦地形环境特点以及无人车辆本身通过性约束条件，对路径点进行地形通过性评估，建立起新的代价函数，引导算法规划出质量较高的路径，最后结合上述二者建立 IGA*算法策略，完成非平坦地形环境下无人车辆路径规划。在四种不同环境下进行了仿真实验分析，结果表明，相较于传统 A*算法，本章所建立的 IGA*算法，平均可节省 65.5%的规划时间，并且所规划出的路径单位路径高程变化平均减少 61.2%，单位路径地面陡峭度变化平均减少 73.2%。与相关文献的改进 A*算法相比，在规划时间平均节省 87.3%的同时，单位路径高程变化平均减少 18.2%，单位路径地面陡峭度变化平均减少 38.1%。IGA*算法在保证算法效率更高的同时，路径质量也得到了显著的提升。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

第五章 总结与展望

5.1 总结

本文针对复杂环境下无人车辆全局路径规划这一问题，分别从平坦复杂环境与非平坦复杂环境两个角度出发，结合车辆运动特性对现有 A*算法进行了研究改进。通过仿真分析与试验验证，结果证明了所改进算法的有效性，所改进算法能够满足无人车辆在不同环境下的应用需求。

本文主要工作总结如下：

（1）针对平坦复杂环境下 A*算法路径规划过程中存在的不足之处，对 A*算法进行了改进研究。建立了斜八邻域扩展概念，与四邻域扩展结合组成一种新的双邻域选择扩展策略，减少了路径规划过程中扩展节点数量；建立了新的代价函数，引导 A*算法可以更高效完成路径搜索；在 A*算法中引入了剔除路径不必要冗余路径点的碰撞检测算法。最后，分别通过计算机仿真和场地试验对所提出的改进方案进行了分析评价，结果表明所提出的改进 A*算法与传统的 A*算法相比，各方面得到了有效提升，能适应复杂的地图环境，可以满足实际应用需求。

（2）考虑到非平坦环境下的地形特点，针对非平坦地形环境下无人车辆路径规划问题，提出了一种错栅格粒度地图模型，并基于该地图模型建立了一种改进的 A*路径规划算法，即 IGA*算法。首先建立了一种错栅格粒度地图模型，通过两幅子地图交错的方式，存储相关环境信息，生成对应的陡峭度地图，完成对环境信息的理论描述。然后基于传统 A*算法，结合错栅格粒度地图模型，从地形坡度、地面阶跃高度、地形陡峭度三个方面对路径节点进行通过性评估，建立新的代价函数，引导算法避开不适宜通过的地形路径点，最后建立了 IGA*路径规划算法策略。在四种不同的地图环境下对所提出的 IGA*算法进行仿真测试评价以及后续场地试验，通过与传统 A*算法以及文献改进 A*算法进行了对比分析，结果表明，所提出的 IGA*算法能够兼顾算法效率和路径规划质量，相较于传统 A*算法，规划时间、单位路径高程变化、单位路径地面陡峭度变化等指标得到了大幅优化，能够实现更高效、更安全的路径规划。

5.2 展望

作为目前交通领域前沿技术之一的无人驾驶技术，不仅能反映出人类科技水平的高速发展，同时也蕴含着人们对于未来世界的美好期待。系统看来，无人驾驶不仅是一个极具深度与广度的科技难题，也是一个十分庞大且复杂的工程实际应用问题，需要多学科领域协同并进，共同发展。结合前人所做工作，本文在无人车辆全局路径规划这一问题上取得了部分成果，也解决了部分问题。但全面来看，对于无人车辆路径规划这一问题，本文所做工作是

中国知网 https://www.cnki.net

有限的，以下几个方面，本文未加以深入研究，而这也是亟待解决的部分难题：

（1） 本文主要针对已知环境地图从全局角度对无人车辆路径规划进行了研究，但现实情况下，环境信息并非一成不变，对于动态障碍物的处理以及规划策略的选择是下一步的研究重点。

（2） 车辆通过性主要包含几何通过性与支承通过性。非平坦环境下如何结合车辆实时位姿以及实时环境信息对以上两方面进行综合判断与分析，从而规划出一条最优路径是接下来的研究重点。

（3） 本文对于非平坦环境下无人车辆路径规划主要考虑了无人车辆的最大爬坡度等三个性能指标，对于其他运动学、动力学约束并未深入涉及。受地形条件的影响，车辆自身位姿（俯仰角、侧倾角、翻滚角等）处于一个动态变化过程，此刻的姿态进而影响下一步运动结果，即使在同一地形条件下，不同位姿下车辆的运动学、动力学约束条件也不尽相同，如何准确构建相关约束条件是一个值得深入研究的问题。

不知何时起，不同级别的无人驾驶技术开始广泛存在于我们身边，虽然目前距离真正的无人驾驶，人类还有很长的路要走，但我相信这一天终究会到，也许是明天，亦或后天。

中国知网 https://www.cnki.net

参考文献

[1] 姚为民.汽车构造[M].北京:人民交通出版社,2021.

[2] 洪金龙,高炳钊,董世营,等.智能网联汽车节能优化关键问题与研究进展[J].中国公路学报,2021,34(11):306-334.

[3] 《中国公路学报》编辑部.中国汽车工程学术研究综述·2017[J].中国公路学报,2017,30(06):1-197.

[4] 《中国公路学报》编辑部.中国汽车工程学术研究综述·2023[J].中国公路学报,2023,36(11):1-192.

[5] 金姬.无人驾驶：为何百年梦难圆？[J].新民周刊,2023(28):42-43.

[6] 詹玉.无人驾驶汽车路径规划方法研究[D].贵阳:贵州大学,2023.

[7] 朱冰,贾士政,赵健,等.自动驾驶车辆决策与规划研究综述[J].中国公路学报,2024,37(01):215-240.

[8] 叶强.德国自动驾驶立法评析[J].国外社会科学,2022(02):73-86+197.

[9] Ratering S, Gini M. Robot navigation in a known environment with unknown moving obstacles[C]//IEEE International Conference on Robotics & Automation. IEEE, 1995.

[10] Lam C P, Chou C T, Chiang K H, Fu L C. Human-Centered Robot Navigation-Towards a Harmoniously Human-Robot Coexisting Environment[J]. IEEE Transactions on Robotics,2011,27(1):99-112.

[11] Verginis C K, Dimarogonas D V. Adaptive robot navigation with collision avoidance subject to 2nd-order uncertain dynamics[J]. Automatica, 2021,123(6):109303.

[12] 陈琦.需求决定市场，悉数自动驾驶发展里程碑[J].汽车与配件,2022(11):34-35.

[13] Thorpe C, Hebert M H, Kanade T, et al. Vision and navigation for the Caregie-Mellon navlab. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1988,10(3):362-373.

[14] Pomerleau D, Jochem T. Image processor drives across america one of the first steps toward fully autonomous vehicles[J]. Photonics Spectra,1996,30(4):80-86.

[15] 《中国公路学报》编辑部.中国交通工程学术研究综述·2016[J].中国公路学报,2016,29(06):1-161.

[16] Durrant-Whyte H F. An autonomous guided vehicle for cargo handling applications[J]. International Journal of Robotics Research,1996,15(5):407-440.

[17] 徐友春,李克强,连小珉,等.智能车辆机器视觉发展近况[J].汽车工程,2003(05):438-443.

[18] 王晓,张翔宇,周锐,等.基于平行测试的认知自动驾驶智能架构研究[J].自动化学报,2024,50(02):356-371.

[19] 蒋倩男.面向智能驾驶辅助系统的视觉感知关键技术研究[D].合肥:合肥工业大学,2021.

[20] Broggi A, Bertozzi M, Fascioli A. ARGO and the MilleMiglia in Automatico Tour[J]. IEEE Intelligent Systems and their Applications,1999,14(1):55-64.

[21] 何科.无人驾驶汽车车道级定位导航系统关键技术研究[D].长春:吉林大学,2023.

[22] 李昌玺,孙玉彪,范泽昊,等.无人作战平台发展现状及趋势[J].中国电子科学研究院学报,2023,18(03):274-279.

中国知网 https://www.cnki.net

[23] 何树林.浅谈智能汽车及其相关问题[J].汽车工业研究,2010(9):28-30.

[24] Thrun S, Montemerlo M, Dahlkamp H, et al. Stanley: The robot that won the DARPA Grand Challenge[M]// The 2005 DARPA Grand Challenge,2007:1-43.

[25] Urmson C, Anhalt J, Bagnell D, et al. Autonomous driving in urban environments: Boss and the Urban Challenge[J]. Journal of Field Robotics,2008,25(8):425-466.

[26] 李兵.基于联合仿真的智能车辆路径跟踪控制研究[D].大连:大连理工大学,2014.

[27] Markoff J. Google cars drive themselves in traffic[J]. New York Times,2010,10.

[28] 胡满江,杨智元,李洋,等.智能汽车人机协同决策关键技术综述[J].中国公路学报,2024,37(03):98-116.

[29] 陈虹,郭露露,宫洵,等.智能时代的汽车控制[J].自动化学报,2020,46(07):1313-1332.

[30] 王浩宇,左志强,邓宇翔,等.无人驾驶车辆运动控制综述[J/OL].控制理论与应用:1-16[2024-03-01].http://kns.cnki.net/kcms/detail/44.1240.TP.20231214.0029.006.html.

[31] 甘钧先.意图孪生：人工智能军事化的国际安全挑战与治理路径[J].长沙理工大学学报(社会科学版),2024,39(01):106-116.

[32] 李兵,何克忠,张朋飞,等.自主轮式机器人 THMR-V 的混合模糊逻辑控制[J].机器人,2003(06):539-543.

[33] 余哲琳.基于视觉惯导融合的智能车辆定位技术研究[D].成都:电子科技大学,2022.

[34] 钱立林.基于拓扑空间的智能车辆行为决策与轨迹规划方法研究[D].长沙:国防科技大学,2023.

[35] Fei R, Li S S, Hei X H, et al. The driver time memory car-following model simulating in Apollo platform with Gru and real road traffic data[J]. Mathematical Problems in Engineering,2020,20201-18.

[36] 李凤玉.百度 Apollo 自动驾驶平台竞争战略选择研究[D].北京:北京邮电大学,2022.

[37] 刘军明.广州小鹏汽车科技有限公司 P7 车型市场营销策略研究[D].长春:吉林大学,2021.

[38] 文雯.蔚来汽车发展战略研究[D].成都:西南财经大学,2021.

[39] 杨彬.园区内无人驾驶环卫车轨迹规划及跟踪控制研究[D].长春:吉林大学,2022.

[40] 耿蕤,周密,殷焕焕.自动驾驶出租车监管制度体系探析[J].综合运输,2023,45(09):66-69.

[41] Li X W, Li Q, Zhang J H. Research on global path planning of unmanned vehicles based on improved ant colony algorithm in the complex road environment[J]. Measurement and Control,2022,55(9-10):945-959.

[42] Wang Z, Li G F, Ren J. Dynamic path planning for unmanned surface vehicle in complex offshore areas based on hybrid algorithm[J]. Computer Communications, 2021,166,49-56.

[43] Wang N, Xu H. Dynamics-Constrained Global-Local Hybrid Path Planning of an Autonomous Surface Vehicle[J]. IEEE Transactions on Vehicular Technology,2020, 69(7):6928-6942.

[44] Wei Y, An D, Liu J, et al. Intelligent control method of underwater inspection robot in netcage[J]. Aquaculture Research,2021,53(5):1928-1938.

[45] Zong C F, Han X J, Zhang D, et al. Research on local path planning based on improved RRT algorithm[J]. Proceedings of the Institution of Mechanical Engineers, Part D: Journal of Automobile Engineering,2021,235(8):2086-2100.

[46] Zhang X, Zhu T, Du L, et al. Local path planning of autonomous vehicle based on an improved heuristic Bi-

中国知网 https://www.cnki.net

RRT algorithm in dynamic obstacle avoidance environment[J]. Sensors,2022,22(20):7968.

[47] Yang L, Qi J L, Song D L, et al. Survey of robot 3D path planning algorithms[J]. Journal of Control Science and Engineering,2016,2016(pt.1):7426913.1-7426913.22.

[48] Galceran E, Carreras M. A survey on coverage path planning for robotics[J]. Robotics Autonomous Systems,2013,61:1258-1276.

[49] Dijkstra E W. A note on two problems in connection with graphs[J]. Numerische Mathematics,1959.

[50] Hart P E, Nilsson N J, Raphael B. A formal basis for the heuristic determination of minimum cost paths[J]. IEEE Transactions on Systems Science & Cybernetics,1972(2):28-29.

[51] Roberge V, Tarbouchi M, Labonte G. Comparison of parallel genetic algorithm and particle swarm optimization for real-time UAV path planning[J]. IEEE Transactions on Industrial Informatics,2013,9(1):132-141.

[52] Jiao Z Q, Ma K, Rong Y L, et al. A path planning method using adaptive polymorphic ant colony algorithm for smart wheelchairs[J]. Journal of Computational Science,2018,25(MARa):50-57.

[53] Mehdi G, Ali M. Motion Planning in order to optimize the length and clearance applying a hopfield neural network[J]. Expert Systems with Applications, 2008,36(3):4688-4695.

[54] 赵畅,刘允刚,陈琳,等.面向元启发式算法的多无人机路径规划现状与展望[J].控制与决策, 2022, 37(05):1102-1115.

[55] Yap P, Burch N, Holte R C, et al. Block A*: Database-Driven Search with Applications in Any-Angle Path-Planning[C]// AAAI Conference on Artificial Intelligence.2013.

[56] Nash A, Koenig S. Any-angle path planning[J]. AI Magazine,2013,34(4):85-107.

[57] Daniel K, Nash A, Koenig S, et al. Theta*: Any-angle path planning on grids[J]. Journal of Artificial Intelligence Research,2010,39(1):533-579.

[58] Xiao K, Gao C, Hu X, et al. Improved Theta*: Improved any-angle path planning on girds[J]. Journal of Computational Information Systems,2014,10(20):8881-8890.

[59] Zhang A, Li C, Bi W. Rectangle expansion A* pathfinding for grid maps[J]. Chinese Journal of Aeronautics,2016,29(5):1385-1396.

[60] Botea A, Martin Müller, Schaeffer J. Near optimal hierarchical path-finding (HPA*)[J]. Journal of Game Development,2004.

[61] 赵晓,王铮,黄程侃,等.基于改进 A*算法的移动机器人路径规划[J].机器人,2018,40(06):903-910.

[62] Uras T, Koenig S, Hernandez C. Subgoal graphs for optimal pathfinding in eight-neighbor grids[C]//Proceedings of the 23rd International Conference on Automated Planning and Scheduling. Menlo Park, USA: AAAI Press,2013:224-232.

[63] Algfoor Z A, Sunar M S, Abdullah A. A new weighted pathfinding algorithms to reduce the search time on grid maps[J]. Expert Systems with Applications,2017, 71(APR.):319-331.

[64] 曹如月,张振乾,李世超,等.基于改进 A*算法和 Bezier 曲线的多机协同全局路径规划[J].农业机械学报, 2021,52(S01):7.

中国知网 https://www.cnki.net

[65] 劳彩莲,李鹏,冯宇.基于改进 A*与 DWA 算法融合的温室机器人路径规划[J].农业机械学报,2021,52(1):14-22.

[66] 李鑫,廖凯文,陈薇,等.多自动导引车路径规划的时空冲突约束 A*算法[J].计算机集成制造系统,2021,27(11):3219-3226.

[67] 欧阳明达,马越原.基于改进 A*算法的水下重力匹配导航路径规划[J].地球物理学报,2020,63(12):4361-4368.

[68] 李晓露,熊禾根,陶永,等.基于改进 A*算法的移动机器人全局最优路径规划[J].高技术通讯,2021,31(3):306-314.

[69] 程传奇,郝向阳,李建胜,等.融合改进 A*算法和动态窗口法的全局动态路径规划[J].西安交通大学学报,2017,51(11):137-143.

[70] 孙炜,吕云峰,唐宏伟,等.基于一种改进 A*算法的移动机器人路径规划[J].湖南大学学报（自然科学版）,2017,44(4):94-101.

[71] 陈光荣,郭盛,王军政,等.凸优化与 A*算法结合的路径避障算法[J].控制与决策,2020,35(12):2907-2914.

[72] 路永鑫,魏云冰,赵启承,等.基于层次分析法和改进 A*算法的电力应急机器人路径规划[J].电力系统保护与控制,2021,49(9):82-89.

[73] 中华人民共和国科技部.科技部关于支持建设新一代人工智能示范应用场景的通知[EB/OL].(2022-08-15) [2024-03-01]. https://www.most.gov.cn/xxgk/xinxifenlei/fdzdgknr/qtwj/qtwj2022/202208/t20220815_181874.html.

[74] Wang L, Lei T, Si J G, et al. Speed consensus control for a parallel six-wheel-legged robot on uneven terrain[J]. ISA Transactions,2021,129(PA):628-641.

[75] 张浩杰,龚建伟,姜岩,等.基于变维度状态空间的增量启发式路径规划方法研究[J].自动化学报,2013,39(10):1602-1610.

[76] Belter D, Wietrzykowski J, Skrzypczyński P. Employing natural terrain semantics in motion planning for a multi-legged robot[J]. Journal of Intelligent & Robotic Systems,2019,93(3-4):723-743.

[77] 闫飞,庄严,白明,等.基于拓扑高程模型的室外三维环境建模与路径规划[J].自动化学报,2010,36(11):1493-1501.

[78] 黄志清,李鼎鑫,王庆文.非平坦地形下移动机器人安全路径规划[J].控制与决策,2022,37(2):323-330.

[79] Saad M, Salameh A I, Abdallah S. Energy-efficient shortest path planning on uneven terrains: A composite routing metric approach[C]. 2019 IEEE International Symposium on Signal Processing and Information Technology (ISSPIT). Ajman, 2019:1-6.

[80] 殷建军,董文龙,梁利华,等.复杂环境下农业机器人路径规划优化方法[J].农业机械学报,2019,50(05):17-22.

[81] Ganganath N, Cheng C T, Tse C K. A constraint-aware heuristic path planner for finding energy-efficient paths on uneven terrains[J]. IEEE Transactions on Industrial Informatics,2015,11(3):601-611.

[82] Liu Q H, Zhao L J, Tan Z B, et al. Global path planning for autonomous vehicles in off-road environment via

中国知网 https://www.cnki.net

an A-star algorithm[J]. International Journal of Vehicle Autonomous Systems,2017,13(4):330-339.

[83] 张慧,荣学文,李贻斌,等.四足机器人地形识别与路径规划算法[J].机器人,2015,37(05):546-556.

[84] 冯世盛,徐青,朱新铭,等.基于地形数据的长距离越野路径快速规划方法研究[J].地球信息科学学报,2022,24(9):1742-1754.

[85] Zhang B, LI G, Zheng Q, et al. Path planning for wheeled mobile robot in partially known uneven terrain[J]. Sensors,2022,22(14):5217.

[86] 徐鹏,丁亮,高海波,等.考虑足地作用的足式机器人环境表征与路径规划[J].机械工程学报,2020,56(23):21-33.

[87] Saeed R A, Recupero D R, Remagnino P. A boundary node method for path planning of mobile robots[J]. Robotics and Autonomous Systems, 2020, 123:103320.

[88] Chunhao S, Chunyang W, Xuelian L, et al. Point cloud object recognition method via histograms of dual deviation angle feature[J]. International Journal of Remote Sensing,2023,44(9):3031-3058.

[89] Lee H, Lee S. Extended spectra-based grid map merging with unilateral observations for multi-robot SLAM[J]. IEEE Access,2021,PP(99):1-1.

[90] Rongguang L, Jie Y, Benfa K, et al. DIG-SLAM: An accurate RGB-D SLAM based on instance segmentation and geometric clustering for dynamic indoor scenes[J]. Measurement Science and Technology,2024,35(1):015401.

[91] Zhao M, Zhao N. Method for the construction of urban road digital elevation models integrated with semantic information[J]. Applied Sciences,2023,13(7):4210.

[92] Khatib O. Real-time obstacle avoidance for manipulators and mobile robots[J]. International Journal of Robotics Research,1986,5:90-98.

[93] Sturtevant N R. Benchmarks for grid-based pathfinding[J]. IEEE Transactions on Computational Intelligence & Ai in Games,2012,4(2):144-148.

[94] Jing X R, Yang X J. Application and improvement of heuristic function in A* algorithm[C]//. 2018 37th Chinese Control Conference. Wuhan: IEEE,2018:483-486.

[95] Francis A, Faust A, Chiang H, et al. Long-range indoor navigation with PRM-RL[J]. IEEE Transactions on Robotics,2020,PP(99):1-20.

[96] Li X, Gao X, Zhang W, et al. Smooth and collision-free trajectory generation in cluttered environments using cubic B-spline form[J]. Mechanism and Machine Theory,2022,169:104606.

[97] Biber P, Strasser W. The normal distributions transform: A new approach to laser scan matching[C]//IEEE/RSJ International Conference on Intelligent Robots and Systems. Piscataway, USA: IEEE,2003:2743-2748.

[98] NASA JPL. NASADEM Merged DEM Global 1 arc second V001[DB/OL]. (2000-02-21) [2024-03-01]. https://doi.org/10.5067/MEaSUREs/NASADEM/NASADEM_HGT.001.

中国知网 https://www.cnki.net